

Maschinelles Lernen II - Fortgeschrittene Verfahren

V01 Organisatorisches - Einführung – Problemstellung

Sommersemester 2017

Prof. Dr. J.M. Zöllner, Prof. Dr. R. Dillmann

INSTITUT FÜR ANGEWANDTE INFORMATIK UND FORMALE BESCHREIBUNGSVERFAHREN
INSTITUT FÜR ANTHROPOMATIK UND ROBOTIK



Inhalt der heutigen Vorlesung

- Allgemeine Informationen
- ML und Rückblick MLI
- Ziele ML II und Überblick MLII
- Literaturhinweise

ALLGEMEINE INFORMATIONEN

Lehrstühle

Institut für Anthropomatik und Robotik (IAR)

- Humanoids and Intelligence Systems Lab (HIS)
- Gebäude 50.20

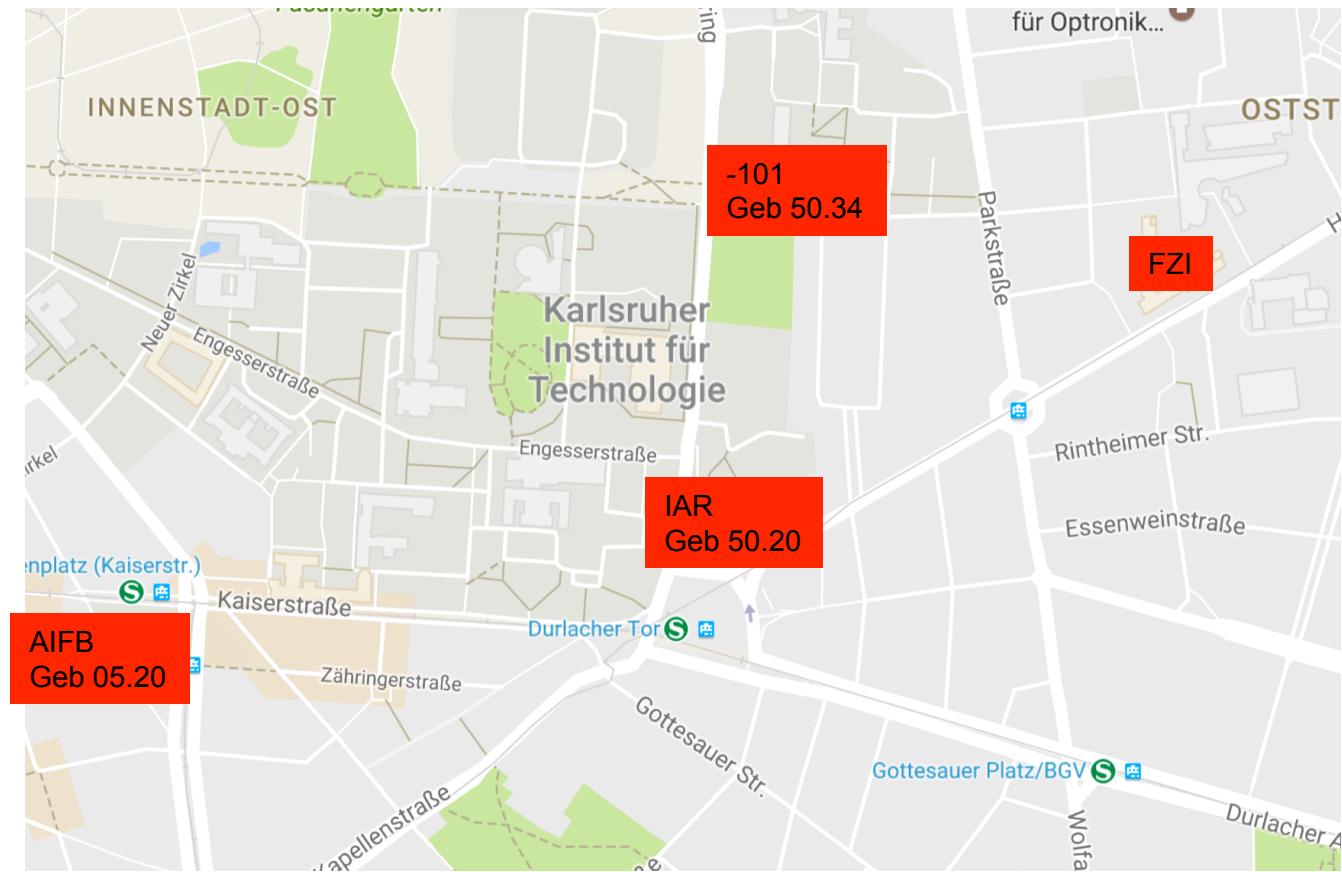
Institut für Angewandte Informatik und Formale Beschreibungsverfahren (AIFB)

- Applied Technical Cognitive Systems
- Gebäude 05.20

z.T. auch Unterstützung durch:

Forschungszentrum Informatik (FZI)

- Technisch Kognitive Assistenzsysteme
- Interaktive Diagnose- und Servicesysteme
- Haid-und-Neu-Str. 5a. 76131 Karlsruhe



Ansprechpartner, Betreuende Mitarbeiter

- Sonja Göttl (Sekretariat)
Haid-und-Neu-Straße 5a, Raum 3.0.05
goettl@fzi.de, 9654 351
- Darius Azafar
Haid-und-Neu-Straße 5a
darius.azarfar@kit.edu
- alle anderen freundlichen Dozenten und Übungsleiter
Michael Weber
Peter Wolf
Stefan Ulbrich
u.a.

Allgemeine Informationen

- Vorlesung LV-Nr. 24620 (Info+X) bzw. 2511502 (WiWi+X)
 - Ort : Geb. 50.34, HS -101
 - Zeit: Freitag, 9:45 - 11:15 Uhr
- Übung LV-Nr. 2511503 (WiWi+X)
 - Ort: Geb. 05.20 Raum 1C-04
 - Zeit: Mittwoch 14:00 – 15:30h (14-tägig), erstmals am 03.05.2017
- Prüfungsmodus: mündlich
- Sprechstunde: Mittwoch, 10:00 – 12:00 Uhr (Bitte anmelden!)
- Skript: Foliensammlung
- Webseite: ILIAS (Beitritt mit Passwort: ML2FVSS2017)
- Laborbesichtigung: ggf. bei Interesse gegen Semesterende
(Genaueres wird bekanntgegeben)

Projektpraktikum: Maschinelles Lernen – Anwendungen

- Begleitende Veranstaltung zu "Maschinelles Lernen"
- Anwendung von Methoden in konkreten, praktischen Umsetzungen:
 - Teilsystem aus dem Bereich Kognitive Robotik und Kognitive Automobile
 - unter Verwendung eines oder mehrere ML-Verfahren mit vorhandenen Bibliotheken
 - mit realen Daten eintrainieren und evaluieren.
- Projektspezifische Teamarbeit:
 - Problembeschreibung, Spezifikation
 - Entwicklung von Konzepten und Lösungsstrategien im Team
 - Evaluierung und Aufbereitung der Ergebnisse
 - Zusammenfassung der Ergebnisse / Erkenntnisse in einem wissenschaftlichen Vortrag
- Projekt dieses Jahr: Videobasierte 3D – Objekterkennung
- Bei Interesse/Fragen → Mail an Michael.Weber@fzi.de



„Ziemlich ausgebucht“

Vorgehen bei Fragen oder Problemen

- Ich hab eine Frage!
- Kein Problem, ich schreibe eine Mail an den Professor.



Vorgehen bei Fragen oder Problemen

- Prüfen Sie zunächst, ob die Frage bereits auf dem **Informationsblatt** oder
- an sonstiger Stelle in **ILIAS** (wie Vorlesungsfolien oder Übungsblätter) oder
- im **Forum** beantwortet wurde.

Falls nein:

- Stellen Sie die Frage mit ausreichender Erläuterung im Forum.
- Sollte Ihr Problem weiterhin bestehen oder es sich um ein persönliches Anliegen handeln, wenden Sie sich dann (und wirklich erst dann) an die Übungsleitung.

Was ist nun zu tun?

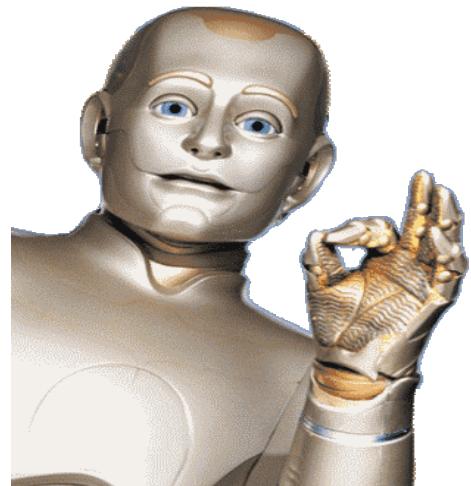
- ✓ ILIAS-Kurs beitreten
- ✓ Infoblatt lesen
- ✓ Folien durcharbeiten
- ✓ Übungsblätter genau lesen
- ✓ Forum lesen

Das ML-Team wünscht Ihnen
einen guten Start ins
Sommersemester

ML UND RÜCKBLICK ML I

Ziel ist Maschinelle Intelligenz !?

- Thema vieler Fantasien, Filme und Geschichten...



Ziel ist Maschinelle Intelligenz !?

- Aber auch Realität z.B. kognitive Autos und Roboter ...

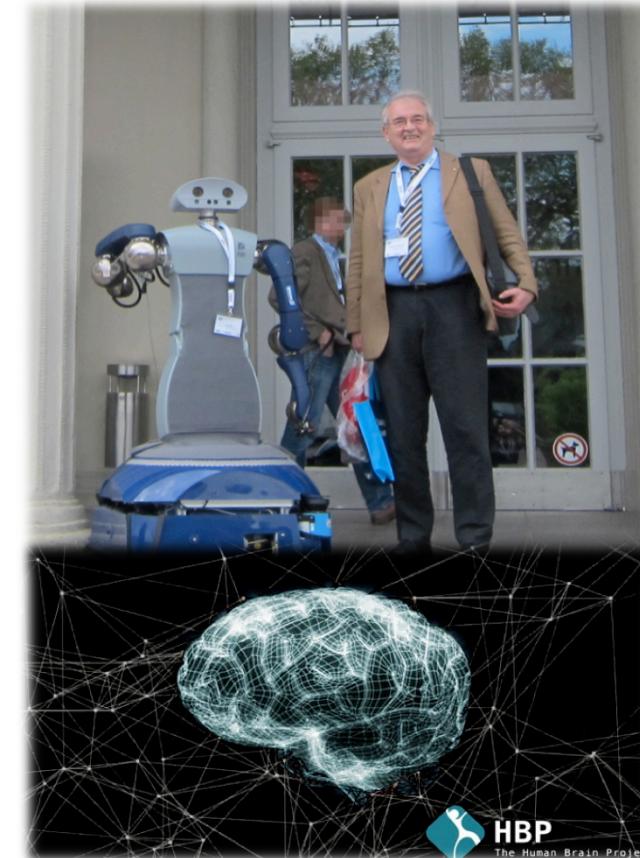


Ziel ist Maschinelle Intelligenz !?

- Aber auch Realität z.B. intelligente lernende Assistenten ...



Maschinelles Lernen II - Einführung und Problemstellung



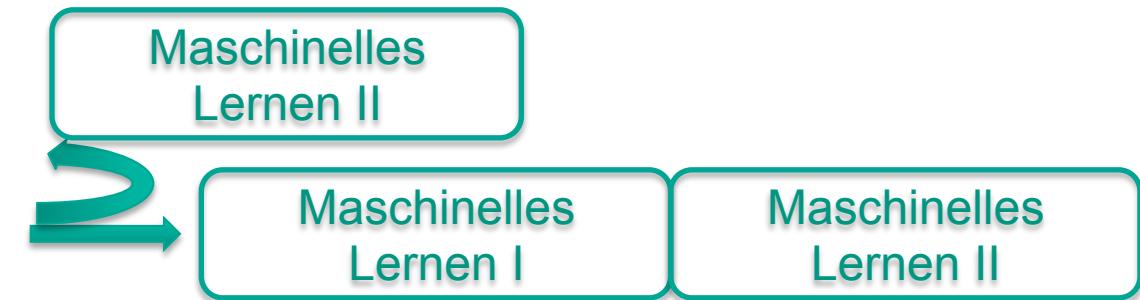
Das Vorbild Gehirn ist der einzige mögliche Leitgedanke für die IT der Zukunft – Prof. Alois Knoll

Intelligenz: Was ist das? Definitionen?

- Bereits 1921: Gesammelte Definitionen führender Psychologen
- Umgebung (in einem technischen: Sinne Einbettung/Anwendung) lange nicht berücksichtigt

Komponenten

- Denken und Problemlösen
- Lernen und Erinnern
- Sprache
- Kreativität
- Bewusstsein
- Überleben in komplexen Welten
- Rezeptive und motorische Fähigkeiten



Was ist Lernen? (naiv)

- Ich lerne ein Gedicht **auswendig**.
- Ich lerne, ein Menü **zuzubereiten**.
- Ich lerne etwas über **theoretische Physik**.
- Ich lerne Rad **fahren**. Ich lerne Auto fahren.
- Ich lerne Klavier **spielen**.
- Ich lerne, bestimmte Aufgabentypen **immer schneller zu lösen**



Definition Maschinelles Lernen - MLI

Definition:

Ein System lernt aus Erfahrung E in Hinblick auf eine Klasse von Aufgaben T und einem Performanzmaß P, wenn seine Leistungen bei Aufgaben aus T gemessen mit P durch Erfahrung aus E steigt.

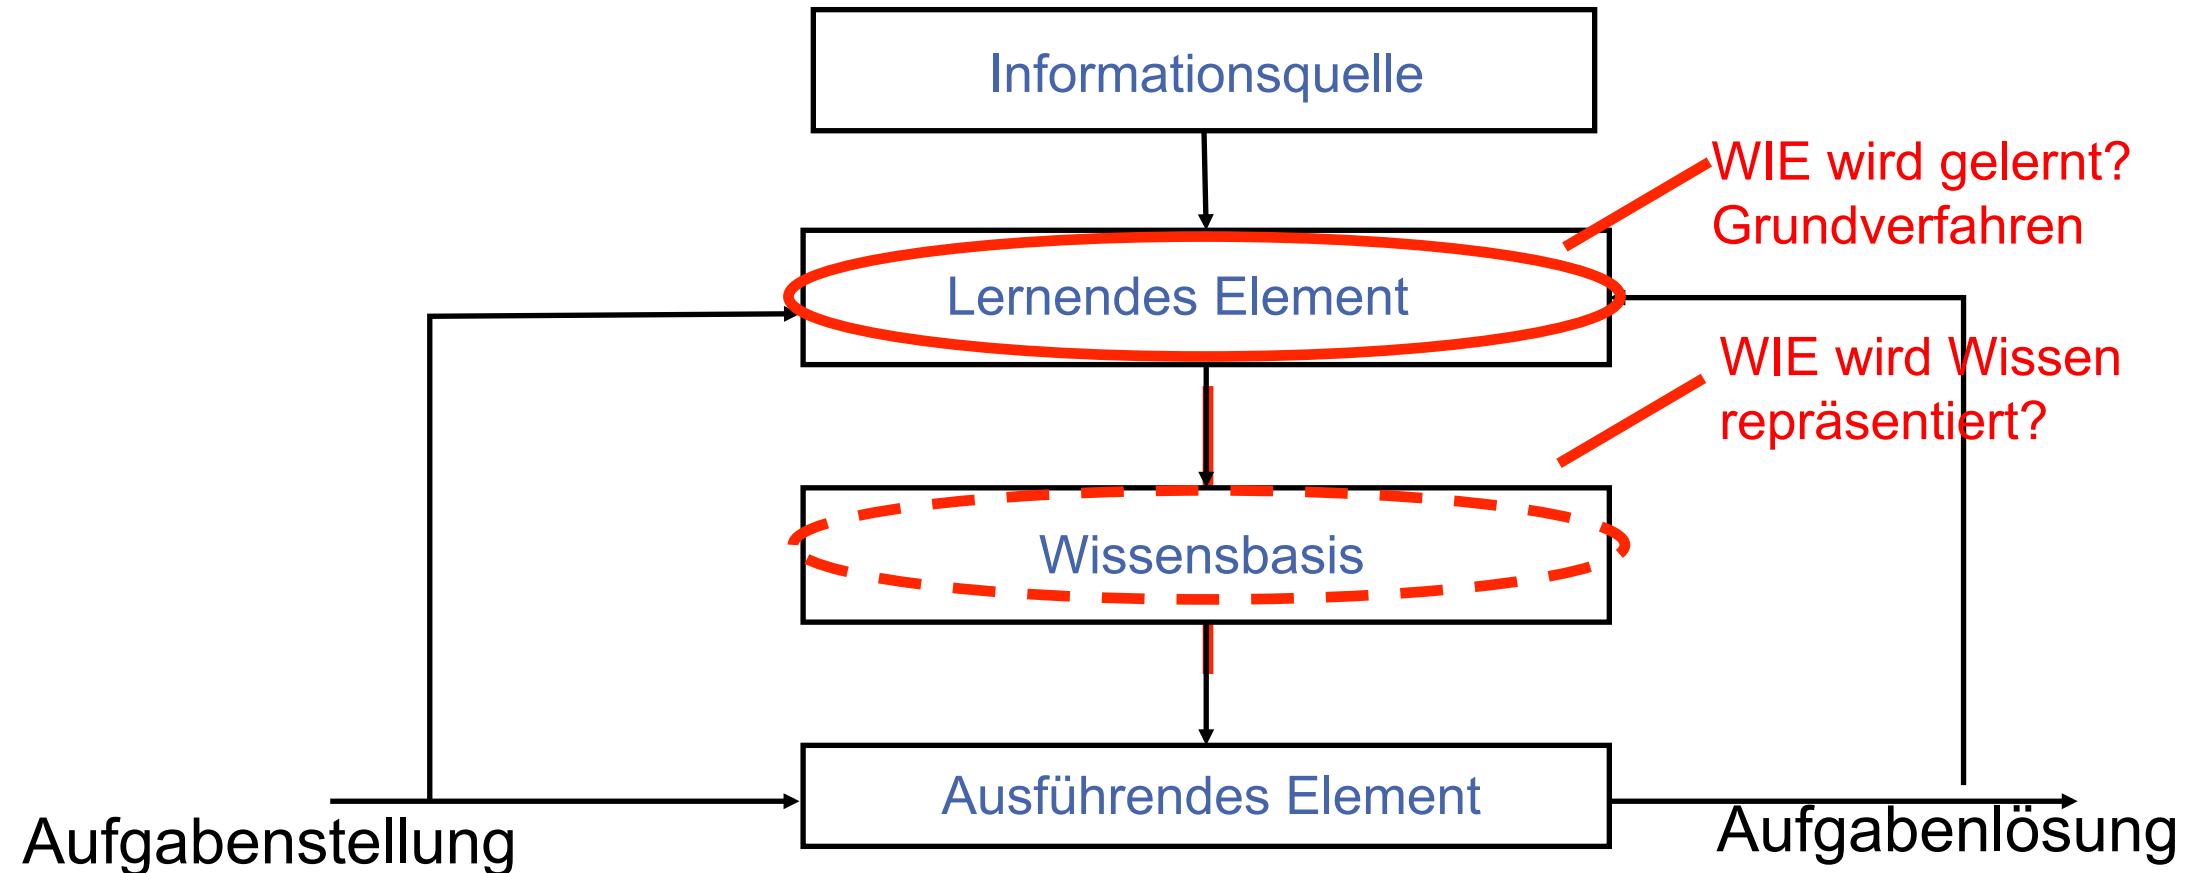
Beispiel: Lernen Schach oder GO zu spielen

T = Schach-/GO-spielen

P = Prozent der gewonnenen Spiele

E = Spiele gegen sich selbst

Komponenten eines lernenden Systems



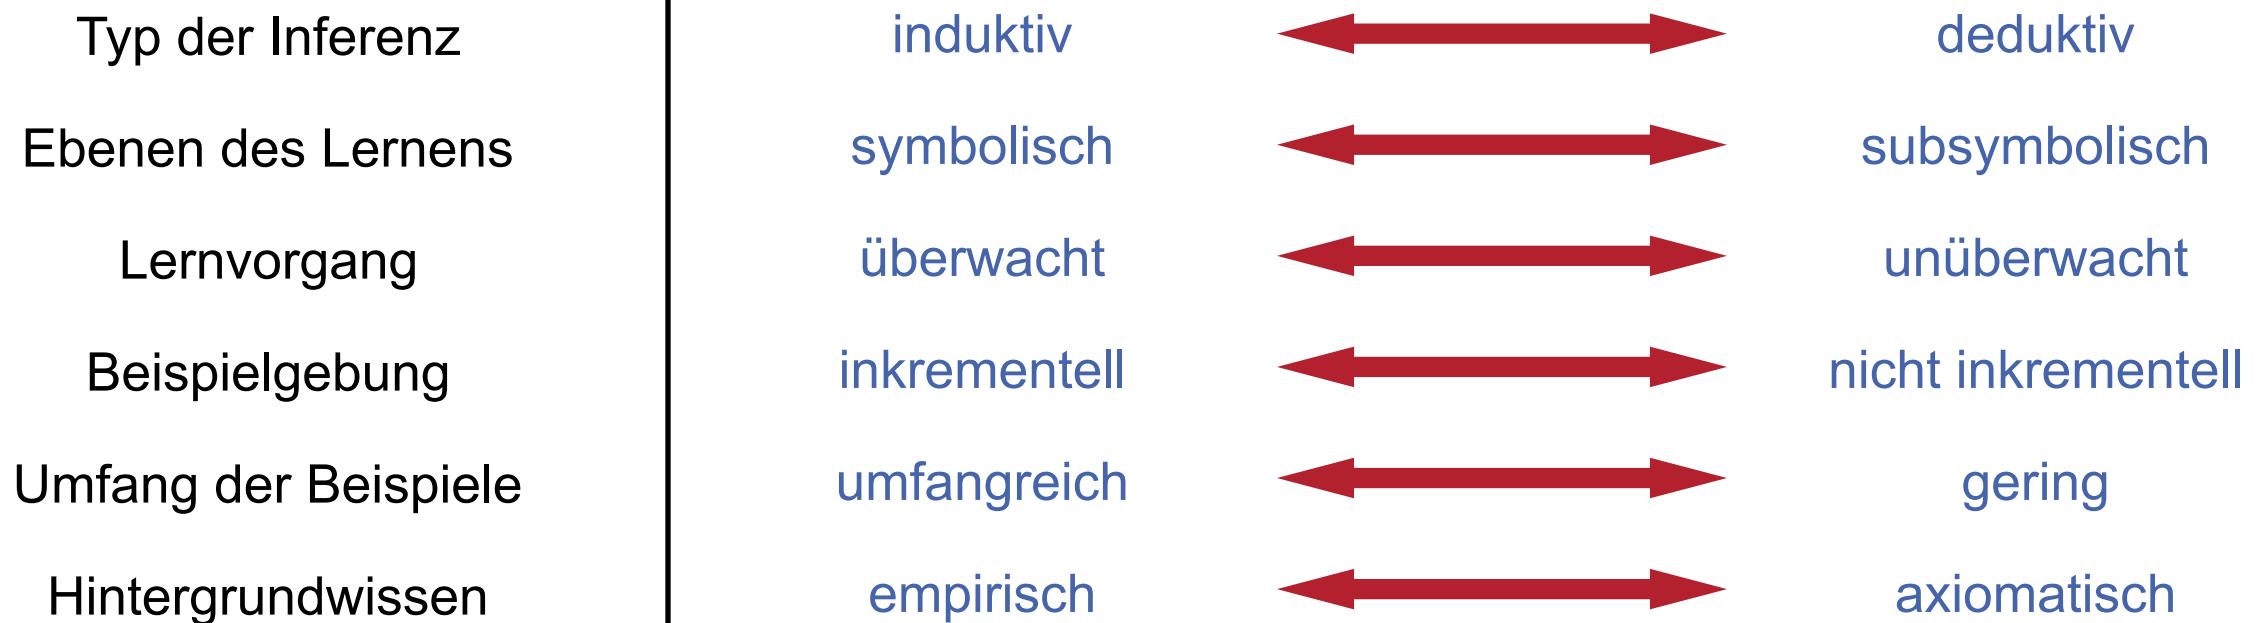
Lernverfahren – MLI

- Induktives Lernen
- Instanzbasiertes Lernen
- Deduktives Lernen
- Unüberwachtes Lernen
- Lernen nach Bayes
- Hidden Markov Modelle
- Entscheidungsbäume
- Lerntheorie (überwachtes Lernen)
- Markov Logik Netze
- Neuronale Netze
- Support Vektor Maschinen
- Evolutionäre Algorithmen
- Reinforcement Learning

Lernverfahren – Erweiterung in MLII

- Induktives Lernen
- Instanzbasiertes Lernen
- Deduktives Lernen
- Unüberwachtes Lernen
- Lernen nach Bayes
- Hidden Markov Modelle
- Entscheidungsbäume
- Lerntheorie (überwachtes Lernen)
- Markov Logik Netze
- Neuronale Netze
- Support Vektor Maschinen
- Evolutionäre Algorithmen
- Reinforcement Learning

Kriterien für die Einordnung von Grundverfahren (ML I)



**WENN DAS NUR SO EINFACH WÄRE
REALE ANWENDUNGEN → KOMPLEXERE ANFORDERUNGEN →
ERWEITERTE ANSÄTZE (BEISPIELHAFTE HERAUSFORDERUNGEN)**

Induktiver Schluss

Definition:

- Geg. eine Menge D von Grundbeispielen. Die Hypothese H folgt induktiv aus D und dem Hintergrundwissen B \Leftrightarrow

$$B \cup H \mapsto D, B \not\mapsto D, B \cup D \not\mapsto \neg H$$

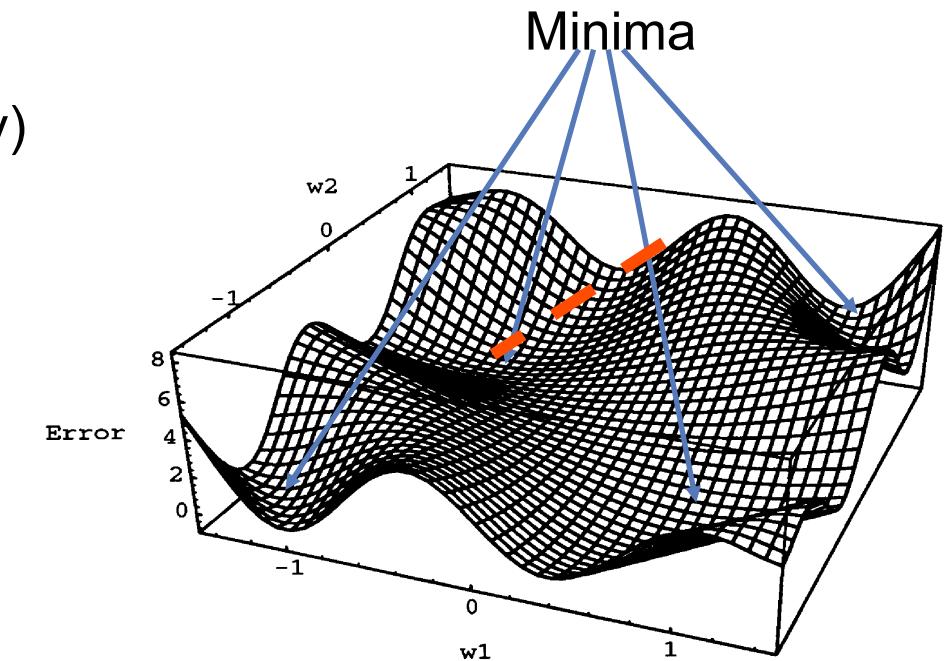
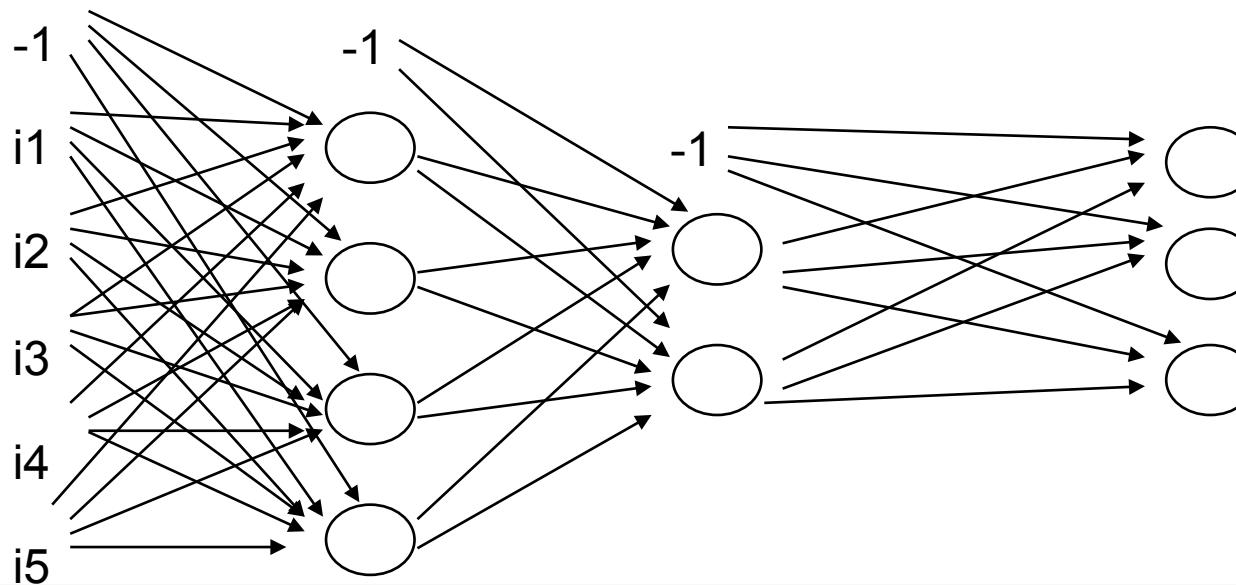
Generalisierung:

- Aus Hypothese einzelne Beispiele ableitbar, aber nicht umgekehrt
- Also genügend hohe Anzahl von Beispielen nötig
 $\{ \text{(`Sokrates ist ein Mensch.' / `Sokrates ist sterblich.'), ...} \}$

=> „Alle Menschen sind sterblich.“

Wdh.: Bestimmung v. Hypothesen durch induktives Lernen z.B MLNN (SVM)

- Aufbau:
 - Topologie, Neuronen, Schichten
 - Aktivierungsfunktion
- Lernen: Anpassen der Gewichte durch Backpropagation-Algorithmus
 - Idee / Fehlerfunktion / Algorithmus \leftarrow Minimierung
 - Allgemeine Delta Regel \leftarrow Gradientenabstieg
- Viele Erweiterungen / Verbesserungen (z.B. konstruktiv)



Induktiver Schluss - geht das immer?

Definition:

- Geg. eine Menge D von Grundbeispielen. Die Hypothese H folgt induktiv aus D und dem Hintergrundwissen B \Leftrightarrow

$$B \cup H \mapsto D, B \not\mapsto D, B \cup D \not\mapsto \neg H$$

Generalisierung:

- Aus Hypothese einzelne Beispiele ableitbar, aber nicht umgekehrt
- Also genügend **hohe Anzahl** von Beispielen

{ („Sokrates ist ein Mensch.“ / „Sokrates ist sterblich.“), }

{ („**Platon ist ein Mensch.**“ / „?“), }

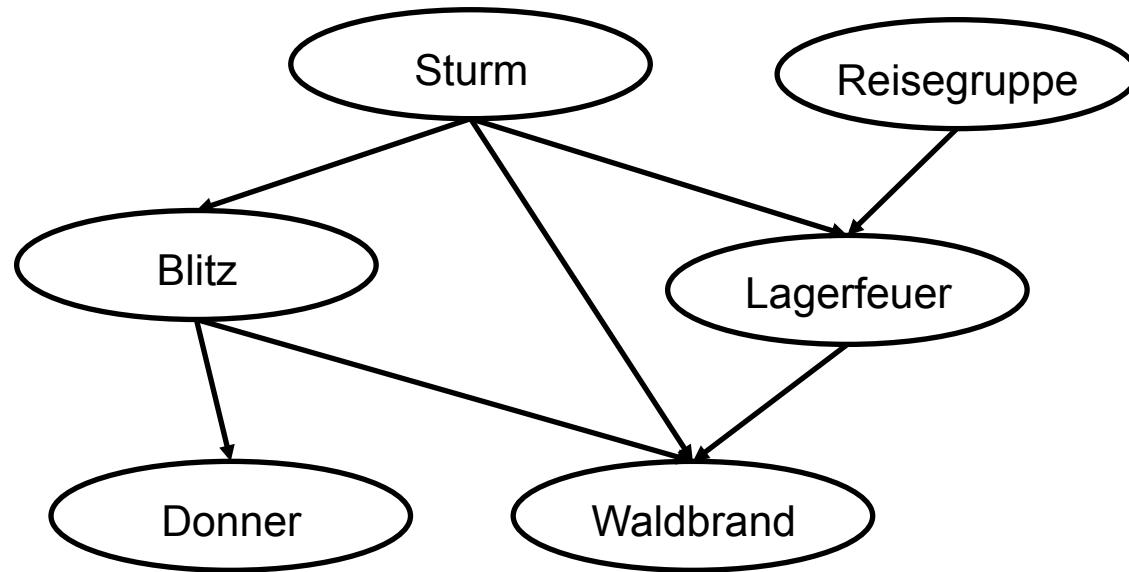
→(?) „Alle Menschen sind sterblich.“

Kriterien für die Einordnung von Grundverfahren (ML I)

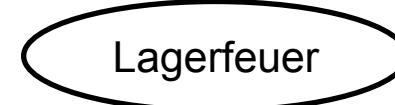


Erweiterte Verfahren
 kombinieren verschiedene Methoden oder Architekturen

Probabilistische Graphische Modelle, z.B. Bayes'sche Netze



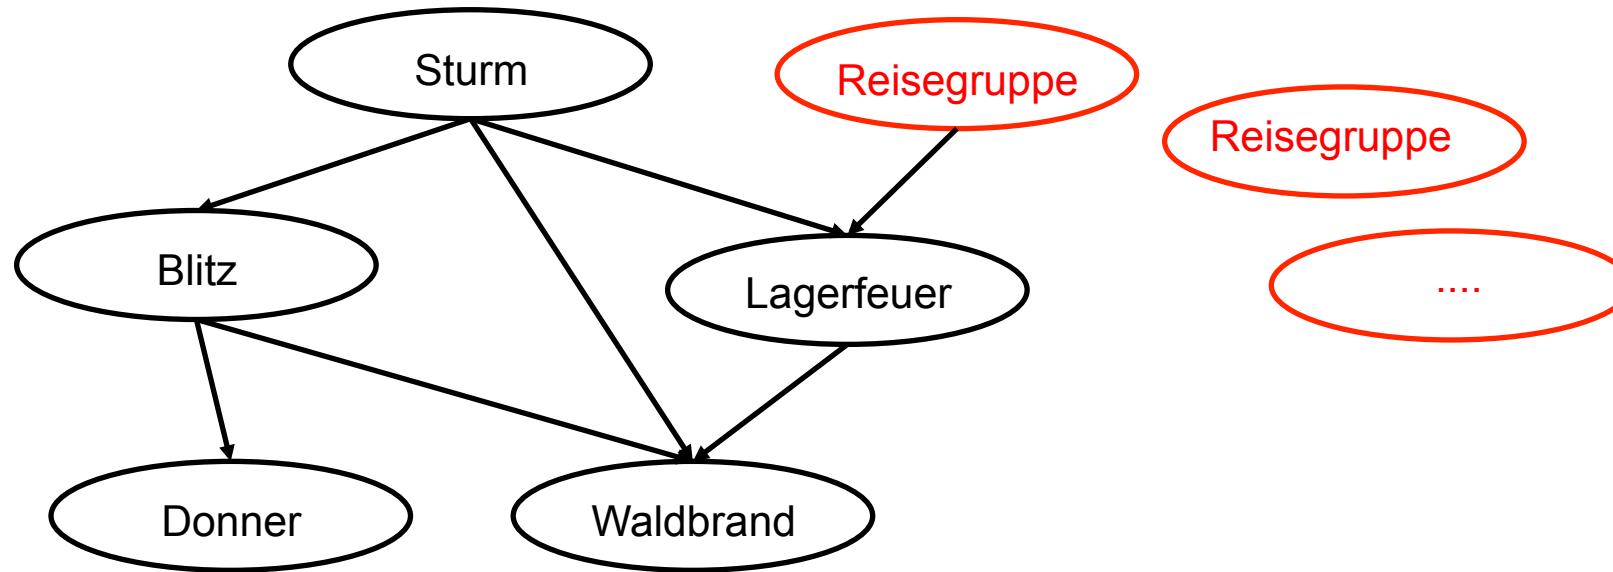
	S, R	$S, \neg R$	$\neg S, R$	$\neg S, \neg R$
L	0.4	0.1	0.8	0.2
$\neg L$	0.6	0.9	0.2	0.8



- Es gilt:
$$P(y_1, \dots, y_n) = \prod_{i=1}^n P(y_i | \text{Vorgänger}(Y_i))$$

wobei $\text{Vorgänger}(Y_i)$ die Menge der direkten Vorgänger von Y_i ist.

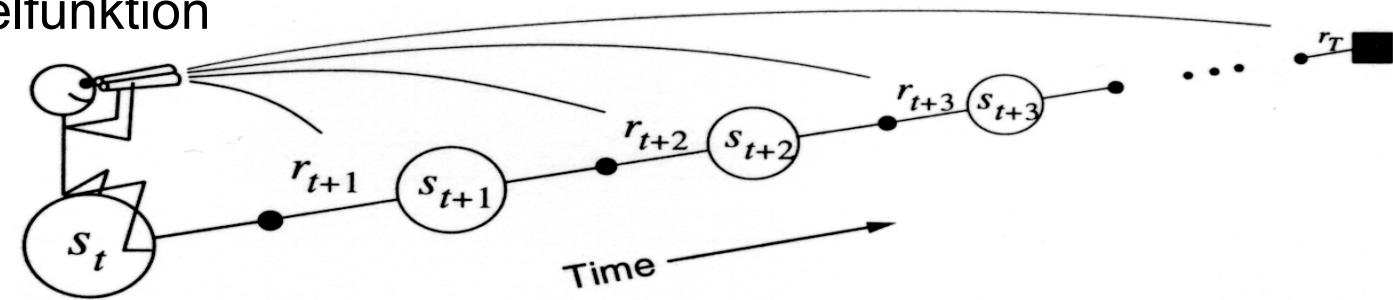
Probabilistische Graphische Modelle, z.B. Bayes'sche Netze



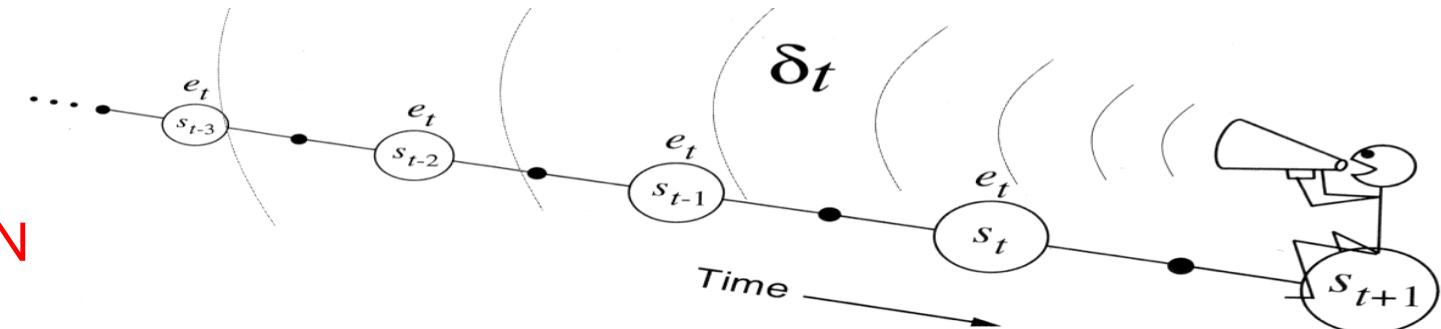
- Wenn mehrere Objekte oder zeitliche Implikationen vorhanden sind ???
- Gibt es eine sinnvolle „dynamische Klassen – Erweiterung“ und wie kann man diese „Erlernen“

Policy - Reinforcement Learning

- Formalismus, Theoretischer Hintergrund, Lernziel
 - Nichtdeterministischer MDP (markov decision process)
 - Zustände, Aktionen, Bewertung, Zielfunktion



- Strategielernen:
 - Temporal difference learning
 - V, Q – Learning: Grundprinzip, Probleme
- Lernen von Aktionssequenzen bei verspäteter Bewertung
 - Eligibility traces



- Wissensrepräsentation
 - Generalisierende Verfahren: NN
- Wenn aber die Menge der Zustände / Aktionen sehr groß ist ???
 - ➔ Wie beherrscht man das und wie lernt man? (Hierarchisches RL, DL)

ML heute: Beispiele & Herausforderungen

- Assistenzfunktionen: ACC ... Verkehrshinweise ...
Ausweichassistent ...
 - Kognitive Automobile



Quelle: MobileEye

- Viele ML-basierte Teilsysteme
 - Vielfältige Erkennung
 - Unsicherheiten
 - Plausible Entscheidung nötig
 - Kombination verschiedener Verfahren
 - **VIELE LERNBEISPIELE NÖTIG**
 - ➔ Aktives Lernen
 - ➔ Selbstlernen / Tiefe NN

ML heute: Beispiele & Herausforderungen

Kognitive Automobile

- AADC/ GCDC – Karlsruhe immer Platz 1 oder 2
- Google / VW / TU Berlin / BMW / Audi ...
- CoCar – Cognitiv Car, FZI Karlsruhe 2010-heute

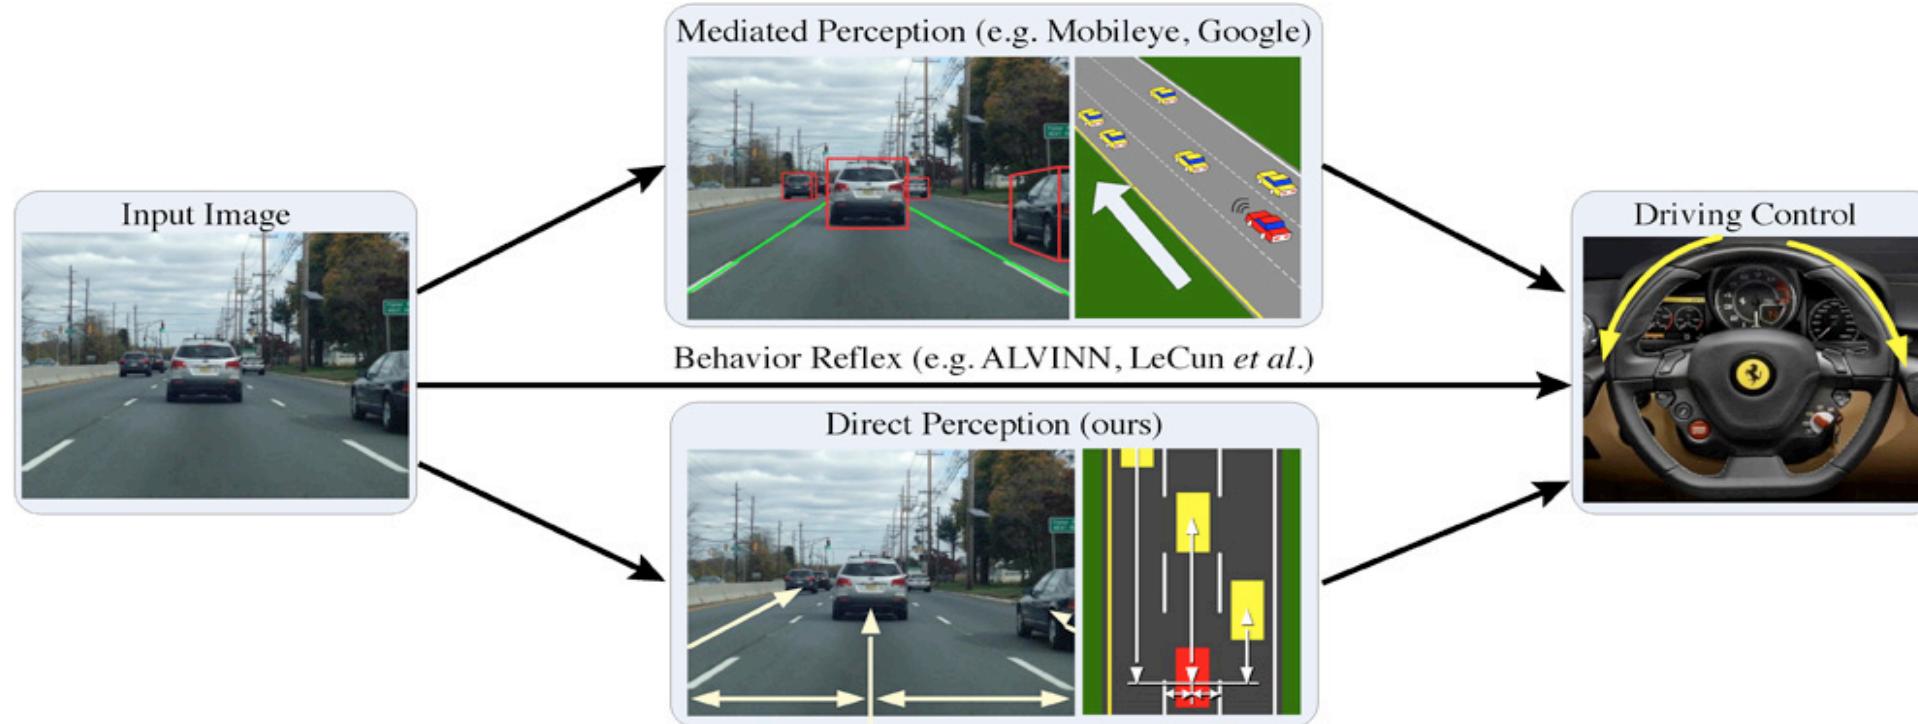


Maschinelles Lernen II - Einführung und Problemstellung



- Interpretation der Situation
- Riesige Zustandsräume
- Nicht vollständig beobachtbare Zustände
- Probabilistische Verhaltensentscheidung
- Nicht manuell modellierbar !!
- ➔ Lernende PRM
- ➔ End to End Deep NN

ML heute: Beispiele & Herausforderungen



- <http://deepdriving.cs.princeton.edu/>

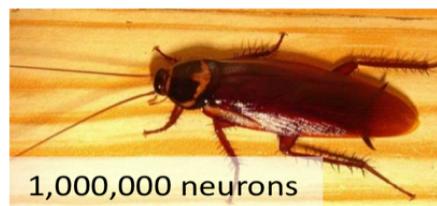
ML heute: Beispiele & Herausforderungen



10,000 neurons



850,000 neurons



1,000,000 neurons



75,000,000 neurons



200,000,000 neurons



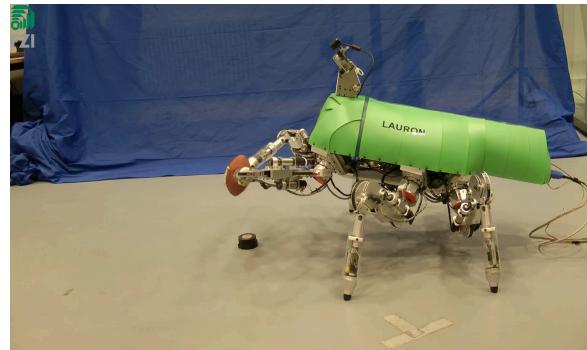
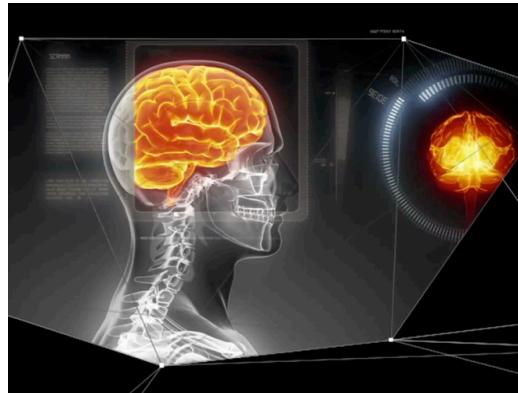
~85,000,000,000 neurons, 10^{15} synapses

- Algorithms are embedded in hardware
- Sensors and effectors operate in real-time
- The brain is massively parallel, but does not suffer from the problems of parallel computing: dead-locks, non-determinism, race-conditions, ...
- ... and decomposition into parallel tasks is self-organized/evolved
- Architecture is scalable from thousands to billions of “processors”
- Performance is robust – with graceful degradation
- Brains are extremely power and space efficient (“peta-flop computer on 20 Watt”)
- Calls for a “neurorobotics approach”



Human Brain Project

ML heute: Beispiele & Herausforderungen



■ Neurorobotik:

- Realisierung von Robotern mit eingebettetem „Gehirn“ basierend auf technisch und biologisch fundierten Modellen

■ Unsere Forschung:

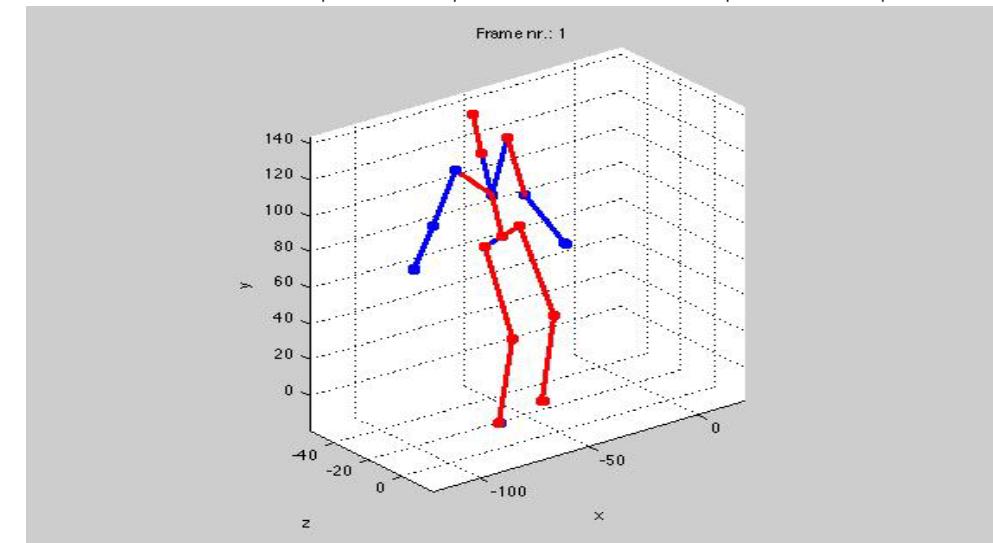
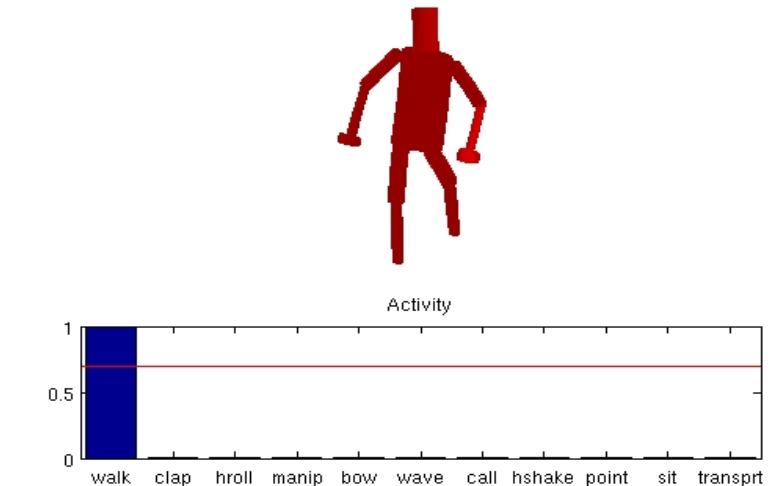
- Verhaltensbasierte Steuerung (z.B. von Laufmaschinen)
- Sensomotorisches Lernen für humanoide Roboter
- Handlungslernen
- Ansätze neuronaler Perzeption
- Umgebung um Neuroroboter-Systeme zu realisieren

ML heute: Beispiele & Herausforderungen

- Gesten- und Aktivitätserkennung, Vorhersage ?
 - Klassifikation menschlicher Aktivitäten anhand 3D-Körperposen und ihres zeitlichen Verlaufs
 - Welches sind die relevanten beobachtbaren Merkmale?

 - Üblich: explizit modellieren

 - Kann man diese implizit lernen?
 - Kann man Aktivitäten besser vorhersagen?
 - ...
- Deep Learning

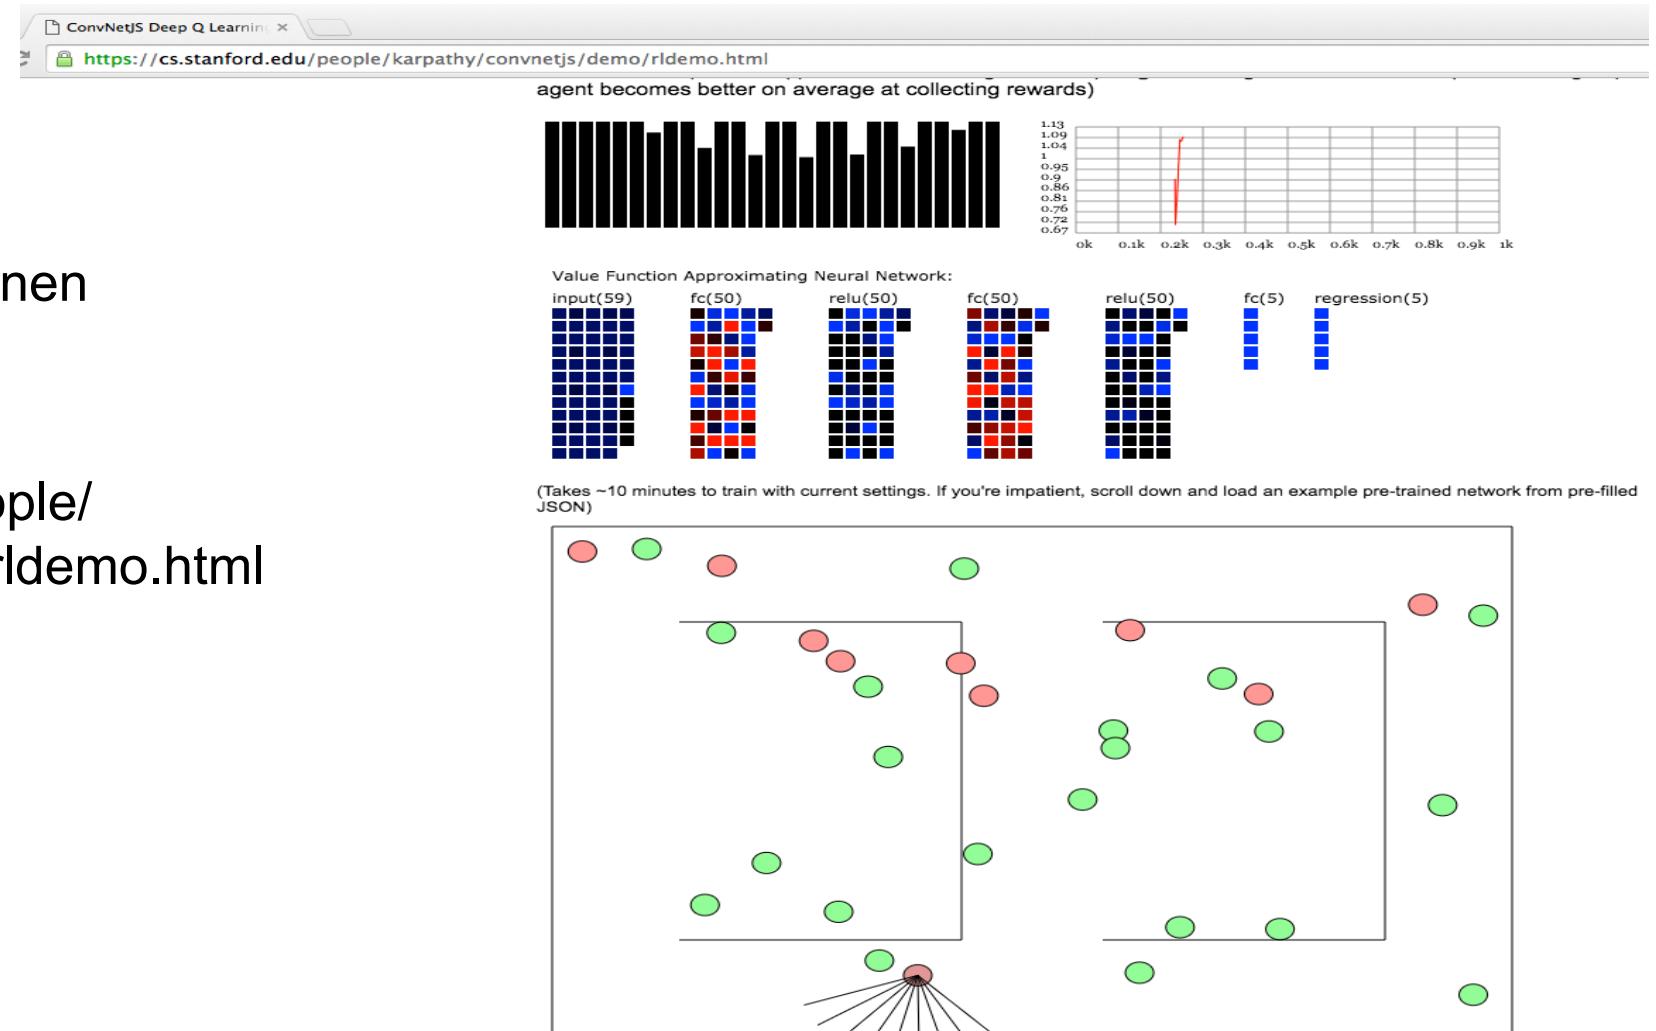


Rot – reale Bewegung
Blau – Vorhersage vor 2 Sec

ML heute: Beispiele & Herausforderungen

- Strategien automatisch lernen

- Kleine Demo:
<https://cs.stanford.edu/people/karpathy/convnetjs/demo/rldemo.html>

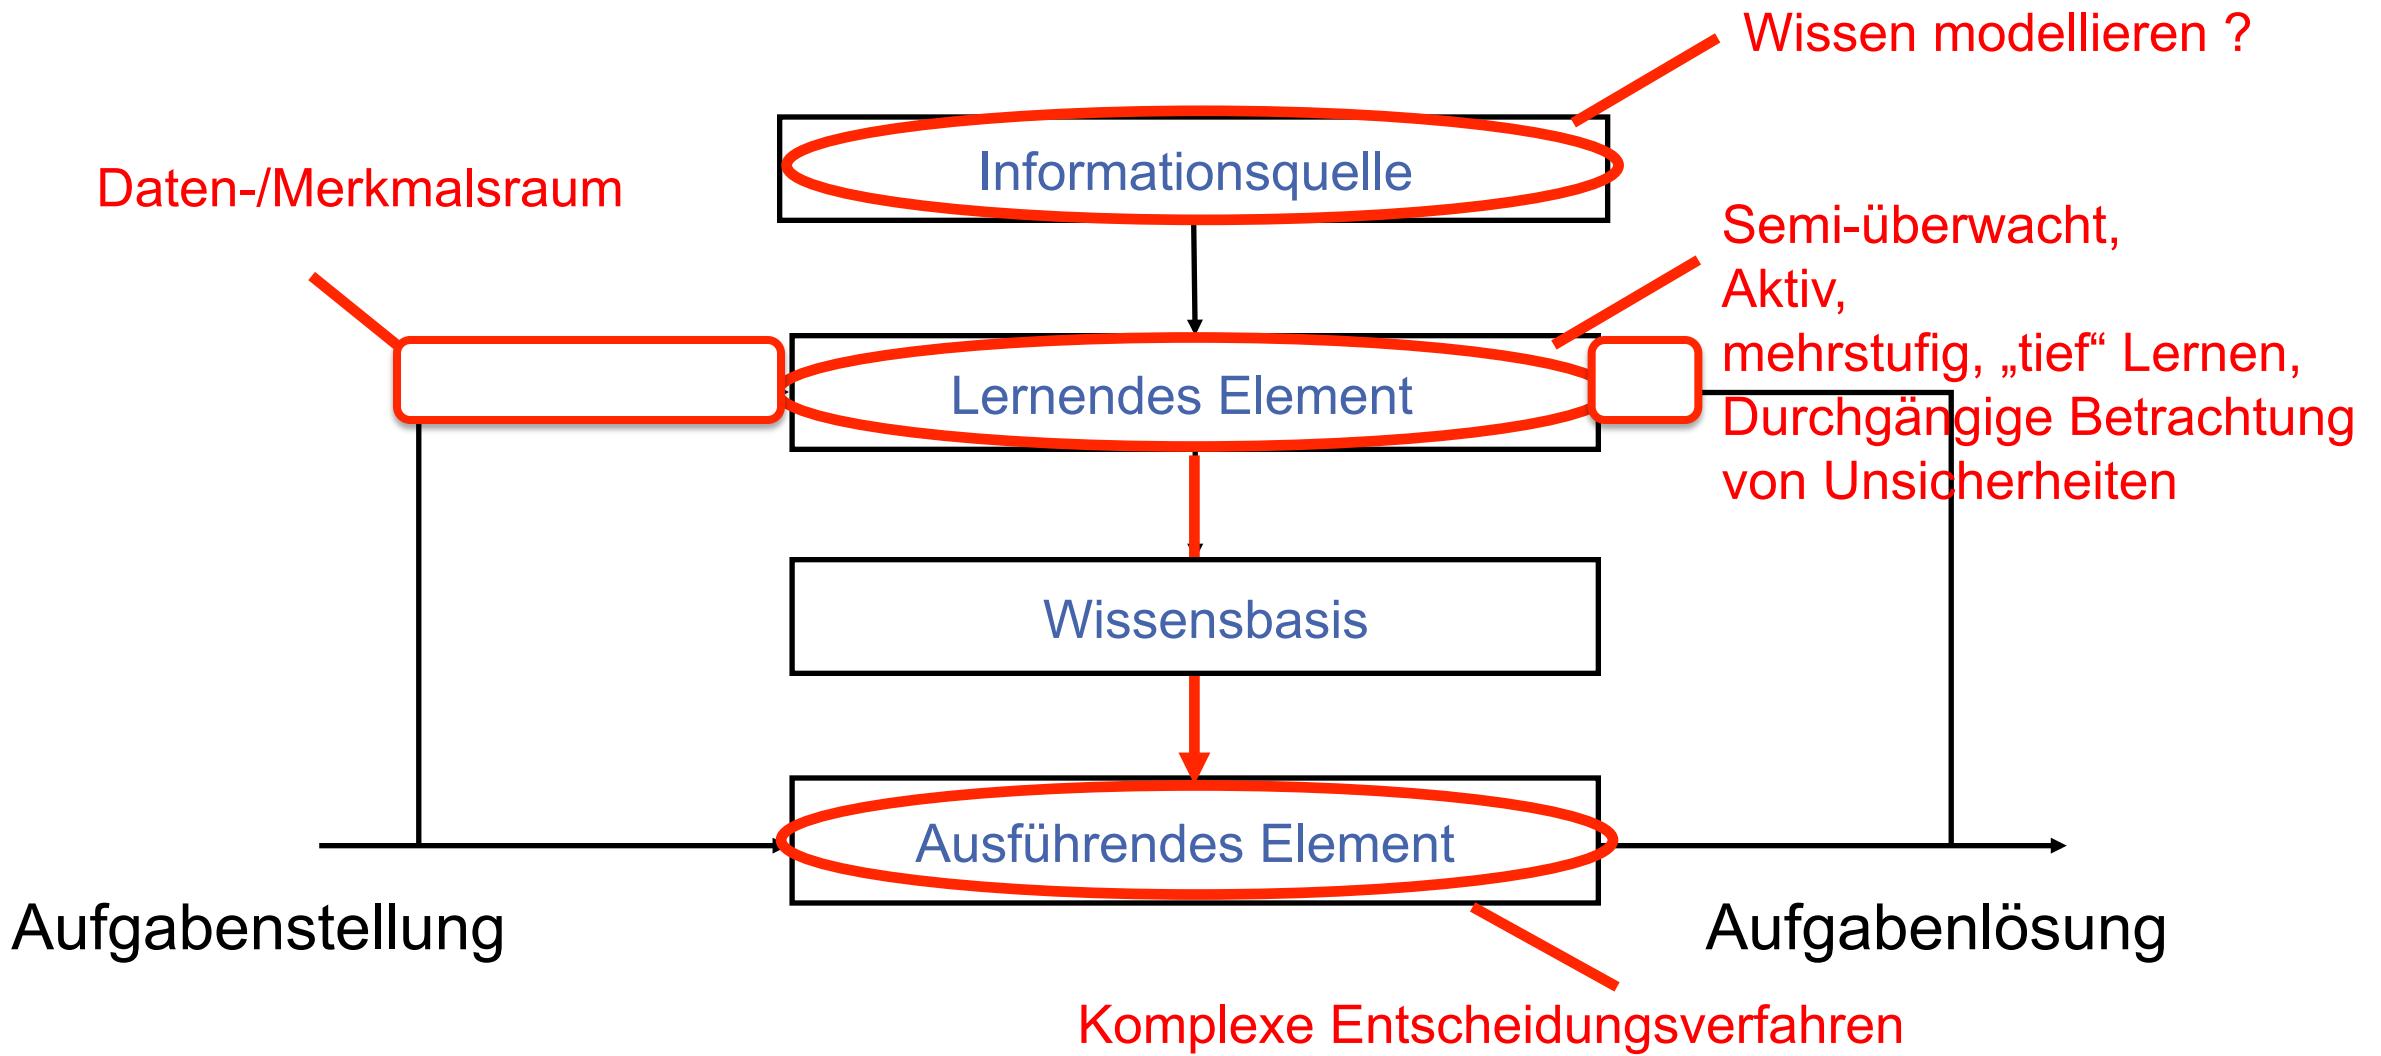


ML und seine Anwendung als aktuelles Forschungsgebiet (... heute)

- Verbesserung und Erweiterung der Grundverfahren
 - Korrektheit / Parametrisierung / Beschleunigung
Analyse des Gelernten, Vergleiche verschiedener Verfahren
 - Lernverfahren werden (realistisch) umsetzbar, z.B. Deep Learning, Spiking Neural Networks, Probabilistisch Relationale Modelle (PRM)
 - Ehrgeizige Ziele, siehe Human Brain Projekt (HBP)
- Betrachtung realer und dh. im Allgemeinen auch komplexerer Problemstellungen und Anwendungen
 - Hochdimensionale (Merkmals-) Räume (Tausende Variablen)
 - Lernbeispiele sind nur teilweise vorhanden
 - Repräsentation und Nutzung von vorhandenem Wissen
 - Nutzung von lernenden Komponenten in erweiternden probabilistischen Verfahren
-

ÜBERBLICK ML II

Komponenten eines lernenden Systems – ML II



Übersicht über die Vorlesung

VORLESUNG FR 9:45-11:15	ÜBUNG MI 14:00-15:30	INHALT
28.04.17		Einführung – Problemstellung
	03.05.17	Organisatorisches, Übungsplan, Wdh Neuronale Netze
05.05.17		Semi-Supervised Learning (SSL)
12.05.17		Semi-Supervised Learning/Active Learning (AL)
	17.05.17	Semi-Supervised Learning
19.05.17		Deep Learning (DL1)
26.05.17		BRÜCKENTAG
	31.05.17	Deep Learning - Tensor Flow
02.06.17		Convolutional Neural Networks (DL2)
09.06.17		Convolutional Neural Networks (DL3)

Übersicht über die Vorlesung

14.06.17	Deep Learning - CNN
16.06.17	BRÜCKENTAG
23.06.17	Advanced Reinforcement Learning
28.06.17	Deep Q-Networks
30.06.17	Spiking Neural Networks
07.07.17	Spiking Neural Networks
12.07.17	SNN - nest Dynamic Bayesian Networks, Statistical Relational Learning (OPRM)
14.07.17	
21.07.17	Gaussian Processes
26.07.17	SNN - nest / Gaussian Processes
28.07.17	Visualization & Analysis of Learning Quality

Literatur I (Basis)

Tom Mitchell: „Machine Learning”, McGraw Hill, 1997

- Neuronale Netze, Reinforcement Lernen, Evolutionäre Algorithmen, Entscheidungsbäume, KBNN, Lernen nach Bayes, ...

<http://www-2.cs.cmu.edu/afs/cs.cmu.edu/user/mitchell/ftp/mlbook.html>

Duda, Hart und Stork: „Pattern Classification”, 2nd Edition,
John Wiley & Sons, 2001

- Neuronale Netze, Unüberwachtes Lernen, Hidden Markov Modelle, ...

Literatur II (Basis)

Berthold und Hand: „Intelligent Data Analysis“, 2nd Edition, Springer, 2003

- Support Vektor und Kernel Methoden, Neuronale Netze, ...

Chapelle, Schölkopf, Zien: „Semi – Supervised Learning“

Russel and Norvig: „Artificial Intelligence – A Modern Approach“, 2003

Weiterführende Literatur – in der Vorlesung