

# Dynamische Bayes'sche Netze

Prof. Dr.-Ing. J. Marius Zöllner



Forschungszentrum Karlsruhe  
in der Helmholtz-Gemeinschaft



Universität Karlsruhe (TH)  
Forschungsuniversität • gegründet 1825

- Motivation
- Probabilistische Graphische Modelle
- Bayes'sche Netze – Verstehen
  - Bedingte Unabhängigkeit
  - Inferenz
  - .....
- Dynamische Bayes'sche Netze
- Zusammenhang mit Filtern
- Zusammenfassung


## ■ Bsp.-Problem 1: Automatisches Diagnosesystem

- Patient zeigt Symptome einer Krankheit
- An welcher Krankheit leidet der Patient?
- Mit welcher Wahrscheinlichkeit kommen einzelne Krankheiten als Ursache in Frage?
  - Modellierung als Bayes'sches Netz

## ■ Bsp.-Problem 2: Fahrzeugverfolgung

- Lage von Verkehrsteilnehmern fortlaufend verrauscht messbar
- Wo befinden sich die Verkehrsteilnehmer jetzt?
- Wie sieht die Verkehrssituation in 10s wahrscheinlich aus?
  - Modellierung als Dynamisches Bayes'sches Netz

# Bsp. - Problem 2: Fahrzeugverfolgung



[Gindele et al., ITS Magazine 2015]

# Wahrscheinlichkeitstheorie

## ■ Multiplikationssatz (Chain Rule)

- Die Verbundwahrscheinlichkeitsverteilung (Joint Probability Distribution, JPD) mehrerer Zufallsvariablen lässt sich wie folgt faktorisieren:

$$P(A, B) = P(A)P(B|A)$$

$$P(X_1, X_2, \dots, X_n) = P(X_1) \prod_{k=2}^n P(X_k | X_{k-1}, \dots, X_1)$$

## ■ Theorem der totalen Wahrscheinlichkeit: Für sich gegenseitig ausschließende Ereignisse $A_1, \dots, A_n$ mit $\sum_{i=1}^n P(A_i) = 1$ gilt für ein beliebiges Ereignis $B$

$$P(B) = \sum_{i=1}^n P(B|A_i)P(A_i) = \sum_{i=1}^n P(B, A_i) \quad \text{Marginalisierung}$$

# Theorem von Bayes

$$P(X|Y) = \frac{P(Y|X)P(X)}{P(Y)}$$

Diagram illustrating the components of Bayes' theorem:

- a posteriori** (red oval, bottom left)
- likelihood** (green oval, top center)
- a priori** (blue oval, top right)

Arrows point from the ovals to their respective terms in the formula: a red arrow from **a posteriori** to  $P(X|Y)$ , a green arrow from **likelihood** to  $P(Y|X)$ , and a blue arrow from **a priori** to  $P(X)$ .

$P(X)$  A priori Verteilung über X (Prior) (z.B. Hypothesen)


$P(Y)$  A priori Verteilung über Y (Prior) (z.B. Daten)

$P(Y|X)$  Verteilung über Y gegeben X (Likelihood)

$P(X|Y)$  Verteilung von X gegeben Y (Posterior)

# Graphen Theorie (gerichtete Graphen)

- Graph: Knoten + Kanten
- Eltern- / Kindknoten
- Nachfolger- / Vorgängerknoten
  
- Weg: Knotenfolge mit verbindenden Kanten  
(keine doppelten)
- Gerichteter Weg: Weg dessen Kanten nur in eine Richtung gehen
- Pfad: Weg ohne doppelte Knoten
- Zyklus: Gerichteter Weg mit identischem Start- und Endknoten



- Michael Jordan, 1998:


*„Graphical models are a marriage between probability theory and graph theory. [...]. Fundamental to the idea of a graphical model is the notion of modularity -- a complex system is built by combining simpler parts. Probability theory provides the glue whereby the parts are combined, ensuring that the system as a whole is consistent, and providing ways to interface models to data.“*

- Probabilistische Graphische Modelle (PGM) beschreiben Verbundwahrscheinlichkeitsverteilungen über Mengen von Zufallsvariablen
- Knoten repräsentieren Zufallsvariablen
- Graph kodiert Abhängigkeiten zwischen Zufallsvariablen

# Arten von Graphischen Modellen


## ■ Bayes'sche Netze (BN):

- Gerichteter azyklischer Graph (DAG)
- Erlaubt induzierte (bewirkende) Abhangigkeiten
- Keine zyklischen Abhangigkeiten darstellbar
- Geeignet zur Modellierung kausaler Zusammenhange
- Einfache Interpretation bedingter Wahrscheinlichkeitsverteilungen



## ■ Markov Random Field (MRF):


- Ungerichteter Graph
- Erlaubt zyklische Abhangigkeiten
- Keine induzierten Abhangigkeiten darstellbar
- Geeignet zur Modellierung von Korrelationen




- Faktorierte Darstellung einer JPD

$$P(X_1, \dots, X_n) = \prod_{i=1}^n P(X_i | X_{\text{parents}(i)})$$


- Kanten stellen direkte Abhängigkeiten dar
- Abwesenheiten von Kanten kodieren bedingte Unabhängigkeit




- Bsp.:  $P(A, B, C)$  Multiplikationssatz liefert:



$$P(A)P(B|A)P(C|B, A)$$



$$P(A)P(C|A)P(B|C, A)$$




$$P(B)P(A|B)P(C|A, B)$$

...

# Wassersprenger Szenario

$$P(W, S, R) = P(R)P(S|R)P(W|S, R)$$

RAIN	SPRINKLER	
	T	F
F	0.4	0.6
T	0.01	0.99




RAIN	GRASS WET	
	T	F
F	0.2	0.8

SPRINKLER	RAIN	GRASS WET	
		T	F
F	F	0.0	1.0
F	T	0.8	0.2
T	F	0.9	0.1
T	T	0.99	0.01

Bsp.:  $P(W = t, S = t, R = f) = 0.8 \times 0.4 \times 0.9 = 0.288$

# Inferenz und Lernen - Fragestellungen

- Gegeben Struktur + partielle Beispiele wie z.B.:  $\{ (W=t, S=t), \dots, \dots \}$
- Gesucht sind z.B. Wahrscheinlichkeitstabellen (allgemein Verteilungen)
  - Parameterlernen: Typischerweise über EM – Expectation Maximization
  - Problem: Iteratives Verfahren, benötigt in jedem Schritt Inferenz
- Was für Inferenz - Anfragen sind, wie möglich?
  - Wie geht man „effizient“ mit BN um?
- Wichtige Aspekte dabei z.B.:
  - Reduzierung auf relevante Teile des Netzes hilfreich
    - Schnelle Inferenz
    - Reduzierung von Parametern
  - Wann ist ein Netz gut aufgebaut?
  - ...



# Bedingte Unabhängigkeit

## ■ Unabhängigkeit ( $A \perp B$ ):

$$P(A, B) = P(B|A)P(A) = P(A)P(B)$$

■ Bsp: Würfeln mit zwei Würfeln

## ■ Bedingte Unabhängigkeit ( $A \perp B|C$ ):

$$P(A, B|C) = P(A|B, C)P(B|C) = P(A|C)P(B|C)$$


■ Muss für alle Belegungen entsprechender Zufallsvariablen A,B und C gelten

■ Unabhängigkeiten können beim probabilistischen Schlussfolgern (Inferenz) und Lernen ausgenutzt werden (s. F. 32 ff)


# Bedingte Unabhängigkeit in BNs

## ■ Betrachtung von 3 Fällen


- Gemeinsame Ursache
- Indirekter Effekt
- Gemeinsamer Effekt



(1) Gemeinsame Ursache



(2) Indirekter Effekt




(3) Gemeinsamer Effekt

# Fall 1: Gemeinsame Ursache

- JPD:  $P(X, Y, Z) = P(Z)P(X|Z)P(Y|Z)$

- Untersuchung ob X und Y unabhängig sind, wenn keine Variable beobachtet wird
  - Marginalisierung nach Z und Nutzung der JPD:

$$P(X, Y) = \sum_Z P(Z)P(X|Z)P(Y|Z)$$



- Faktorisiert im Allg. nicht zu  $P(X)P(Y)$ 
  - $X \not\perp\!\!\!\perp Y | \emptyset$
- Bedeutet, dass X und Y nicht bedingt unabhängig sind gegeben der leeren Menge  $\emptyset$

# Fall 1: Gemeinsame Ursache


- JPD:  $P(X, Y, Z) = P(Z)P(X|Z)P(Y|Z)$

- Untersuchung ob X und Y unabhängig sind, wenn Z beobachtet wird

- Allgemeiner Multiplikationssatz

$$\begin{aligned} P(X, Y|Z) &= \frac{P(X, Y, Z)}{P(Z)} \\ &= P(X|Z)P(Y|Z) \end{aligned}$$

- $(X \perp Y | Z)$
- X und Y sind bedingt unabhängig gegeben Z
- Wenn die gemeinsame Ursache bekannt ist, verrät X nichts über Y und umgekehrt




# Fall 2: Indirekter Effekt

- JPD:  $P(X, Y, Z) = P(X)P(Z|X)P(Y|Z)$

- Untersuchung ob X und Y unabhängig sind, wenn keine Variable beobachtet wird
  - Marginalisierung nach Z und Nutzung der JPD:

$$P(X, Y) = P(X) \sum_Z P(Z|X)P(Y|Z) = P(X)P(Y|X)$$

- Faktorisiert im Allg. nicht zu  $P(X)P(Y)$ 
  - $\Rightarrow X \not\perp\!\!\! \perp Y | \emptyset$




# Fall 2: Indirekter Effekt

■ JPD:  $P(X, Y, Z) = P(X)P(Z|X)P(Y|Z)$

■ Untersuchung ob X und Y unabhängig sind,  
wenn Z beobachtet wird

$$\begin{aligned}
 P(X, Y|Z) &= \frac{P(X, Y, Z)}{P(Z)} \\
 &= \frac{P(X)P(Z|X)P(Y|Z)}{P(Z)} \\
 &= P(X|Z)P(Y|Z)
 \end{aligned}$$

Satz von Bayes




- $(X \perp Y | Z)$
- X und Y sind bedingt unabhängig gegeben Z
- Z verrät bereits alles über die Verteilung von X und Y

# Fall 3: Gemeinsamer Effekt

- JPD:  $P(X, Y, Z) = P(X)P(Y)P(Z|X, Y)$

- Untersuchung ob X und Y unabhängig sind, wenn keine Variable beobachtet wird
  - Marginalisierung nach Z und Nutzung der JPD:

$$P(X, Y) = P(X)P(Y) \sum_Z P(Z|X, Y) = P(X)P(Y)$$




- $(X \perp Y | \emptyset)$
- Bedeutet, dass X und Y bedingt unabhängig sind gegeben der leeren Menge  $\emptyset$ , im Unterschied zu Fall 1 und 2

# Fall 3: Gemeinsamer Effekt

- JPD:  $P(X, Y, Z) = P(X)P(Y)P(Z|X, Y)$

- Untersuchung ob X und Y unabhängig sind, wenn Z beobachtet wird


$$\begin{aligned} P(X, Y|Z) &= \frac{P(X, Y, Z)}{P(Z)} \\ &= \frac{P(X)P(Y)P(Z|X, Y)}{P(Z)} \end{aligned}$$




- $(X \perp\!\!\!\perp Y|Z)$
- X und Y sind **nicht** bedingt unabhängig gegeben Z
- Da sowohl X als auch Y den beobachteten Effekt Z beeinflussen, liefert X Information über Y gegeben Z und umgekehrt
- Genau umgekehrt wie in Fall 1 und 2

# D-Separation – „Blockieren der Abhängigkeit“


- Pfad zwischen einem Knoten A und einem Knoten B ist *blockiert durch beobachtete Knoten C bzw. F*, wenn für einen Pfadknoten
  - Fall 1 oder Fall 2 vorliegt und ein Pfadknoten C bzw. F ist
  - Fall 3 vorliegt und weder ein Pfadknoten noch einer seiner Nachfolgeknoten C bzw. F ist



$$(A \not\perp B | C)$$




$$(A \perp B | F)$$



- A, B und C sind disjunkte **Knotenmengen** eines gerichteten, azyklischen Graphen (DAG)
- Pfad zwischen einem Knoten aus A und einem Knoten aus B ist *blockiert*, wenn für einen Pfadknoten
  - Fall 1 oder Fall 2 vorliegt und Pfadknoten in C enthalten ist
  - Fall 3 vorliegt und weder der Pfadknoten noch einer seiner Nachfolgeknoten in C enthalten sind
- Wenn alle Pfade zwischen Knoten aus A und B blockiert sind, dann ist A *d-separiert* von B durch C
  - Für die JPD gilt dann  $(A \perp B | C)$

# Übungsaufgabe

- Untersuche bedingte Unabhängigkeiten zwischen R (Reisegruppe) und D (Donner)



Pfade:

$$R \rightarrow L \leftarrow \underline{S} \rightarrow \underline{B} \rightarrow D$$

$$R \rightarrow L \leftarrow \underline{S} \rightarrow W \leftarrow \underline{B} \rightarrow D$$

$$R \rightarrow \underline{L} \rightarrow \underline{W} \leftarrow \underline{B} \rightarrow D$$

$$R \rightarrow \underline{L} \rightarrow \underline{W} \leftarrow \underline{S} \rightarrow \underline{B} \rightarrow D$$

Alle Pfade blockiert


$$\rightarrow (D \perp R | B, S, L)$$

→ Knoten sind unabhängig von allen Nicht-Nachfolgerknoten wenn die Elternknoten gegeben sind

→ ....

# Markov Blanket

- Minimale Menge an beobachteten Knoten, die notwendig ist um einen Knoten vom Rest des Graphen zu separieren



- Markov Blanket eines Knoten besteht aus dessen Elternknoten, Kindknoten und Elternknoten der Kindknoten
- Wichtig um effizient zu Inferieren und zu Lernen

- Zufallsvariablen (RV):  $\mathcal{X} = \{X_1, X_2, \dots, X_n\}$ 
  - Gegeben: BN und damit JPD:  $P(X_1, \dots, X_n)$
  - ggf. Evidenz: Instanziierungen der Zufallsvariablen  $E \subseteq \mathcal{X}$  mit  $e$
- Wahrscheinlichkeitsanfragen
  - Anfrage Variablen:  $X, Y \subseteq \mathcal{X}$  mit und ohne Evidenzen z.B.
    - $P(X)$  (ohne Evidenzen)
    - $P(X | Y, E=e)$  (mit Evidenzen)
    - $P(Y | E=e)$  (auch Posterior genannt)
- Maximum a-posteriori (MAP) Anfragen

$$\text{MAP}(Y|e) = \underset{y}{\operatorname{argmax}} P(y|e)$$

## ■ Inferenz ohne Evidenz (Marginalisierung)

- Gesucht:  $P(X)$
- Gegeben:  $P(X, Y)$  (JPD durch BN)



## ■ Naiver Ansatz: Theorem der totalen Wahrscheinlichkeit

$$P(X) = \int_Y P(X, Y)$$

- Erfordert Integral über alle möglichen Instanziierungen von  $Y$
- Im diskreten Fall wird das Integral durch eine Summe ersetzt

Bsp.: zwei fahrende Autos

- Variablen:
  - D: Distanz {nah, weit}
  - V: Geschwindigkeit {langsam, mittel, schnell}
  - A: Unfall {Unfall, kein Unfall}
- JPD:
$$P(A, D, V) = P(D)P(V)P(A|D, V)$$
- Mögliche Fragestellung:
  1. Verteilung der Distanzwahrscheinlichkeiten
  2. Verteilung der Geschwindigkeitswahrscheinlichkeiten
  3. Verteilung der Unfallwahrscheinlichkeiten



- Frage 1 & 2 – „trivial“  
weil D unabhängig ist von V und A  
ohne Evidenzen (bzw. V unabhängig  
ist von D und A)


- Frage 3 (Lösung über Marginalisierung):

$$\begin{aligned}
 P(A) &= \sum_d \sum_v P(d, v, A) \\
 &= \sum_d \sum_v P(d)P(v)P(A|d, v)
 \end{aligned}$$

Ergebnis:

	accident	no accident
P(A)	0.2	0.8

	P(D)		P(V)		
P(D)	close	far	P(V)	slow	average
P(D)	0.3	0.7	P(V)	0.2	0.5



D	V	accident	no accident
close	slow	0.2	0.8
close	average	0.3	0.7
close	fast	0.8	0.2
far	slow	0.0	1.0
far	average	0.1	0.9
far	fast	0.2	0.8

## ■ Inferenz mit Evidenz

- Gesucht:  $P(X|E=e)$
- Gegeben:  $P(X, Y, E)$  durch BN und Evidenz  $e$

## ■ Naiver Ansatz: Theorem der totalen Wahrscheinlichkeit zusammen mit Multiplikationssatz

$$P(X|e) = \int_Y P(X, Y|e) = \int_Y \frac{P(X, Y, e)}{P(e)}$$

- Aufwand wie vorher nur zusätzliche Normalisierung notwendig

## Frage 1: $P(\text{intelligent} | \text{college})$

$$P(\text{int.} | \text{college}) = \sum_s \frac{P(\text{int.}, s, \text{college})}{P(\text{college})}$$


$$\approx \frac{0,52}{0,72} \approx 0,71$$

## Frage 2: $P(\text{intelligent} | \text{sportlich}, \text{college})$

$$P(\text{int.} | \text{college, sport.}) = \frac{P(\text{int.}, \text{sport.}, \text{college})}{P(\text{college, sport.})}$$

$$\approx \frac{0,32}{0,52} \approx 0,63$$

	sportlich	nicht sportlich
P(S)	0,6	0,4
	intelligent	nicht intelligent
P(I)	0,6	0,4



I	S	college	kein college
intelligent	sportlich	0,9	0,1
intelligent	nicht sportlich	0,8	0,2
nicht intelligent	sportlich	0,8	0,2
nicht intelligent	nicht sportlich	0,1	0,9


# Explaining Away

## ■ Ergebnisse der Inferenz:

$$P(\text{intelligent} | \text{college}) \approx 0.71$$

$$P(\text{intelligent} | \text{sportlich, college}) \approx 0.63$$

- Die Beobachtung, dass jmd. auf ein College geht und er sportlich ist, lässt diesen automatisch weniger intelligent erscheinen
- Die Beobachtung einer Ursache, die ausreicht um einen Effekt zu erklären, lässt andere mögliche Ursachen automatisch unwahrscheinlicher werden
  - Die Beobachtung des gemeinsamen Effekts macht die Ursachen bedingt abhängig (Fall 3)
- Kommt häufig in der Realität vor (z.B. Medizin)



# Naive Bayes revisited

- Klassifikation  $C$  anhand von Attributen  $X_1, X_2, \dots, X_n$

- Naive Bayes Annahme:


- Alle Attribute sind untereinander unabhängig gegeben  $C$ , d.h.

$$\forall i : (X_i \perp \!\!\! \perp \mathbf{X}_{\{1\dots n\} \setminus i} \mid C)$$

- Vereinfachte Formel:



$$P(C|X_1, \dots, X_n) \propto P(C)P(X_1, \dots, X_n|C) = P(C) \prod_{i=1}^n P(X_i|C)$$

- Bayes'sches Netz:




# Kausalität in BNs

- Multiplikationssatz erlaubt beliebige Faktorisierungen
- Beziehungen in BNs müssen nicht kausal im Sinne Klasse → Merkmal sein!
- Vorteile kausaler BNs:
  - i.d.R. weniger Kanten
  - i.d.R. einfachere Modelle (weniger Parameter → besser lernbar)
- Bsp.: Modellierung einer digitalen Anzeige



Kausal 😊



Nicht kausal 😥

# Inferenz in BNs - Komplexität

## ■ Schlechte Nachricht

- Exakte Inferenz in allgemeinen BNs ist NP-hart
- Approximative Inferenz in allgemeinen BNs ist NP-hart

## ■ Gute Nachricht


- Dies betrifft nur den Worst-Case
- Inferenzkomplexität in realen BNs oft nur linear oder polynomiell

## ■ Bsp. Exakte Inferenz mit diskreten Zufallsvariablen $A, B, C, D$

$$P(D) = \sum_a \sum_b \sum_c P(a, b, c, D)$$

- Exponentieller Aufwand  $O(k^n)$  bei  $n$  Zufallsvariablen mit  $k$  Werten

- Geht oft besser, wenn wir die Struktur des BNs ausnutzen
- Angenommen BN ist ein Kettengraph
- Ohne Struktur („naiver“ Ansatz)



$$\begin{aligned} P(D) &= \sum_a \sum_b \sum_c P(a, b, c, D) \\ &= \sum_a \sum_b \sum_c P(a)P(b|a)P(c|b)P(D|c) & O(k^n) \\ &= \sum_c P(D|c) \sum_b P(c|b) \sum_a P(a)P(b|a) \end{aligned}$$

- Aufwandsvergleich bei Nutzung der Struktur




- Einzelschritt  $P(X_{i+1}) = \sum_{x_i} P(X_{i+1}|x_i)P(x_i)$  hat den Aufwand  $O(k^2)$
- Gesamt:  $O(nk^2)$
- Linearer Aufwand im Gegensatz zu exponentiellem

- Verfahren lässt sich verallgemeinern
  - Variable Elimination
  - Conditioning
  - Belief Propagation
- Weiterer Effizienzgewinn durch dynamische Programmierung
- Approximative Inferenzverfahren
  - Loopy Belief Propagation
  - Importance Sampling (z.B. Likelihood Weighting)
  - Markov-Chain Monte Carlo Verfahren (z.B. Gibbs Sampling)

- Jede JPD ist ein generatives Modell, das es erlaubt Stichproben zu ziehen
- Viele Anwendungsgebiete
  - Approximative Inferenz
  - Visualisierung
  - Etc.
- Viele Verfahren existieren
- Oft ist es schwierig direkt aus der JPD zu ziehen, aber einfach Stichproben aus den Faktoren zu erzeugen

# Generatives Modell - Ancestral Sampling

- Ancestral Sampling:
  - Knoten des BN topologisch sortieren
  - Werte für Prior-Knoten ziehen
  - Werte für bedingte Knoten anhand der Vorgängerwerte ziehen
- Auch zum Samplen marginaler Verteilungen geeignet
- Bsp.: Stichproben aus einer Gauß-Mixtur erzeugen



# Dynamische Bayes'sche Netze



Forschungszentrum Karlsruhe  
in der Helmholtz-Gemeinschaft



Universität Karlsruhe (TH)  
Forschungsuniversität • gegründet 1825

## ■ Motivation

- Gesucht: Position und Geschwindigkeit eines Fahrzeugs (Zustand)
- Gegeben
  - Verrauschte Messungen
  - Vorwissen wie sich Fahrzeuge bewegen können

## ■ Modellierung als BN


- Zustand ändert sich über der Zeit
- Verwendung von Zufallsvariablen zur Beschreibung der Fahrzeugzustände zu bestimmten Zeitpunkten

$$P(X_0, X_1, \dots, X_T)$$

# Dynamische Bayes'sche Netze

- Dynamische Bayes'sche Netze (DBNs) sind BNs zur Beschreibung dynamischer Prozesse
- Eigenschaften
  - Zustandsraum: Menge aller möglichen Systemzustände
  - Diskrete Zeitschritte zwischen Zustandsübergängen
  - Markov'sche Annahme: Zukünftige Zustände unabhängig von vergangenen Zuständen gegeben den aktuellen Zustand

$$\begin{aligned}
 & (X_{t+1} \perp X_{t-1}, \dots, X_0 \mid X_t) \\
 \Rightarrow P(X_0, X_1, \dots, X_T) &= P(X_0) \prod_{t=0}^{T-1} P(X_{t+1} \mid X_t)
 \end{aligned}$$




# Dynamische Bayes'sche Netze

## ■ Beschreibung


- Prior  $P(X_0)$  : Initiale Verteilung über den Zustand
- Prozessmodell  $P(X_t|X_{t-1})$ : Bedingte Wahrscheinlichkeitsverteilung zur Beschreibung der Systemübergänge (Transitionsmodell)

## ■ Zeitscheiben sind BN und definieren DBN

## ■ DBN kann viele Knoten haben




- Gegeben: Evidenzen bis zum Zeitpunkt  $t$
- Gesucht: Verteilung über Zustand zu einem Zeitpunkt  $t'$
- Varianten (je nach  $t'$ ):



# Filterverfahren im Überblick


## ■ Unterscheidungsmerkmale

- Zustandsraum (diskret, kontinuierlich, hybrid)
- Modelle (linear z.B.  $x_{t+1} = Ax_t + e_t$ , nicht-linear)
- Verteilungen und Inferenzverfahren




## ■ DBN mit Eigenschaften

- Zustandsraum: Systemzustand + Messung
- Modelle: linear/nicht-linear (Markov 1. Ordnung)
- Verteilungen und Inferenzverfahren: beliebig
- Graphstruktur (Baum) ermöglicht effiziente Inferenzverfahren



# Bayes Filter


- **Transitionsmodell**  $P(X_t|X_{t-1})$ :
  - Beschreibt den Übergang des System von einem Zeitpunkt zum nächsten
- **Messmodell**  $P(Z_t|X_t)$ :
  - Beschreibt, welche Messungen ein Systemzustand zur Folge haben kann
- **Markov'sche Annahme**
  - Gültig für die Zustände  $X$



# Bayes Filter - Anfragen


## ■ Filtern

$$P(X_t | Z_t, \dots, Z_0)$$




## ■ Prädizieren

$$P(X_{t+k} | Z_t, \dots, Z_0)$$



## ■ Glätten

$$P(X_{t-k} | Z_t, \dots, Z_0)$$



## ■ Eigenschaften

- Erfordert Verteilungen, die vollständig über die ersten beiden Momente (Erwartungswert und Kovarianz) beschrieben werden können (i.d.R. Normalverteilungen)
- Modelle: Linear + additives, weißes Rauschen
- Unimodalität der Verteilungen und Linearitätsannahme der Modelle sehr restriktiv
- Wird in der Realität dennoch sehr häufig eingesetzt

## ■ Erweiterungen für nicht-lineare Modelle

- Extended Kalman Filter
- Unscented Kalman Filter

# Kalman Filter

- Bsp.: Fahrzeugverfolgung

- Zustand:

- Position  $x_1, x_2$
- Geschwindigkeit  $v_1, v_2$

$$x = \begin{pmatrix} x_1 \\ x_2 \\ v_1 \\ v_2 \end{pmatrix}$$

- Transitionsmodell:

- Berechnet Folgeposition mit Unsicherheiten


$$x_{t+1} = Ax_t + e_t = \begin{pmatrix} 1 & 0 & \Delta t & 0 \\ 0 & 1 & 0 & \Delta t \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} x_{1t} \\ x_{2t} \\ v_{1t} \\ v_{2t} \end{pmatrix} + e_t$$

- Messmodell:

- Gemessen werden verrauschte Positionen (weißes Rauschen)

$$z_t = Ax_t + e_{zt} = \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \end{pmatrix} \begin{pmatrix} x_{1t} \\ x_{2t} \\ v_{1t} \\ v_{2t} \end{pmatrix} + e_{zt}$$

## ■ Bsp.: Fahrzeugverfolgung




## ■ Eigenschaften

- Zustandsraum: diskret
- Modelle: bedingte Wahrscheinlichkeitstabellen
- Verteilungen: Wahrscheinlichkeitstabellen
- Transitionsmodell kann über endlichen Automaten dargestellt werden, dessen Kanten mit Wahrscheinlichkeiten annotiert sind

## ■ Erweiterungen

- kontinuierlichen Messungen
- Hierarchische HMMs
- Coupled HMMs




## ■ Eigenschaften

- Zustandsraum: diskret/kontinuierlich/hybrid
- Modelle: linear/nicht-linear
- Verteilungen: Partikelverteilungen (Dirac Mixturen), Multimodal
- Inferenz: und partikelbasierte Inferenzverfahren (z.B. Likelihood Weighting)


## ■ Erweiterungen

- Rao-Blackwellized Partikel Filter (gemischt exakt-approximativ)

# Partikel Filter - Video



# Anwendung: Situationsanalyse und Prädiktion im Straßenverkehr



[Gindele et al., ITS Magazine 2015]

# Situationsanalyse und Prädiktion

$$P(X|z, X^-) \propto P(z|X) \int_{X^-, L^-, LR^-, R^-, A^-} P(X, X^-, L^-, LR^-, R^-, A^-)$$

$P(Z|X)$  – Measurement

$P(R|X)$  – Trafic. Part. Relations

$P(L|X)$  – Lane Matching

$P(L_{i+1}|L_i)$  – Lane Following

$P(LR|X, L)$  – Lane Relations

$P(X^{(t+1)}|X^{(t)}, A^{(t)})$  – Motion

$P(A|X, R, LC)$  – Policy Modell

Lernen aus Daten möglich  
z.B. mit Monte Carlo - EM

Perzeption, Wissen

$$X = (X_1 \dots X_n), X_i = (\vec{x}, w, v)$$



$$Z = (Z_1 \dots Z_n)$$

$$R = \{R_{i,j}\}, R_{i,j} = \Delta X_{ij}$$


$$L = (L_{1,1:m} \dots L_{n,1:m})$$

$$LR = (LR_{1,1:m} \dots LR_{n,1:m})$$

$$A = (A_1 \dots A_n), A_i = (w, a)$$




$$P(X_1 \dots X_n | z, X_1^- \dots X_n^-)$$



Inferierte Situationsaussage  
[Ginckel et al., ITS Magazine 2015]

# Situationsanalyse und Prädiktion



model	pos rmse ( $\Delta t: 0.3$ s)	pos rmse ( $\Delta t: 6.0$ s)	mll
learned model	0.19 m	6.48 m	2.032
single track model	0.28 m	12.83 m	0.988

[Gindele et al., ITS Magazine 2015]

- Probabilistische Graphische Modelle kodieren JPDs inklusive bedingter Unabhängigkeiten zwischen Zufallsvariablen
- Bedingte Unabhängigkeiten ermöglichen effiziente Inferenzverfahren, einfachere Modelle und damit effizienteres Lernen
- DBNs erweitern BNs um den Aspekt der Zeit
- DBNs eignen sich hervorragend, um nicht beobachtbare Zustände von dynamischen Systemen zu schätzen
  
- Ausblick:
  - Lernen der Struktur und Modelle von BNs und DBNs

- [1] D. Koller and N. Friedman. ***Probabilistic graphical models: principles and techniques***. The MIT Press, 2009.
- [2] C. Bishop. ***Pattern recognition and machine learning***, volume 4. Springer New York, 2006.
- [3] K. Murphy. ***Dynamic Bayesian Networks: Representation, Inference and Learning***. PhD thesis, University of California, 2002.
- [4] J. Pearl. ***Probabilistic reasoning in intelligent systems: networks of plausible inference***. Morgan Kaufmann, 1988.
- [5] S. Srihari. ***Machine Learning and Probabilistic Graphical Models Course***. Vorlesungsfolien, Department of Computer Science and Engineering, University at Buffalo, 2011.
- [5] T. Gindele, S. Brechtel. ***Learning Driver Behavior Models from Traffic Observations for Decision Making and Planning***. IEEE Intelligent Transportation Systems Magazine, Vol. 7, pp. 69-79.