Maschinelles Lernen I -
WDH – ML I – Neuronale Netze

Sommersemester 2017

Prof. Dr. J.M. Zöllner, Prof. Dr. R. Dillmann, Darius Azarfar, Peter Wolf

„Not the neural devices themselves contain the secret of thought. It is, rather, the organizing principle by which vast numbers of these elementary devices work in concert. Neural computation is an emergent property of the system.“

Carver Mead (1989)
Professor am California Institute of Technology (CalTech) forderte 1968 alle gängigen Überzeugungen heraus, indem er berechnete, wie klein ein funktionierender Transistor sein könnte. (0,15 Micron)

INSTITUT FÜR ANGEWANDTE INFORMATIK UND FORMALE BESCHREIBUNGSVERFAHREN
INSTITUT FÜR ANTHROPOMATIK UND ROBOTIK

Ein biologischen Vorbild

- Der Mensch, sein Gehirn:
  - Neuron Schaltzeit: > 0.001 sec
  - Anzahl Neuronen: 10^{10}
  - Verbindungen (Synapsen) pro Neuron: 10^4-10^5
  - Szenenerkennung: 0.1 sec

  - hochparallele Berechnung
  - verteilte Repräsentation von Wissen

Vergleich zw. Gehirn und seriellem Rechner

Eigenschaft	Parallelität	Präzision	Fehlertoleranz	Speicherzugriff	Erkennen v. Mustern u. Ähnlichkeiten
Gehirn	hoch	mäßig	hoch	global	gut
ser. Rechner	noch mäßig	hoch	niedrig	lokal	mäßig

Eigenschaft	Numerische präzise Be-rechnungen	Fehlerloses Speichern v. Daten	Rekonstrukt. teilw. zerst. Daten	Verallgem. v. Bsp. auf implizite Regeln	Selbstorganisation
Gehirn	schlecht	schlecht	gut	gut	ja
ser. Rechner	gut	gut	schlecht	schlecht	bisher nicht

„Konnektionistische“ Verfahren

Künstliche Neuronale Netze (*KNN*) - Nachbildung des Gehirns ?

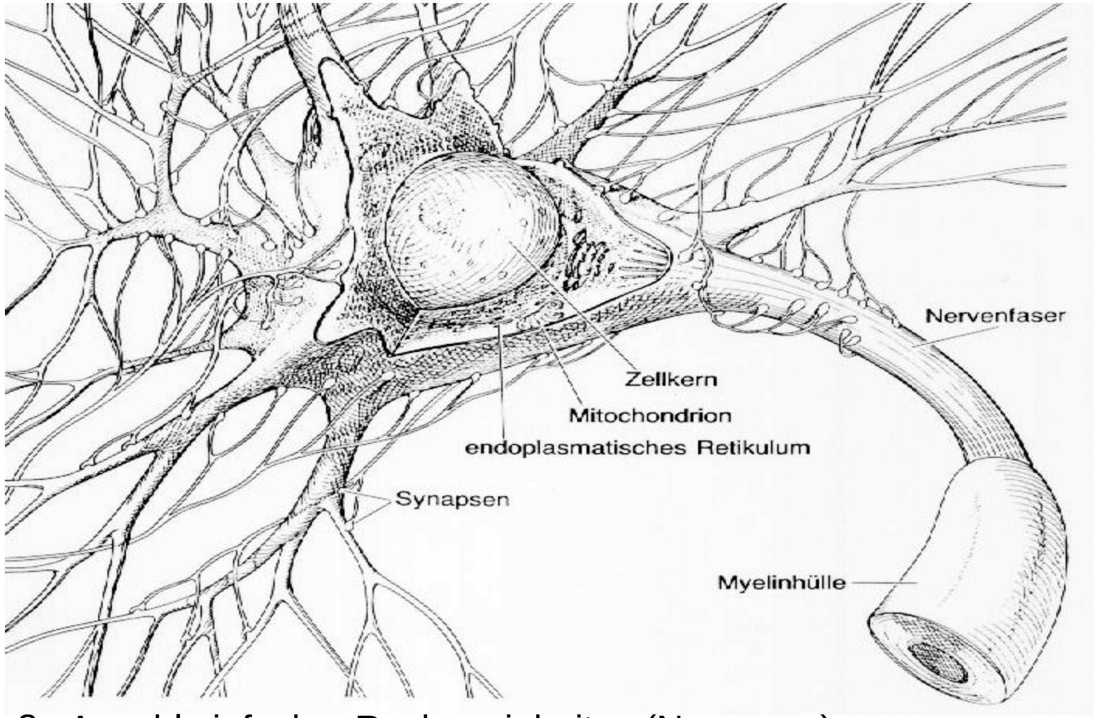

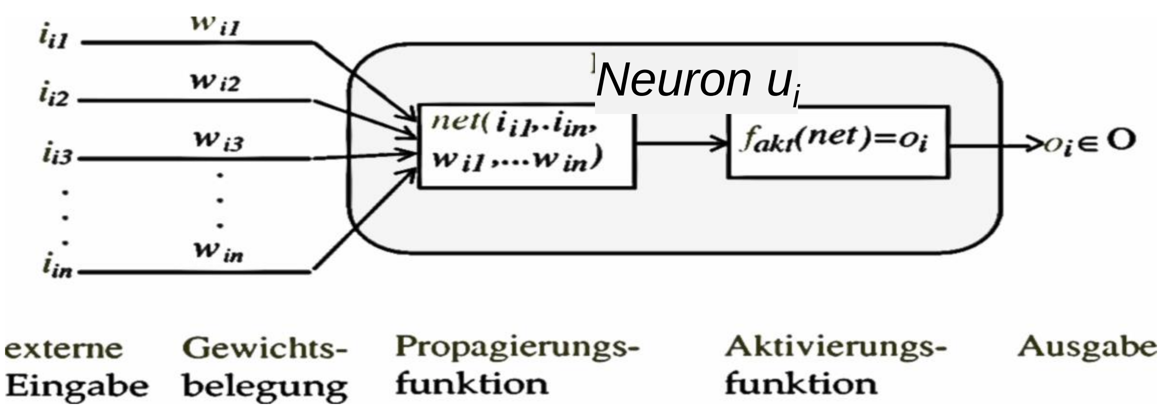

Große Anzahl einfacher Recheneinheiten (Neuronen)
Durch gewichtete Kanäle verbunden (Netz)
Kein Rechnen mit symbolisch kodierten Nachrichten
Wissen in der Struktur/Verbindungen repräsentiert

Gemeinsame Eigenschaften:

- Parallele Informationsverarbeitung
- Lernfähigkeit
- Generalisierungsfähigkeit
- Fehlertoleranz

Motivation - Problemstellungen

Entscheidungsregionen (Raumaufteilung),
Clustering, Regression, Sequenzen, ...

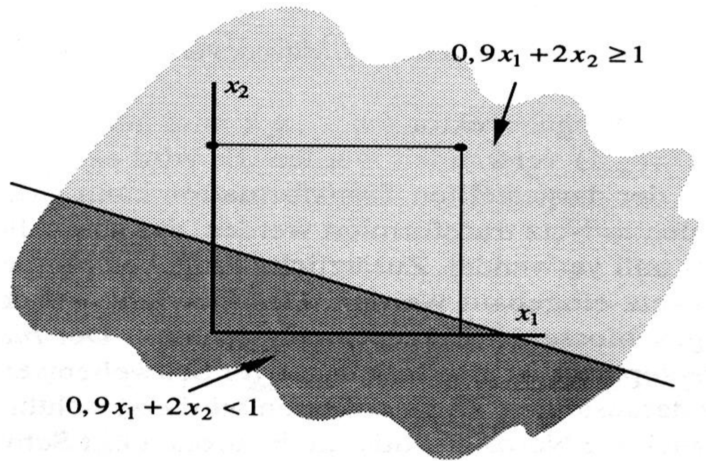

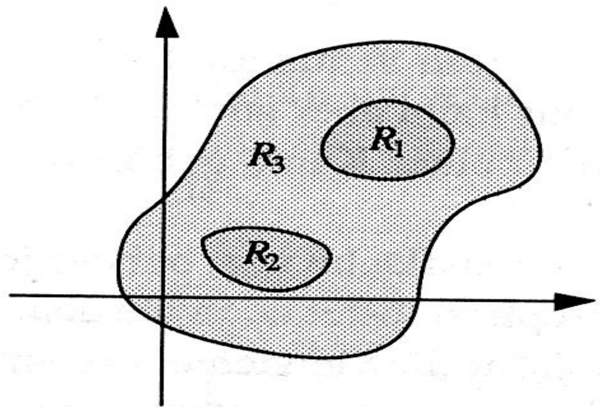

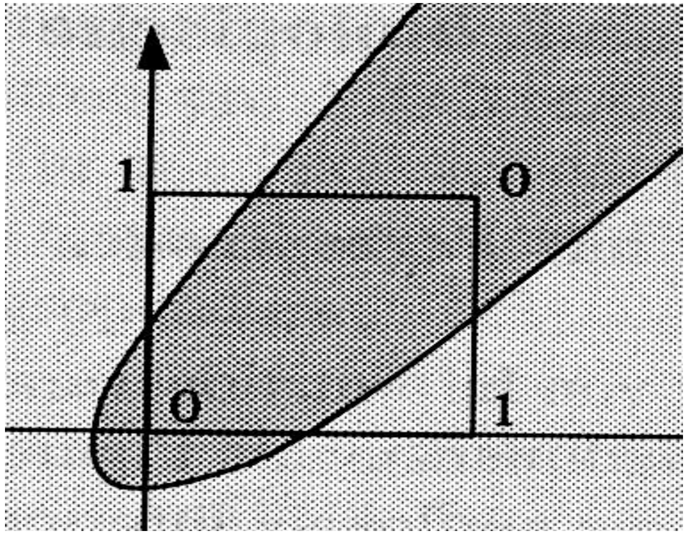

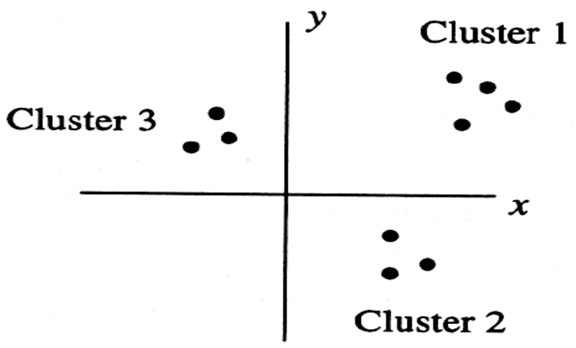

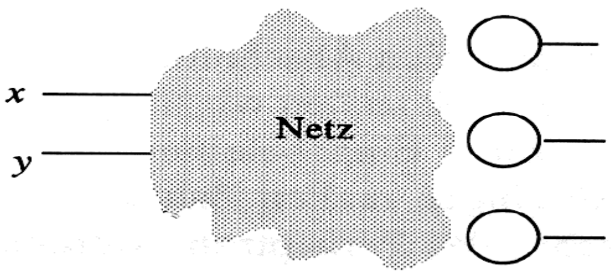

Typische Einsatzfelder künstlicher Neuronaler Netze

- Klassifikation und Mustererkennung
  - Diagnose, Spracherkennung, Schrifterkennung
- Funktionsapproximierung / Regression
  - Kontinuierliche Abbildung
  - Steuerung
  - Vorhersage
- Mustervervollständigung
  - Bilderkennung
  - Kodierung
- etc...

Frühe Realisierung: Perzeptron

- Grundidee
- Aufbau
- Lernverfahren
- Geometrische Interpretation

Perzeptron [Rosenblatt 1960]

Grundidee:
Anlehnung an das Funktionsprinzip der natürlichen Wahrnehmung – Reaktion im Tierbereich

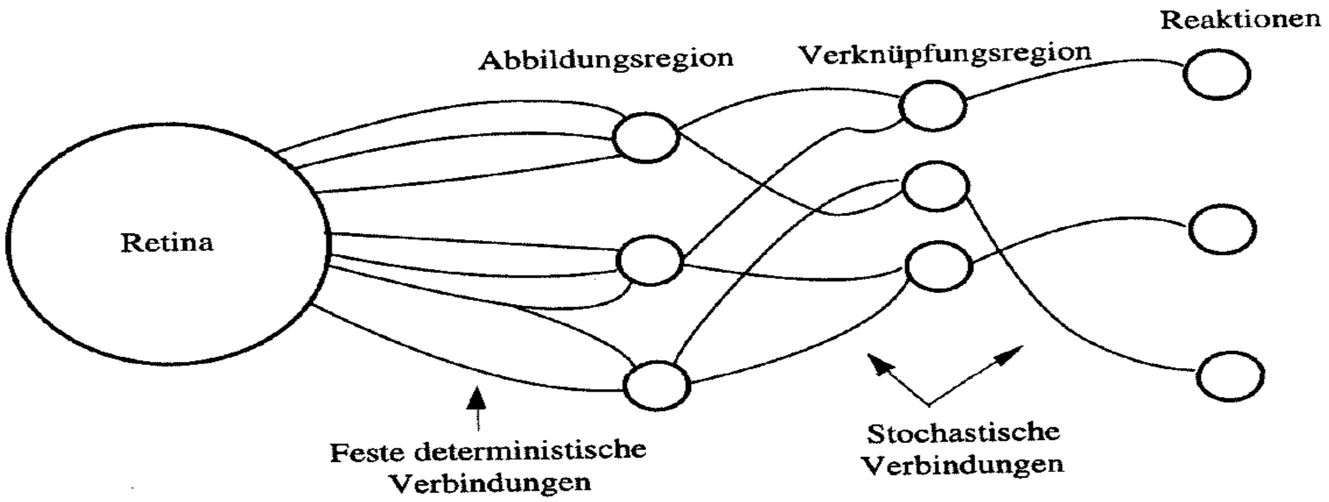

Perzeptron

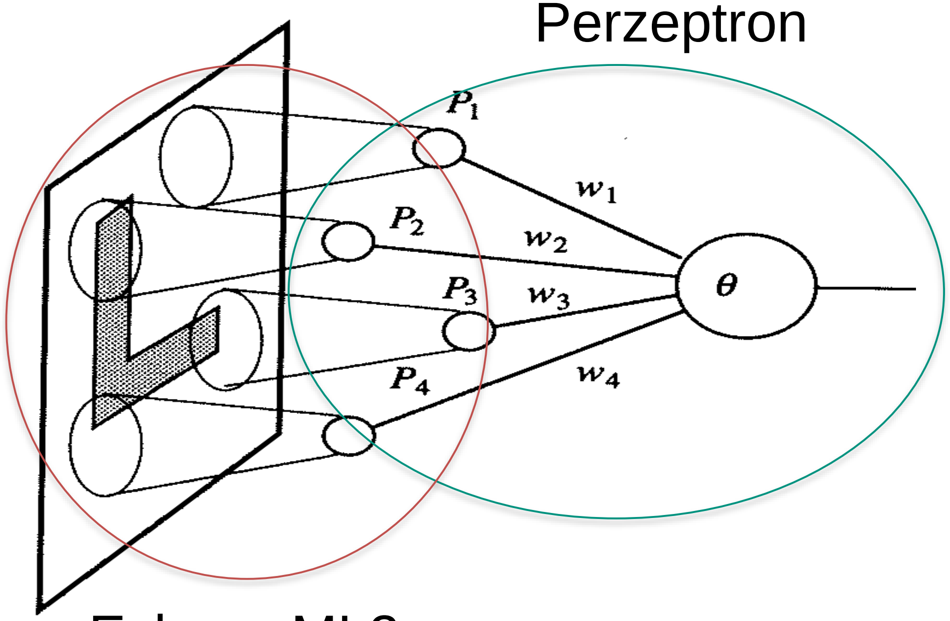

Exkurs: ML2
Deep Learning

Perzeptron [Rosenblatt 1960]

Aufbau eines Perzeptrons:

x – Eingabevektor

t – Target (Soll-Ausgabe)

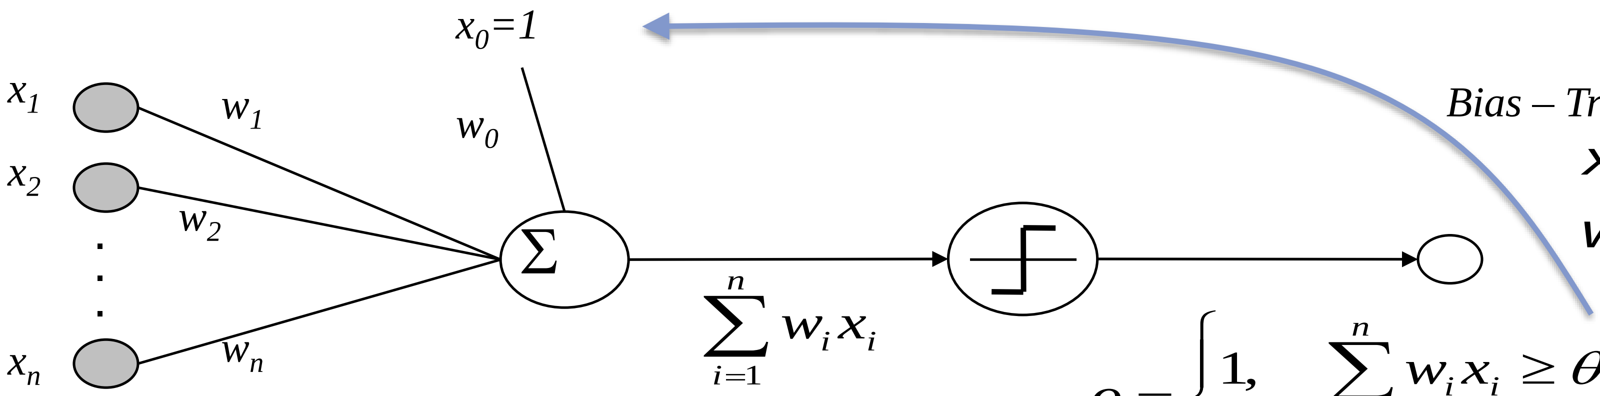

Bias – Trick

$$x_0 = 1$$

$$w_0 = -q$$

$$o = \begin{cases} 1, & \sum_{i=1}^{n} w_i x_i \geq \theta \\ -1, & sonst \end{cases}$$

w – Gewichtsvektor

o – Output (Ist-Ausgabe)

Perzeptron: Geometrische Interpretation

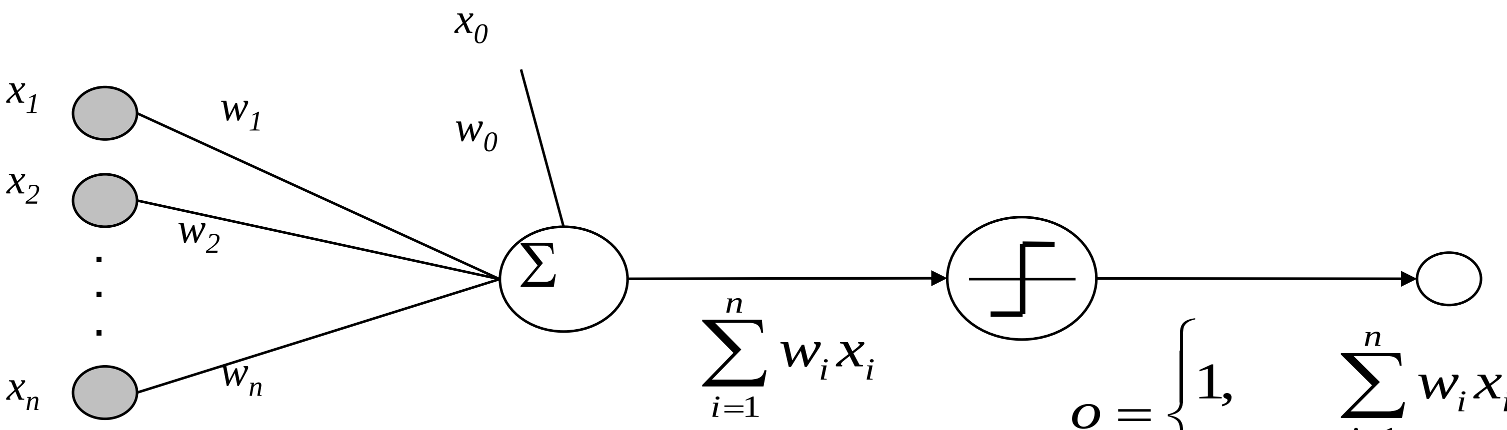

$$o = \begin{cases} 1, & \sum_{i=1}^{n} w_i x_i \geq 0 \\ -1, & sonst \end{cases}$$

„Positive und Negative“ Daten (P,N)
Erweiterung der Dimension durch x_0
Trennhyperebene (R^2: Gerade)
Gewichte definieren diese Ebene (Normale)
Entscheidung, gewichtete Summe → Skalarprodukt

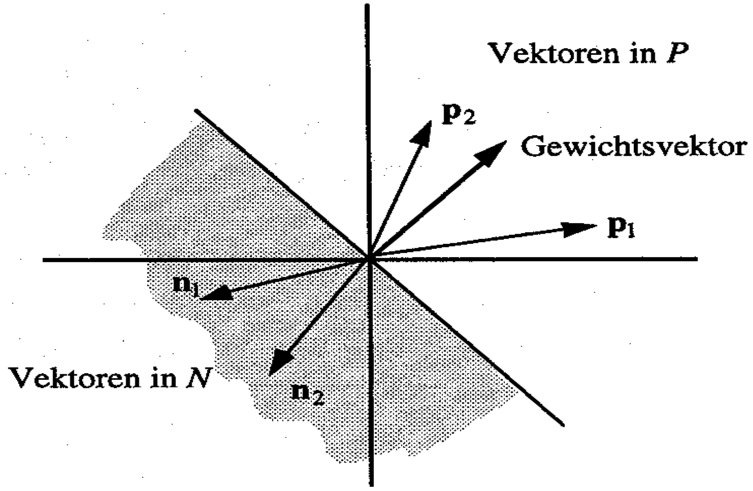

Lernen = Anpassen der Gewichte

➔ Gesucht wird die beste Trennhyperebene

Lernen - Geometrische Interpretation

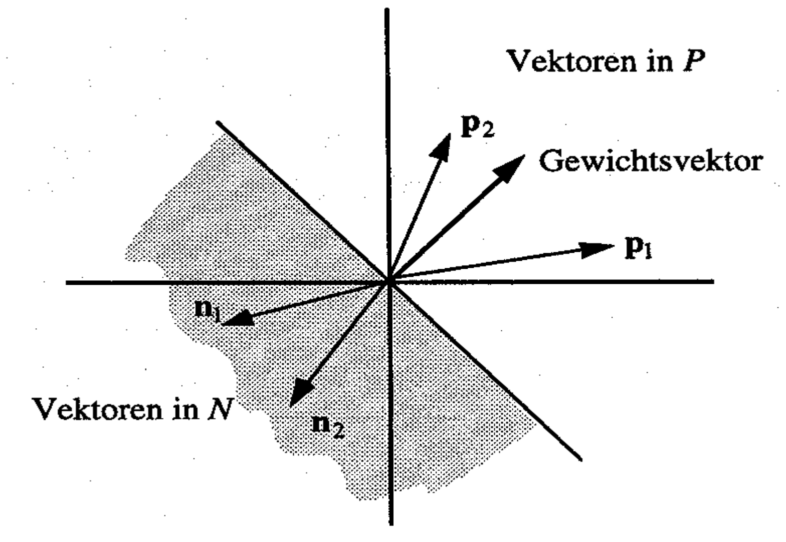

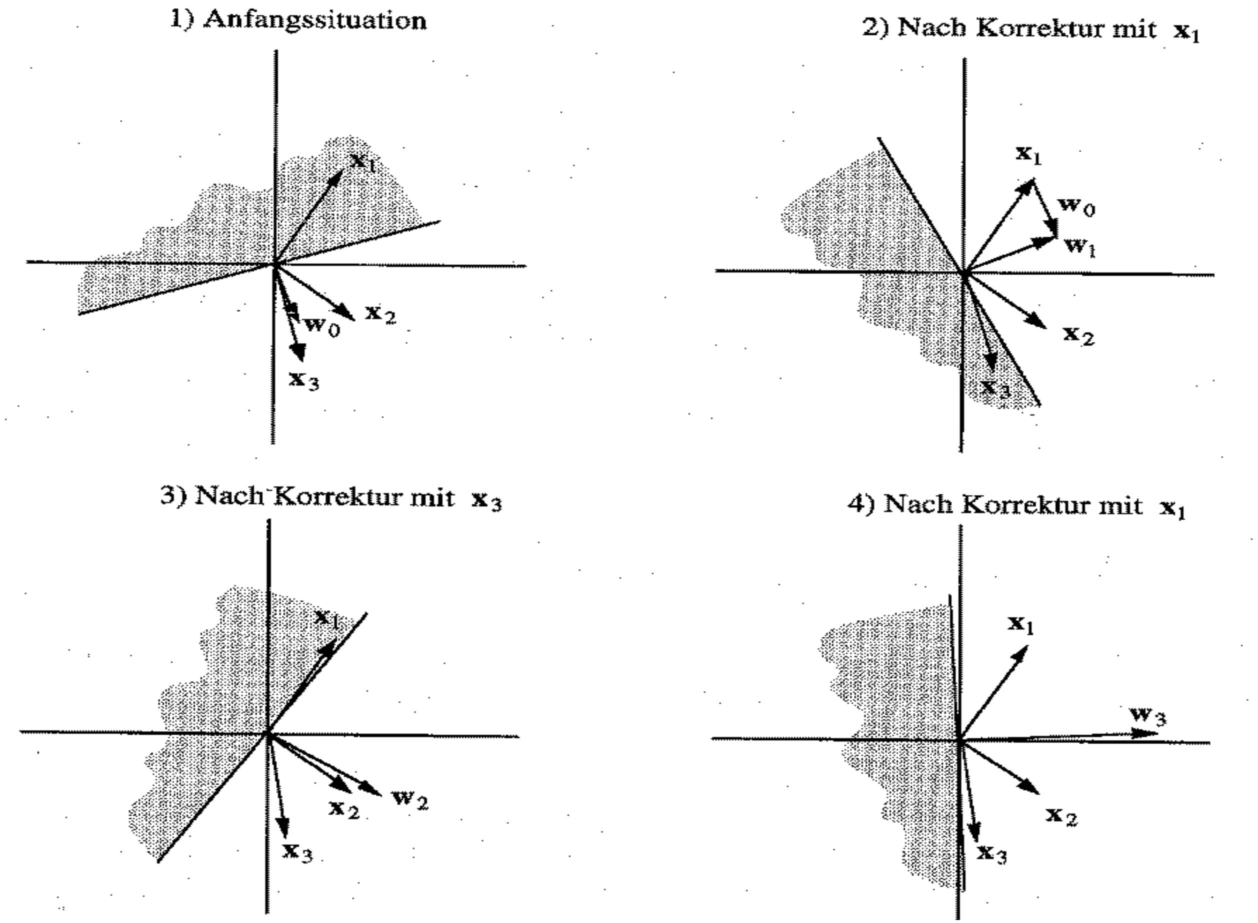

Hilfsmenge

$$N' = \{ x' \mid x' = -x, \forall x \in N \}$$

Neues Lernproblem

$$xw > 0 \quad , \forall x \in N' \cup P$$

➔ Im Beispiel: alle x_i aus P

Perzeptron – Lernalgorithmus

Start: Gegeben Lerndatenmenge $P \cup N$
Der Gewichtsvektor $w(0)$ wird zufällig generiert.
Setze $t{:=}0$.

Testen: Ein Punkt x in $P \cup N$ wird zufällig gewählt.
Falls $x \in P$ und $w(t) \cdot x > 0$ gehe zu *Testen*
Falls $x \in P$ und $w(t) \cdot x \leq 0$ gehe zu *Addieren*
Falls $x \in N$ und $w(t) \cdot x < 0$ gehe zu *Testen*
Falls $x \in N$ und $w(t) \cdot x \geq 0$ gehe zu *Subtrahieren*

Addieren: Setze $w(t+1) = w(t)+x$.
Setze $t{:=}\ t+1$. Gehe zu *Testen.*

Subtrahieren: Setze $w(t+1) = w(t)-x$.
Setze $t{:=}t+1$. Gehe zu *Testen*.

Multi Layer Feedforward Neural Network

- Motivation
  - Grenzen des Perzeptrons
- Aufbau des MLNN
  - MLNN - Neuronen
  - Lernverfahren:
    - Backpropagation (allgemeine Deltaregel)
- Aufbau des RBF Netzes
  - Neuronen
  - Lernen
- Probleme / Optimierungen
  - Gradientenabstieg (z.B. RPROP)
  - Konstruktive Verfahren (DDA, Cascade Correlation)

Perzeptron Lernalgorithmus

- $|w| >> |x|$

  Sehr langsame Anpassung

  ➔ Normierung

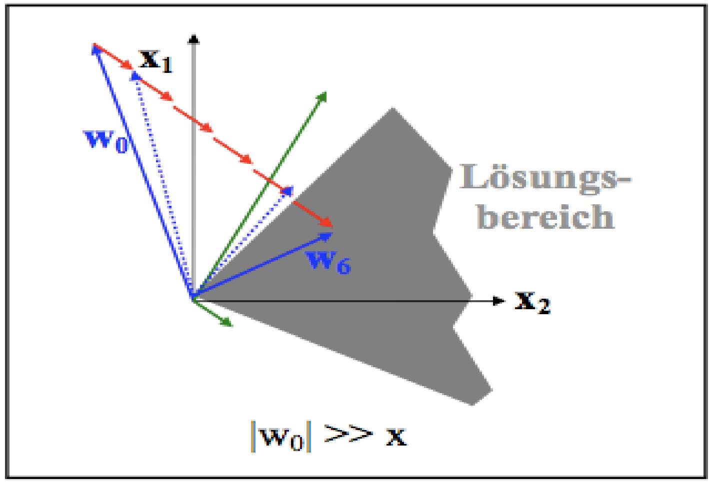

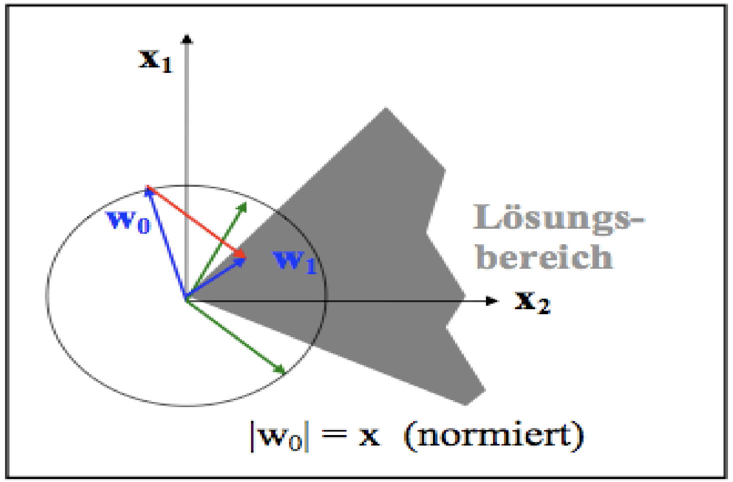

- Worst case:
- Fast anti-parallele
- Vektoren

➔ Gradientenabstieg
Delta-Regel
(idealerweise mit Optimierung)

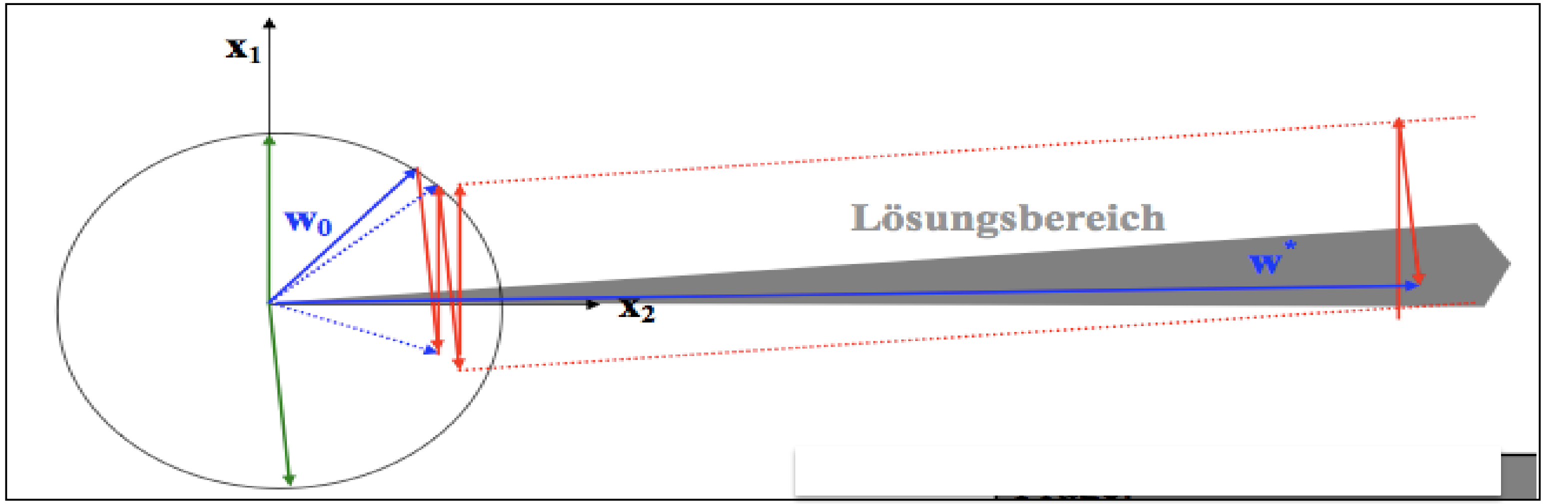

Perzeptron [Rosenblatt 1960]

Aufbau eines Perzeptrons:

x – Eingabevektor $\quad$ t – Target (Soll-Ausgabe)

Aktivierungsfunktion
➔ differenzierbar machen

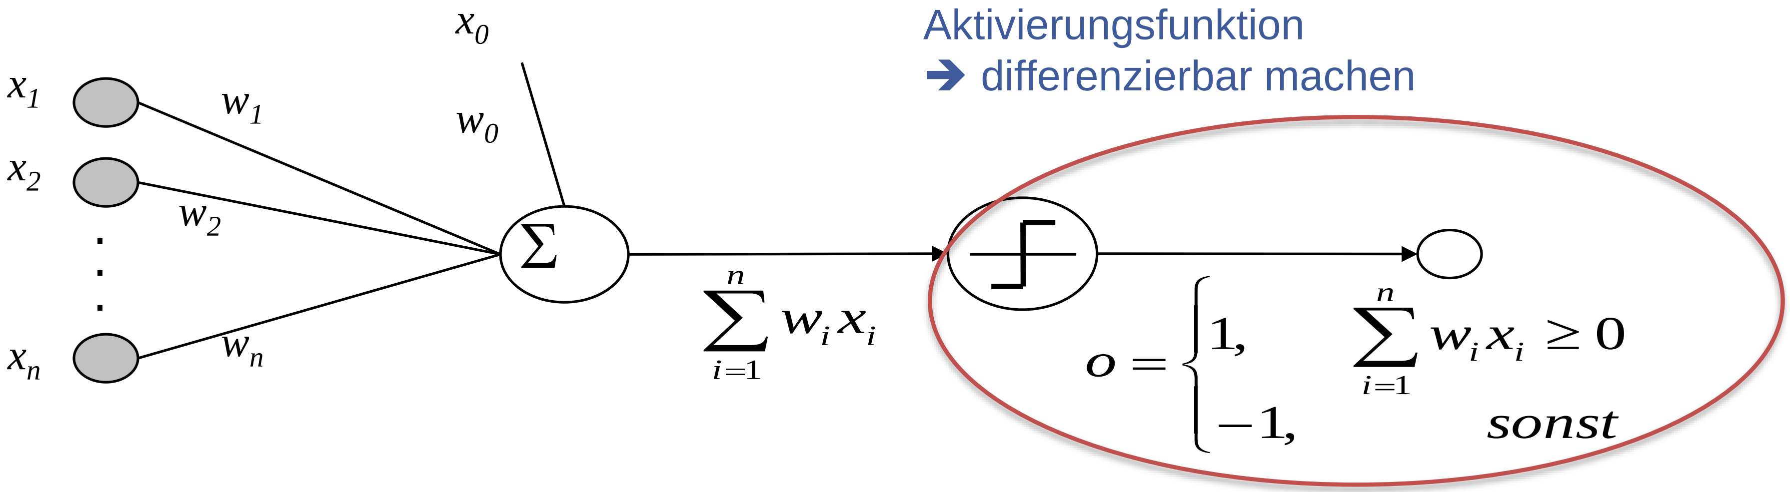

w – Gewichtsvektor $\quad$ o – Output (Ist-Ausgabe)

Gradientenabstieg - Fehlerfunktion

Fehlerfunktion

$$E(\vec{w}) = \frac{1}{2|D|}\sum_{d \in D}(t_d - o_d)^2$$

D – Lerndaten

Lernen: Minimieren von E

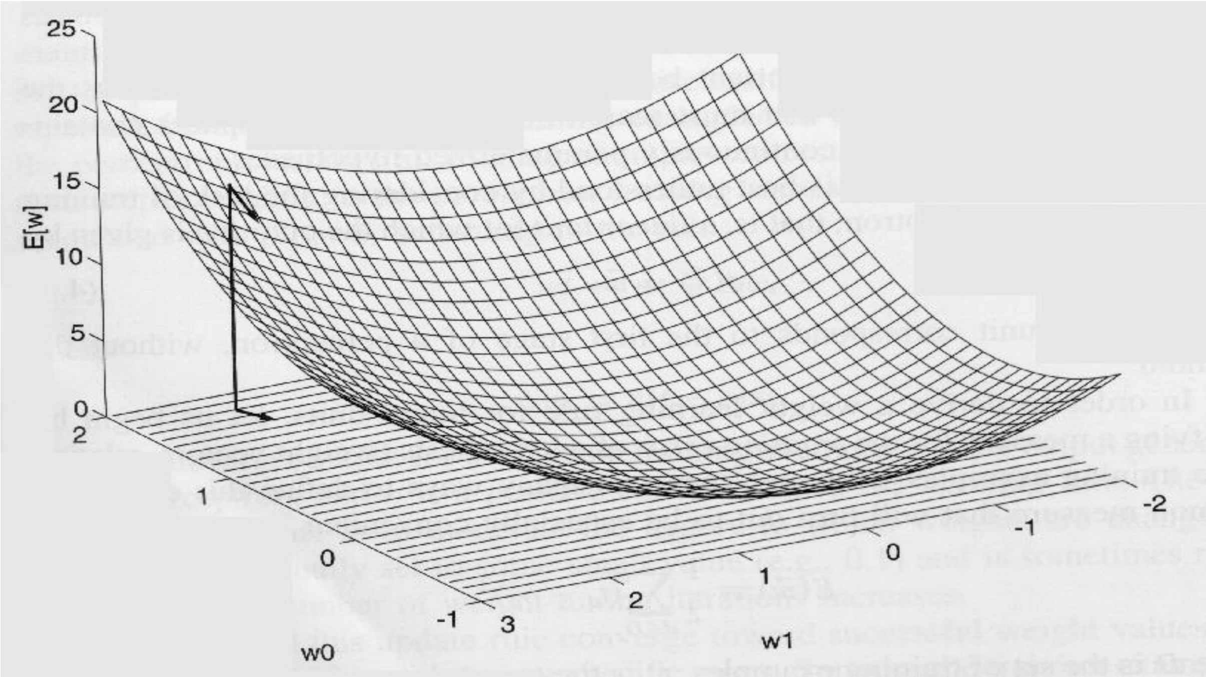

Gradient

$$\nabla E(w) \equiv \left[\frac{\partial E}{\partial w_0}, \frac{\partial E}{\partial w_1}, \ldots, \frac{\partial E}{\partial w_n}\right]$$

Anpassung des Gewichtsvektors

$$\vec{w} \leftarrow \vec{w} + \Delta\vec{w}$$
$$\Delta\vec{w} = -\eta \nabla E(\vec{w})$$

Lernrate η

oder

$$w_i \leftarrow w_i + \Delta w_i$$
$$\Delta w_i = -\eta \frac{\partial E}{\partial w_i}$$

Gradientenabstieg - Deltaregel

$$\frac{\partial E}{\partial w_i} \cong \frac{\partial}{\partial w_i} \frac{1}{2} \sum_{d \in D} (t_d - o_d)^2$$

$$= \frac{1}{2} \sum_{d \in D} \frac{\partial}{\partial w_i} (t_d - o_d)^2$$

$$= \frac{1}{2} \sum_{d \in D} 2 (t_d - o_d) \frac{\partial}{\partial w_i} (t_d - o_d)$$

$$= \sum_{d \in D} (t_d - o_d) \frac{\partial}{\partial w_i} (t_d - \vec{w} \cdot \vec{x}_d)$$

Aktivierungsfunktion
muss differenzierbar sein !!
z.B.

$$o(\vec{x}) = \sum \vec{w} \cdot \vec{x}$$

$$\frac{\partial E}{\partial w_i} \cong \sum_{d \in D} (t_d - o_d)(-x_{id})$$

$$\Delta w_i = \eta \sum_{d \in D} (t_d - o_d) x_{id}$$

Perzeptron Kapazität

Bsp. Logik:

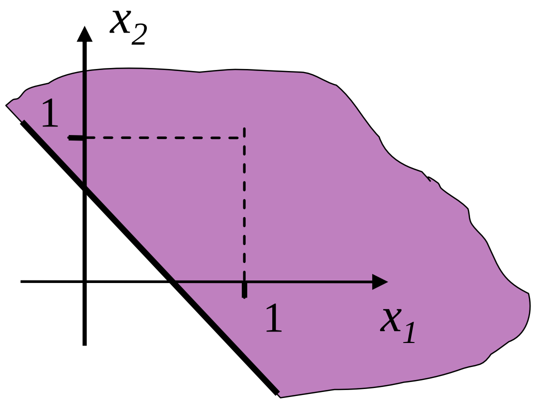

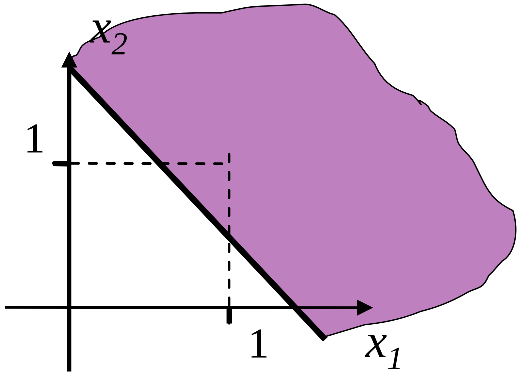

x_1 OR x_2: $0.5x_1 + 0.5\,x_2 - 0.3 > 0$

x_1 AND x_2 : $0.5x_1 + 0.5\,x_2 - 0.8 > 0$

➔ Durch Kombination von Perzeptronen sind viele Funktionen möglich

XOR: ???

NICHT MÖGLICH
(mit einem Perzeptron)

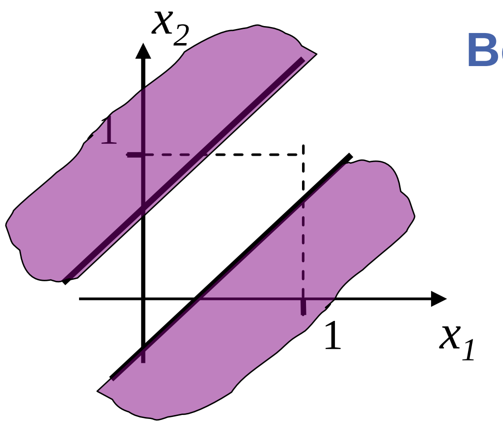

Besser

Multi Layer Feedforward Neural Network

- Motivation
  - Grenzen des Perzeptrons
- Aufbau des MLNN
  - MLNN - Neuronen
  - Lernverfahren:
    - Backpropagation (allgemeine Deltaregel)
- Probleme / Optimierungen
  - Gradientenabstieg (z.B. RPROP)
  - Konstruktive Verfahren (DDA, Cascade Correlation)

Multi Layer Neural Network

- Netzaufbau: mehrere versteckte (innere) Schichten
- Lernverfahren: Backpropagation – Algorithmus (allgemeine Delta-Regel) [Rumelhart86, Werbos74]
- Neuronenaufbau: nichtlineare Aktivierungsfunktion

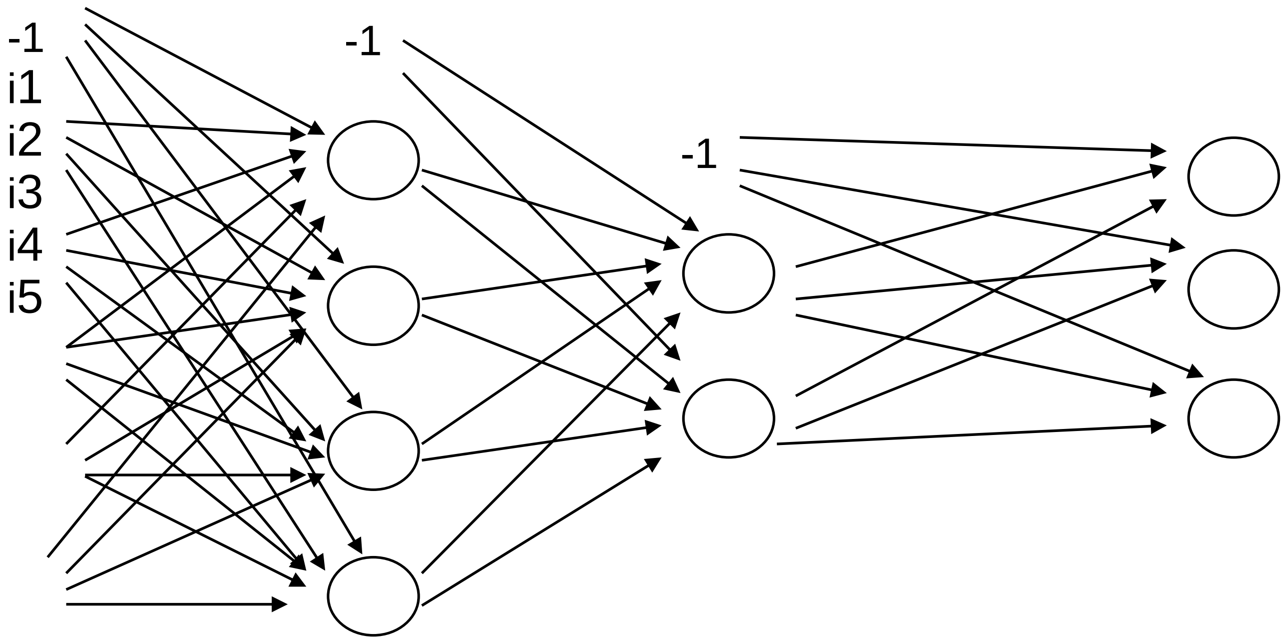

Aufbau der Neuronen

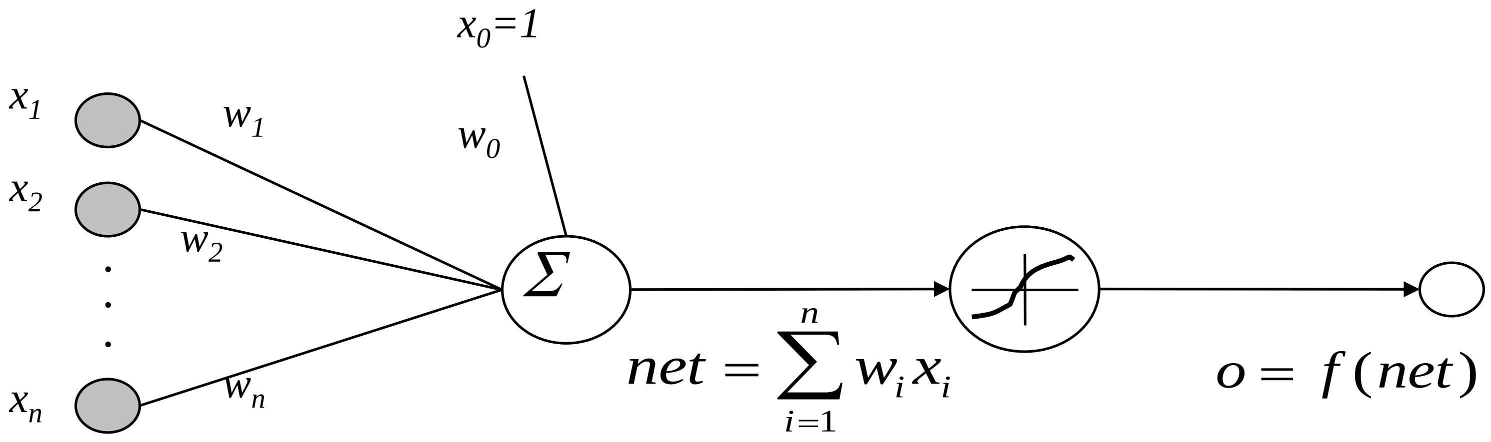

$$net = \sum_{i=1}^{n} w_i x_i$$

$$o = f(net) = \frac{1}{1+e^{-net}}$$

- x_{ij} = i-te Eingabe des Neurons j
- w_{ij} = das Gewicht zwischen Neuron i und Neuron j
- net_j = $\sum_i w_{ij} x_{ij}$ Propagierungsfunktion
- o_j = Ausgabe des Neurons j
- t_j = Zielausgabe (target) des Ausgabeneurons j
- $f(x)$ = Aktivierungsfunktion

- *outputs* = Menge der Ausgabeneuronen
- *Downstream* (j) = direkte Nachfolger des Neurons j

Nichtlineare Aktivierungsfunktionen

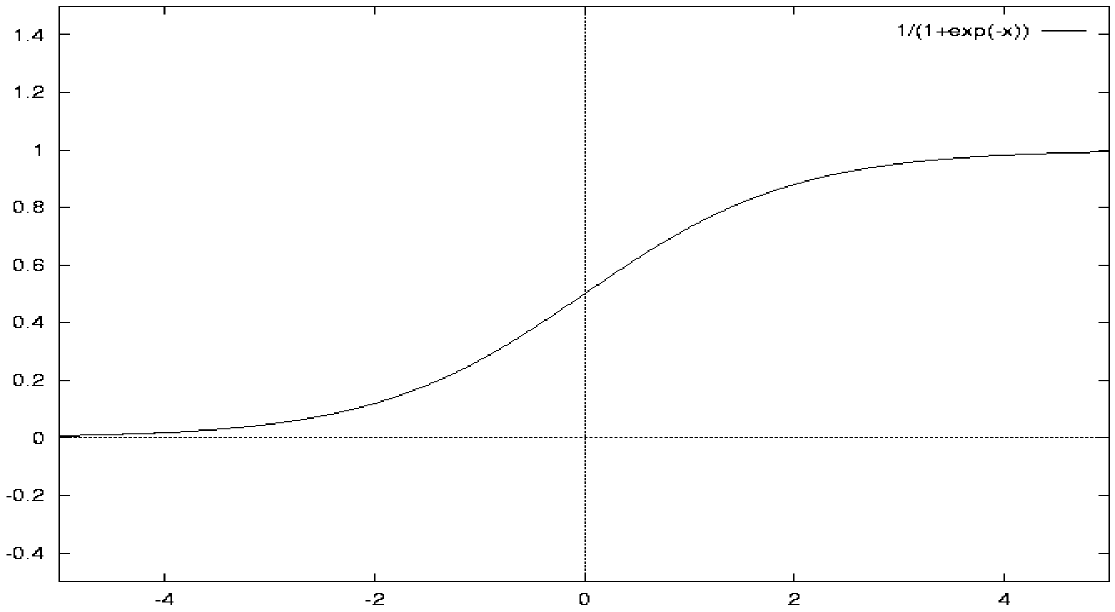

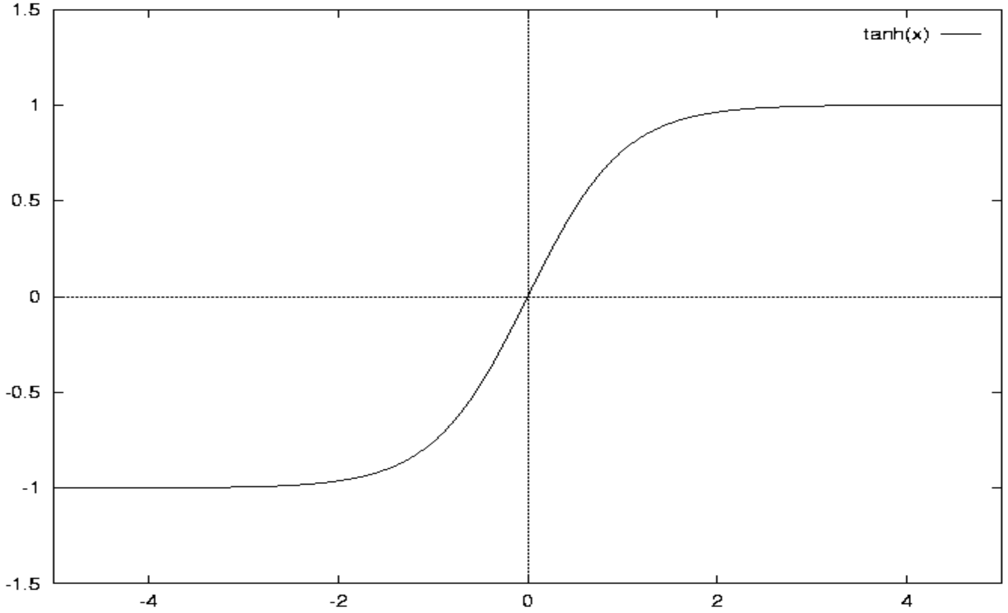

Sigmoid:

$$f(x) = \frac{1}{1+e^{-x}}$$

$$\frac{\partial f}{\partial x} = f(x)\,(1 - f(x))$$

$$f(x) = \tanh(x)$$

$$\frac{\partial f}{\partial x} = (1 + f(x))\,(1 - f(x))$$

Backpropagation Algorithmus I

Vorgaben:

Menge T von Trainingsbeispielen

Eingabevektor / Ausgabevektor (input / output)

Lernrate η

Netztopologie

Anzahl und Ausmaße der Zwischenschichten

Schichten sind vollständig vorwärts gerichtet verbunden

Lernziel:

Finden einer Gewichtsbelegung W, die T korrekt wiedergibt

Vorgehen:

Gradientenabstieg ➔ allgemeine Deltaregel

Backpropagation Algorithmus II

- Initialisieren der Gewichte mit kleinen zufälligen Werten

- Wiederhole
  - Auswahl eines Beispielmusters d
  - Bestimmen der Netzausgabe
  - Bestimmen des Ausgabefehlers (bzgl. Sollausgabe)
  - Sukzessives Rückpropagieren des Fehlers auf die einzelnen Neuronen

$$\delta_j = \begin{cases} o_j(1-o_j) \sum\limits_{k \in Downstream(j)} \delta_k w_{jk} & j \notin output \\ o_j(1-o_j)\ (t_j - o_j) & j \in output \end{cases}$$

  - Anpassung der Gewichtsbelegungen um
- solange ein gewähltes Abbruchkriterien nicht erfüllt ist

$$\Delta w_{ij} = \eta \delta_j x_{ij}$$

Gradientenabstieg - Allgemeine Deltaregel

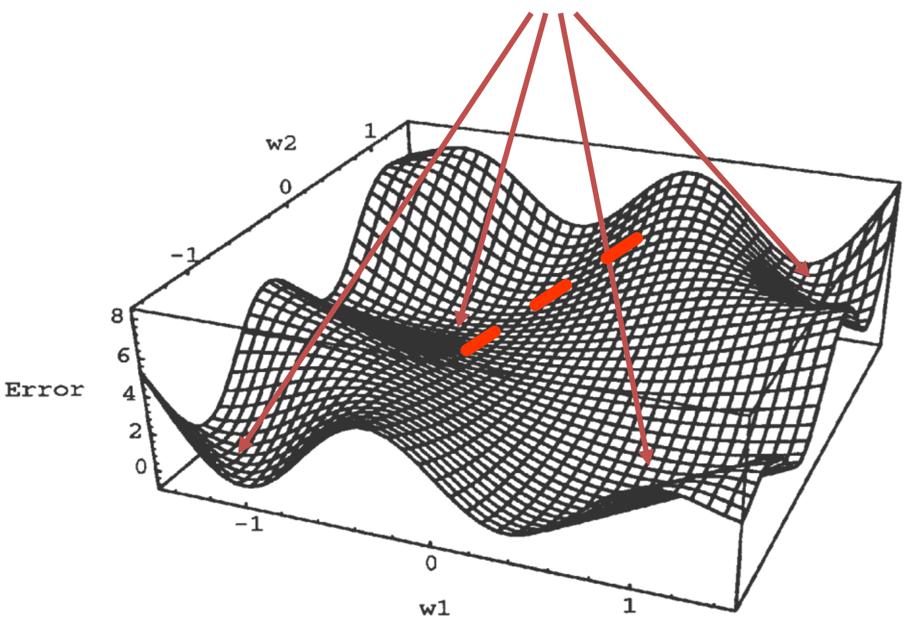

Fehlerfunktion

$$E_d(\vec{w}) \equiv \frac{1}{2} \sum_{k \in outputs} (t_k - o_k)^2$$

Gewichtsänderung nach dem Gradienten

$$\Delta w_{ij} = -\eta \frac{\partial E_d}{\partial w_{ij}}$$

Kettenregel

$$\frac{\partial E_d}{\partial w_{ij}} = \frac{\partial E_d}{\partial net_j} \frac{\partial net_j}{\partial w_{ij}} = \frac{\partial E_d}{\partial net_j} x_{ij}$$

$$net_j = \sum_{i=1}^{n} w_{ij} x_{ij}$$

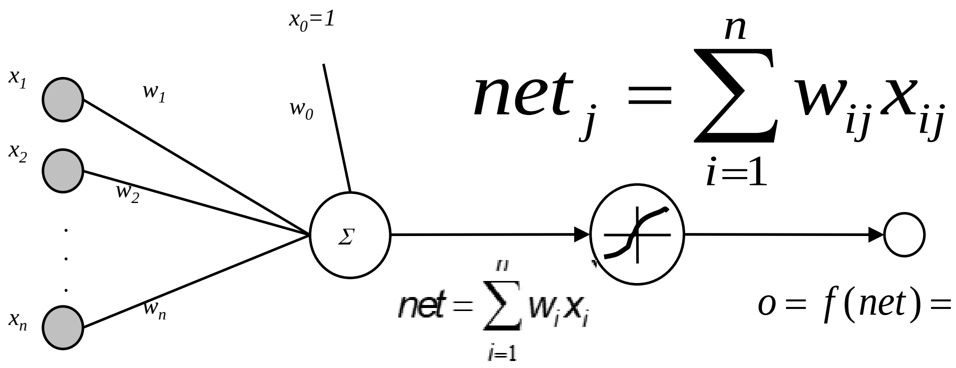

$$net = \sum_{i=1}^{n} w_i x_i$$

$$o = f(net) = \frac{1}{1+e^{-net}}$$

Allgemeine Deltaregel

Ableitung von $\frac{\partial E}{\partial net_j}$ für Ausgabeschicht

$$\frac{\partial E_d}{\partial net_j} = \frac{\partial E_d}{\partial o_j}\frac{\partial o_j}{\partial net_j}$$

$$\frac{\partial E_d}{\partial o_j} = \frac{\partial}{\partial o_j}\frac{1}{2}\sum_{k\in outputs}(t_k - o_k)^2$$

$$\frac{\partial E_d}{\partial o_j} = \frac{\partial}{\partial o_j}\frac{1}{2}(t_j - o_j)^2$$

$$= \frac{1}{2}2(t_j - o_j)\frac{\partial(t_j - o_j)}{\partial o_j}$$

$$= -(t_j - o_j)$$

$$\frac{\partial o_j}{\partial net_j} = \frac{\partial f(net_j)}{\partial net_j} = o_j(1 - o_j)$$

$$f(x) = \frac{1}{1+e^{-x}}$$

$$\frac{\partial f}{\partial x} = f(x)(1 - f(x))$$

Allgemeine Deltaregel

Ableitung von $\frac{\partial E}{\partial net_j}$ für Zwischenschichten

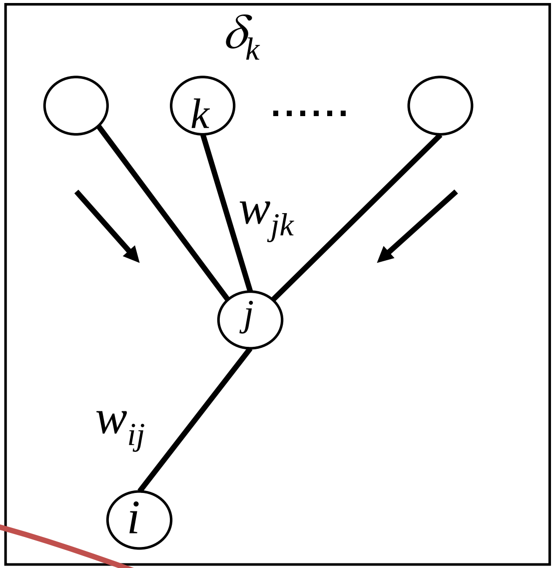

$$\frac{\partial E_d}{\partial net_j} = \sum_{k \in Downstream(j)} \frac{\partial E_d}{\partial net_k} \frac{\partial net_k}{\partial net_j}$$

$$\delta_j = -\frac{\partial E_d}{\partial net_j} = -\sum_{k \in Downstream(j)} -\delta_k \frac{\partial net_k}{\partial net_j}$$

$$= -\sum_{k \in Downstream(j)} -\delta_k \frac{\partial net_k}{\partial o_j} \frac{\partial o_j}{\partial net_j} = -\sum_{k \in Downstream(j)} -\delta_k w_{jk} \frac{\partial o_j}{\partial net_j}$$

$$= \sum_{k \in Downstream(j)} \delta_k w_{jk} o_j (1 - o_j)$$

$$= o_j (1 - o_j) \sum_{k \in Downstream(j)} \delta_k w_{jk}$$

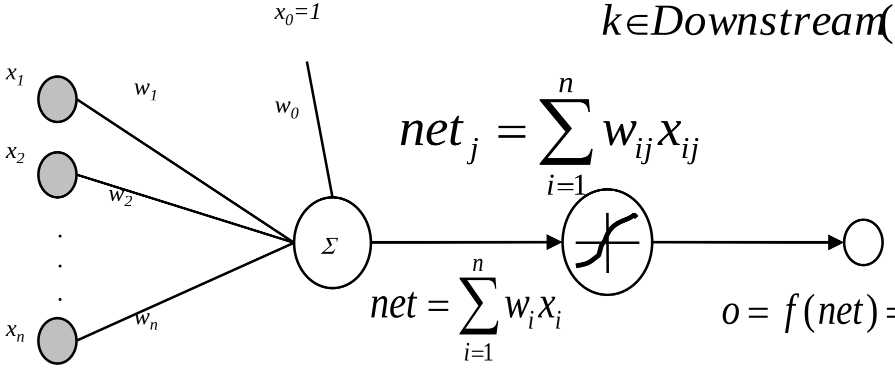

$$net_j = \sum_{i=1}^{n} w_{ij} x_{ij}$$

$$net = \sum_{i=1}^{n} w_i x_i$$

$$o = f(net) = \frac{1}{1+e^{-net}}$$

Allgemeine Deltaregel

$$\Delta w_{ij} = -\eta \frac{\partial E_d}{\partial w_{ij}}$$

$$\Delta w_{ij} = \eta \delta_j x_{ij}$$

$$\delta_j = \begin{cases} o_j(1-o_j) \sum_{k \in Downstream(j)} \delta_k w_{jk} & j \notin output \\ o_j(1-o_j)\ (t_j - o_j) & j \in output \end{cases}$$

Multi Layer Feedforward Neural Network

- Motivation
  - Grenzen des Perzeptrons

- Aufbau des MLNN
  - MLNN - Neuronen
  - Lernverfahren:
    - Backpropagation (allgemeine Deltaregel)

- Probleme / Optimierungen
  - Empirischer Fehler - Gradientenabstieg (z.B. RPROP)
  - Kapazität - Konstruktive Verfahren (DDA, Cascade Correlation)

Fehlerflächen

- Lernen abhängig von:
  - Steigung der Fehlerfläche
  - Vorkommen lokaler Minima
  - Ausprägung der lok. Min.
  - Lernrate

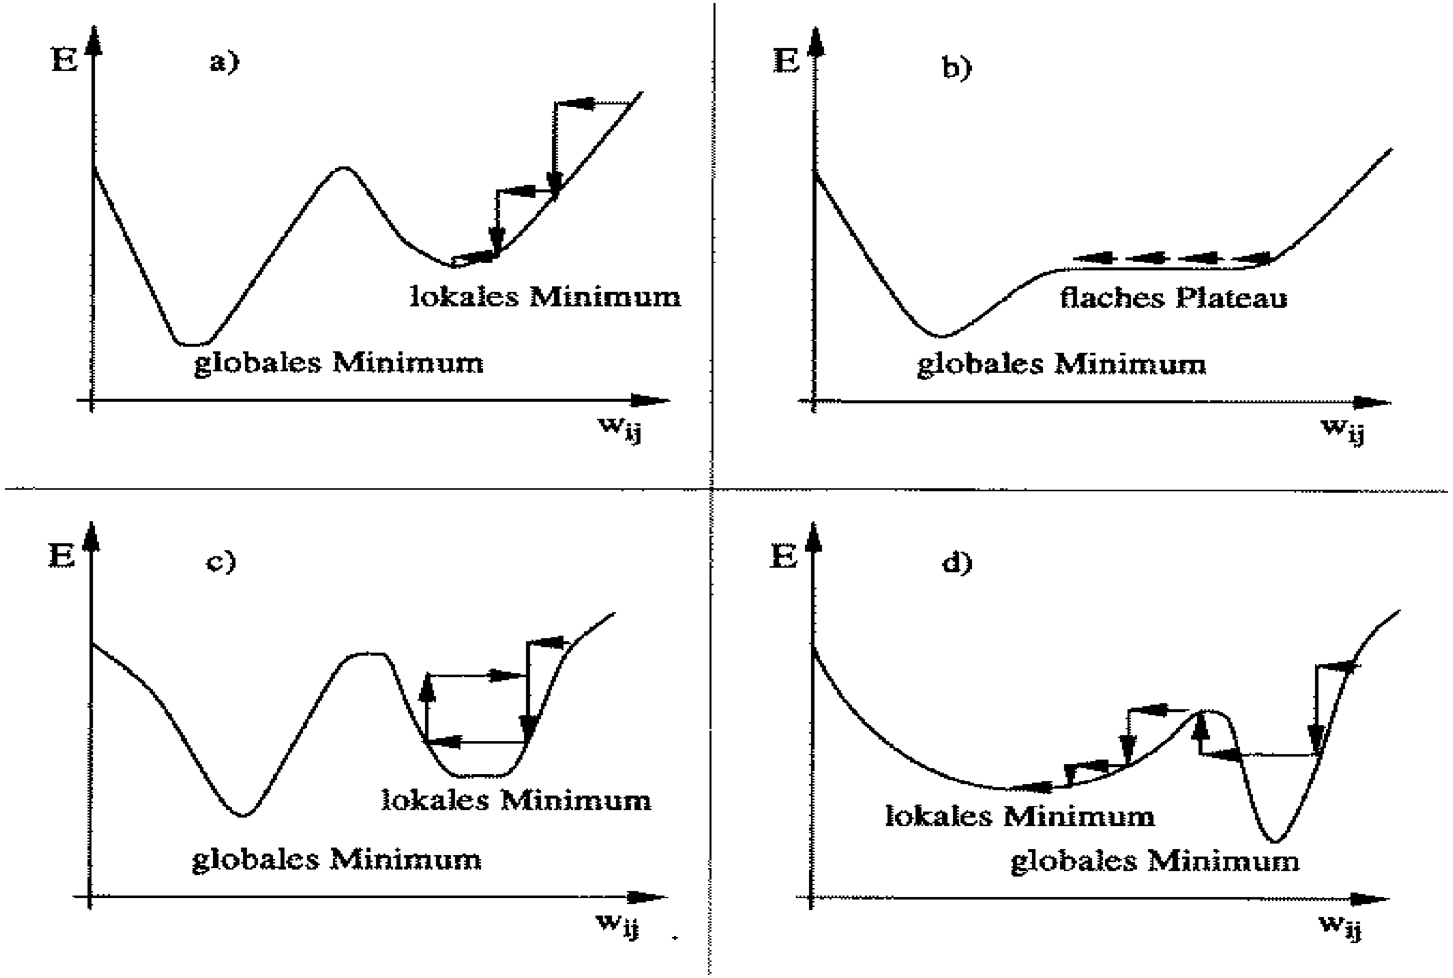

Optimierungen des Gradientenabstiegs

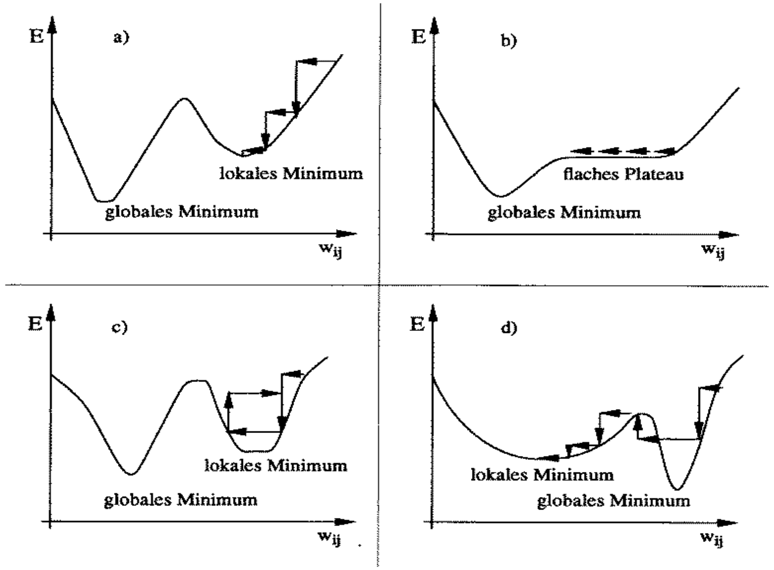

- Momentum Term $$\Delta w_{ij}(t) = \eta\,\delta_j(t)\,x_{ij}(t) + \alpha\,\Delta w_{ij}(t-1)$$
  (α im Intervall [0.2,0.9])
- Normierung der Schrittweite (Manhattan-Training)
  $$\Delta w_{ij} = \eta\, sign(\delta_j)\, x_{ij}$$
- Lernratenanpassung
  - Wie ist ideale Schrittweite in hochdimensionaler Fehlerfläche ? → individuelle Lernrate
  - Modifikation der Lernrate mittels Gradientenvergleichs (RPROP)

$$\eta(t+1) > \eta(t)\,,\ wenn\ \ sign\left(\frac{\partial E}{\partial w}(t+1)\right) = sign\left(\frac{\partial E}{\partial w}(t)\right)$$

$$\eta(t+1) < \eta(t),\ \ sonst$$

RPROP (Resilient Propagation)

Fehlerfunktion

$$E = \frac{1}{2} \sum_{i \in outputs} (t_i - o_i)^2$$

Gewichtsänderung

$$\Delta w_{ij}(t) = \begin{cases} -\Delta_{ij}(t), & wenn \ \frac{\partial E}{\partial w_{ij}}(t) > 0 \\ +\Delta_{ij}(t), & wenn \ \frac{\partial E}{\partial w_{ij}}(t) < 0 \\ 0, & sonst \end{cases}$$

RPROP

Karlsruher Institut für Technologie

Lernrate abhängig vom Gradientenvergleich

$$\Delta_{ij}(t) = \begin{cases} \Delta_{ij}(t-1)\cdot\eta^{+}, & wenn\ \dfrac{\partial E}{\partial w_{ij}}(t-1)\dfrac{\partial E}{\partial w_{ij}}(t) > 0 \\ \Delta_{ij}(t-1)\cdot\eta^{-}, & wenn\ \dfrac{\partial E}{\partial w_{ij}}(t-1)\dfrac{\partial E}{\partial w_{ij}}(t) < 0 \\ \Delta_{ij}(t-1), & sonst \end{cases}$$

$$\eta^{+} > 1,\ \eta^{-} < 1$$

RPROP – Interpretation

Beschleunigen auf flachem Plateau

Langsam Anpassen im Minimum

➔ Schnelle Konvergenz

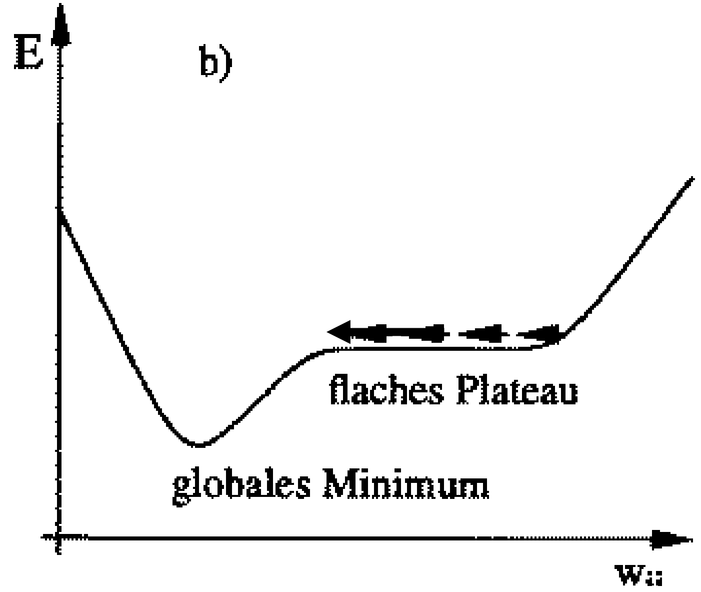

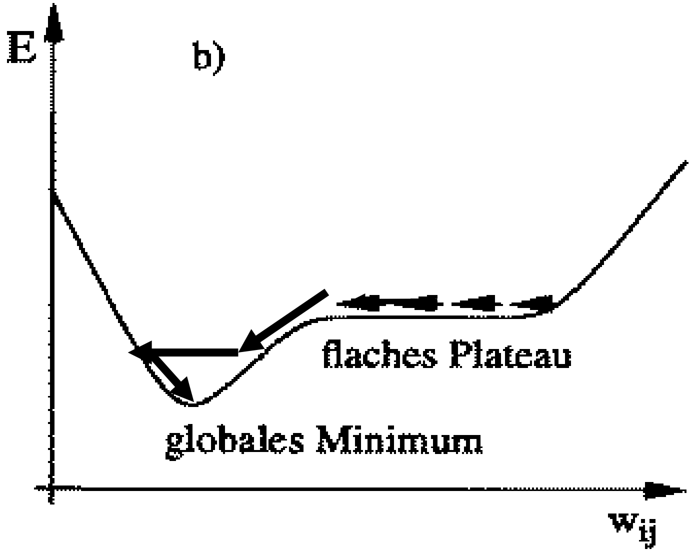

Multi Layer Feedforward Neural Network

- Motivation
  - Grenzen des Perzeptrons
- Aufbau des MLNN
  - MLNN - Neuronen
  - Lernverfahren:
    - Backpropagation (allgemeine Deltaregel)
- Probleme / Optimierungen
  - Empirischer Fehler - Gradientenabstieg (z.B. RPROP)
  - Kapazität - Konstruktive Verfahren (DDA, Cascade Correlation)

Topologieauswahl MLNN

Anzahl der (hidden) layer ←→ Zielfunktion

- 3 Layer (1 hidden Layer - sigmoid):
  - jede Boolsche Funktion abbildbar
  - jede kontinuierliche beschränkte Funktion
  - [Cybenko 1989, Hornik et al. 1989]
- 4 Layer (2 hidden Layer -sigmoid)
  - beliebige Funktionen mit beliebiger Genauigkeit
  - [Cybenko 1988]

→ Schon eine geringe Tiefe ist ausreichend

Lernverhalten - Topologieauswahl

Anzahl der Neuronen pro Schicht im Bezug zu der Anzahl von (stochastisch unabhängigen) Lerndaten ist wichtig

- allgemeine Aussage zur Topologie nicht möglich

Topologie ←→ Kapazität (VC –Dimension)

Beispiel:

gestrichelte Kurve
soll eingelernt werden

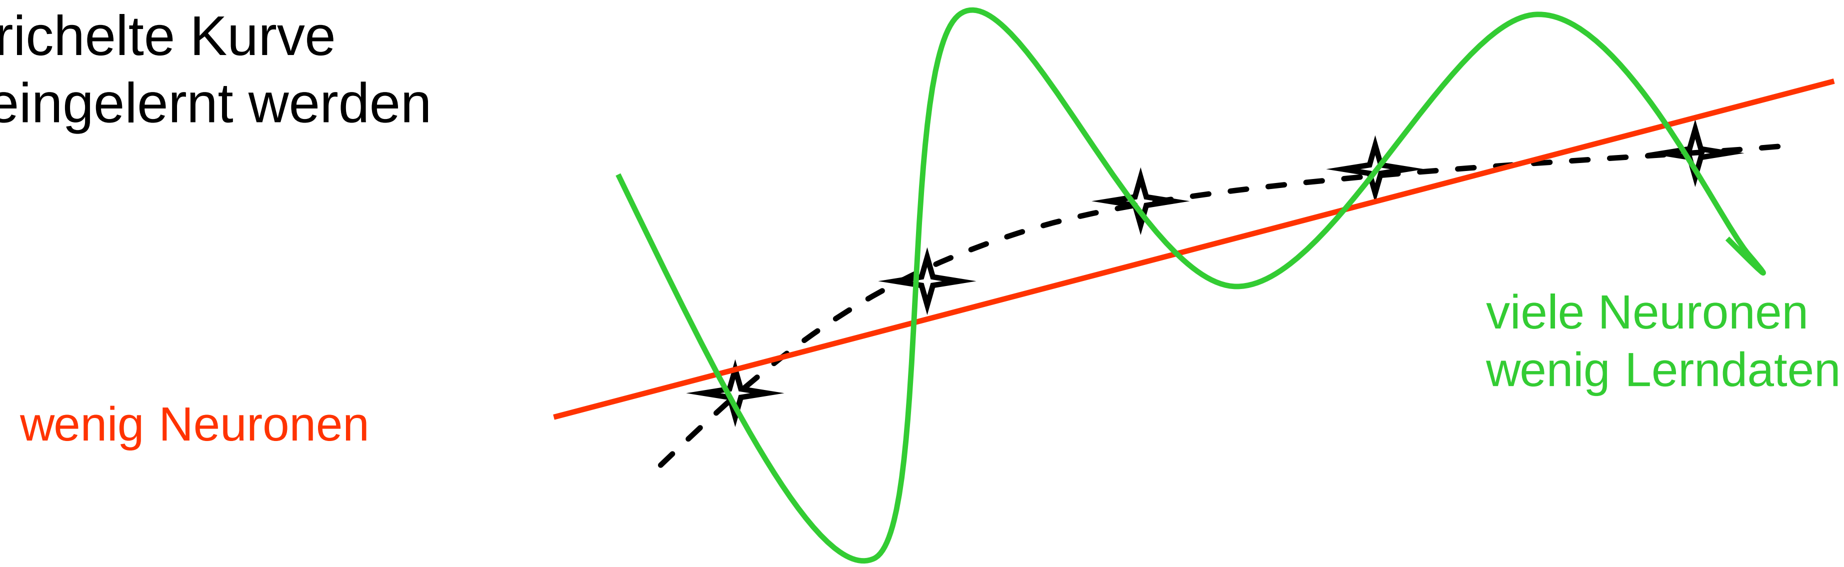

Verbesserung der Generalisierung (~realer Fehler) von MLNN

- Ziel: Gleichzeitiges Trainieren eines NN und Finden der optimalen Topologie
- Anpassung der Kapazität, 2 Ansätze :
  - großes Netzwerk wird verkleinert und so daran gehindert, die Daten auswendig zu lernen
  - kleines Netzwerk wird solange erweitert bis es die Daten lernen kann

- Methoden der Reduzierung
  - Weight Decay, Weight Elimination = Bestrafen von großen w durch Verwendung erweiterter Fehlerfunktion:

$$E(w) = E_D(w) + \tfrac{1}{2}\lambda \sum w^2,$$

  - Optimal Brain Damage
    - Lernen + anschließend Löschen von Verbindungen,
    - zB. w mit kleinen Beträge oder wenig Einfluss auf den Fehler E
    - (Verwendung der zweiten Ableitung. Taylor-Entwicklung)

Verbesserung der Generalisierung (~realer Fehler) von MLNN

- Ziel: Gleichzeitiges Trainieren eines NN und Finden der optimalen Topologie
- Anpassung der Kapazität, 2 Ansätze :
  - großes Netzwerk wird verkleinert und so daran gehindert, die Daten auswendig zu lernen
  - kleines Netzwerk wird solange erweitert bis es die Daten lernen kann

- Schrittweise Vergrößern (konstruktiv)
  - Cascade Correlation
  - Meiosis Netzwerke (Unsicherheit der Gewichte wird berücksichtigt: relative Standardabweichung = Standardabweichung/Mittelwert >1 □ Aufspalten)

Konstruktive Lernverfahren für MLNN

Beispiel: Cascade – Correlation – Verfahren für MLNN (Fahlman, Lebiere)

Algorithmus:

Initialisierung:

2- schichtiges Netz, Abbruchkriterien: Fehlerschranke $E(w)$, # Neuronen

….

Trainieren → Anpassen aller Gewichte

while $E(w) >$ *Fehlerschranke* und *nicht weiteres Abbruchkriterium do*

Füge Neuron ein: (s.g. Kandidat-Neuron)

- hidden, vor die Ausgabeschicht
- vollständig verbunden, (mit Eingabeschicht)

(z.B. Gewicht -1 zu vorher eingefügten Neuronen)

Trainiere neues Neuron (einmalig)

Trainiere Netz

done

Cascade Correlation I (Fahlman)

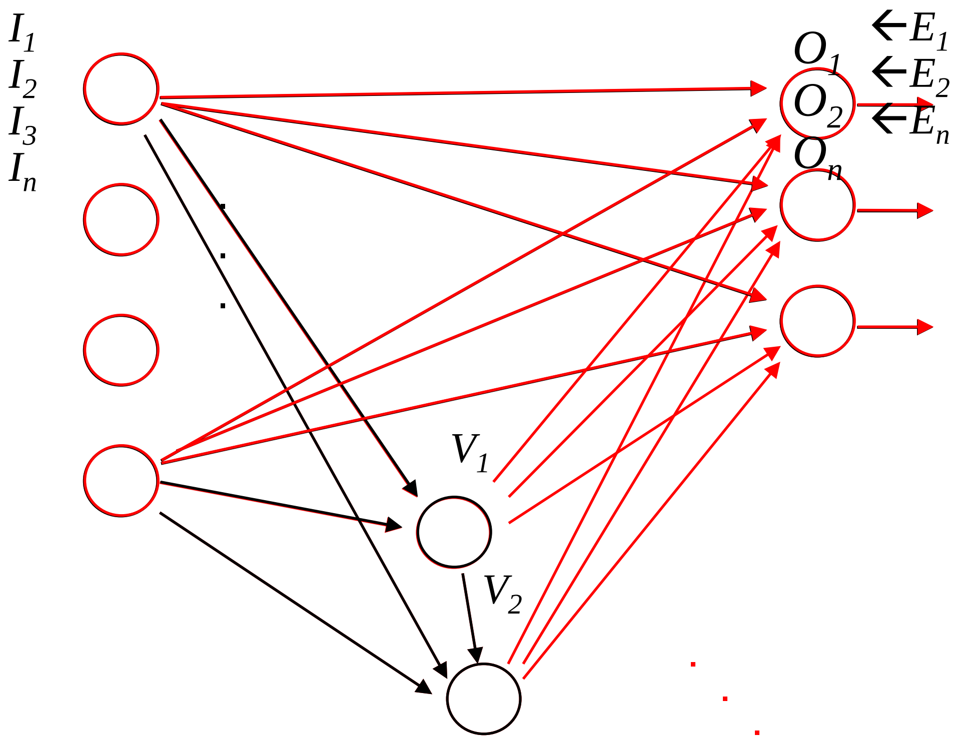

Anpassung der Kandidat-Neuronen (maximale Ausprägung für Fehler für alle Pattern p und alle output Neuronen o) durch Maximierung von:

$$S = \sum_o \left| \sum_p (V_p - \bar{V})(E_{p,o} - \bar{E}) \right|$$

Ausgabe Kandidatneuron

$$\frac{\partial S}{\partial w_i} = \sum_{p,o} \sigma_o (E_{p,o} - \bar{E}) f_p' I_{i,p},$$

Vorzeichen, Korrelation zw. Aktivierung Kandidatneuron und output o

Ableitung Sigmoid

Input Kandidat-neuron

Cascade Correlation II (Duda & Hart)

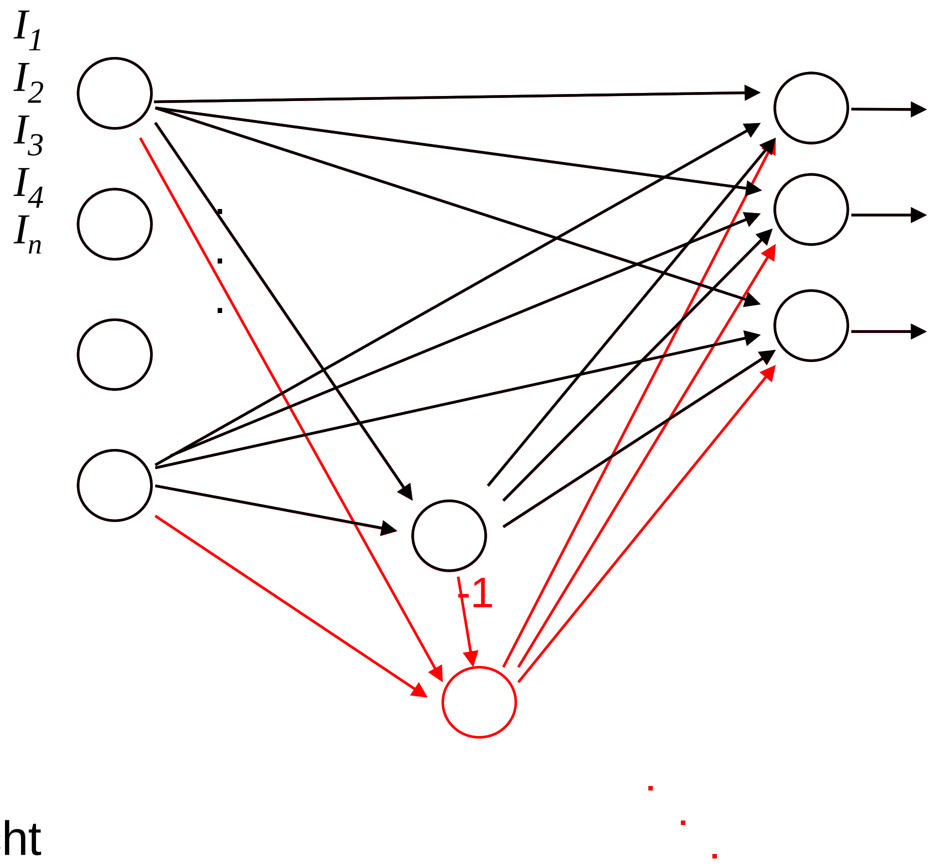

Vereinfachte Version:
Anpassung der neuen Neuronen

Kandidat-Neuronen wird mit -1 zu den anderen Neuronen der Zwischenschicht verbunden (maximal unterschiedliche Ausprägung)

Cascade Correlation

- Zu jedem Zeitpunkt wird „nur eine Ebene“ von Verbindungen trainiert
- Lernt sehr schnell
- Inkrementelles Training
- (d.h. bei neuen Daten vom letzten Stand aus **weiter** Lernen)
- Iterative Anpassung der Kapazität des Netzes

Einsatz von MLNN

- Entwurf
  - Subsymbolische Repräsentation der Ein- und Ausgabe
  - Auswahl Trainingsdaten
  - Auswahl des Verfahren
  - Auswahl der Topologie
  - Parametereinstellung

- Auswahl des Lernverfahrens
  - z.B. Optimierungsmethode (Momentum,...., RPROP)

- Lernen
  - Initialisierung
  - Lernschritt (Gewichtsanpassung) Overfitting
  - Training & Verifikation (Test)

Auswahl repräsentativer Trainingsbeispiele

- Lerndaten
  - für die Anpassung der Gewichte
- Testdaten
  - für das Testen des Fehlers und auf Overfitting
- Verifikationsdaten
  - für das Feststellen der Generalisierung
- gute Verteilung
  - Klassifikation: Daten aus allen Klassen
  - Regression: gesamter Definitionsbereich
- komplexe Regionen
  - Randregionen zw. Klassen
  - Verlaufsänderungen

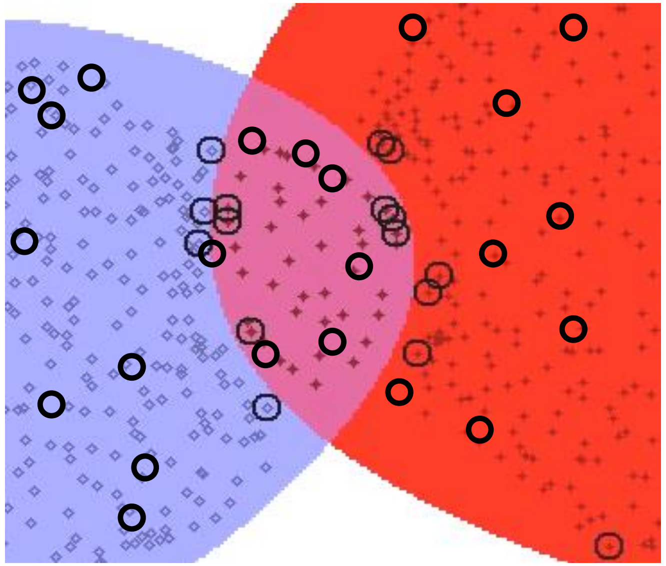

Ansätze der Wissensrepräsentation

Verteilt (global) - Sigmoid MLNN

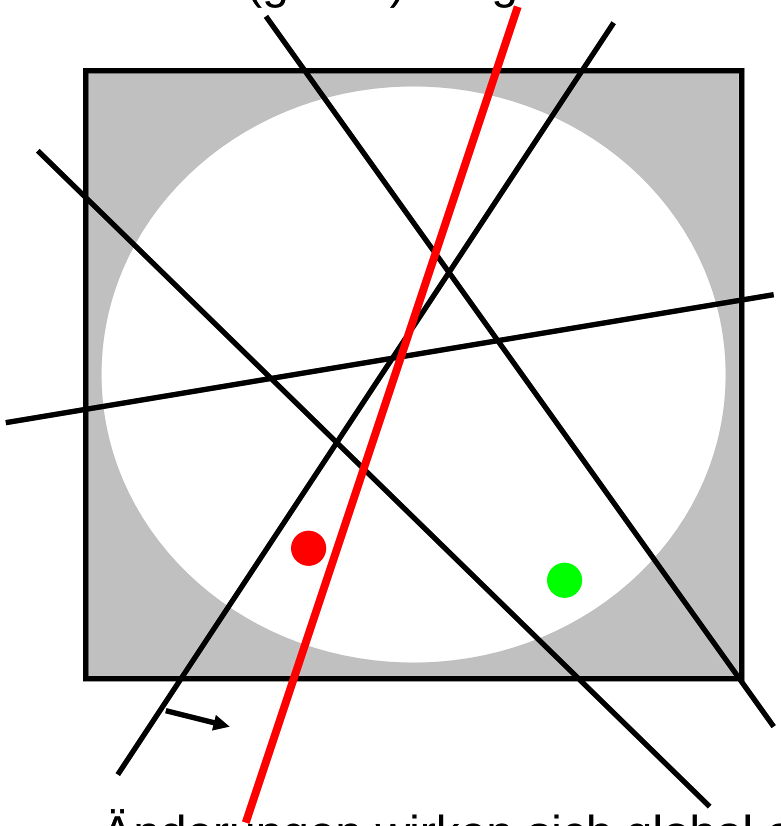

- Änderungen wirken sich global aus
- Generalisierung ist gut

Lokal RBF - NN

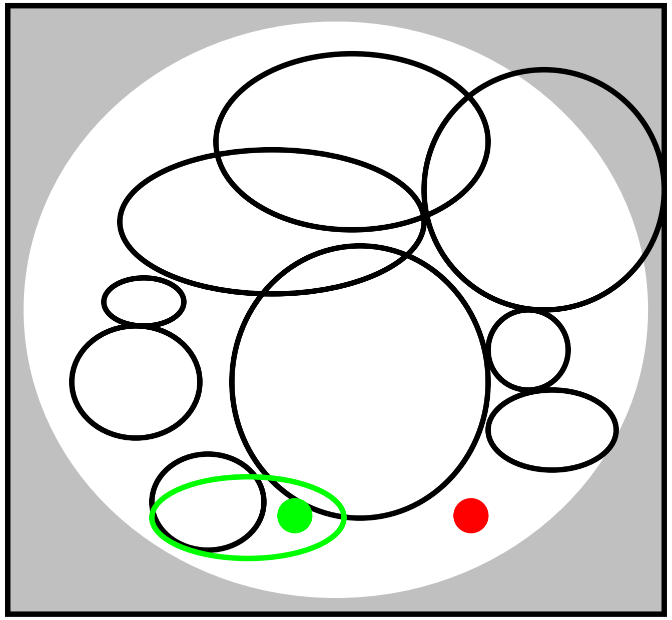

- Änderungen nur lokal
- Generalisierung schlechter

Verteilte vs. Lokale Wissensrepräsentation

- Vergleichskriterien:
  - Zielsetzung: Generalisierungsverhalten (verteilt)
  - Inkrementelles Lernen (Beibehalten von Wissen: eher lokal)
  - Interpretierbarkeit (lokal)
  - Einsatz in hybriden Lernarchitekturen (beide)
    - Umsetzbarkeit von bzw. in Fuzzy-Wissensbasen (lokal)

Initialisierung der Gewichte

- Gewichte:
  - verschieden voneinander
  - sonst funktionsgleiche Neuronen

- zufällig, gleichverteilt und klein

$\Rightarrow$ keine anfängliche Ausrichtung

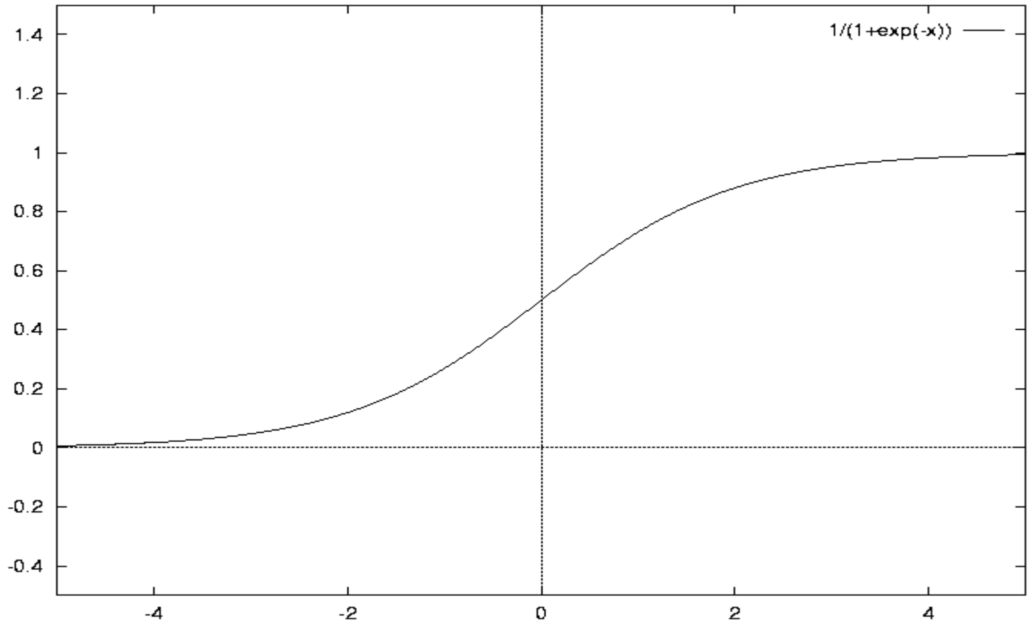

- weil

$$\Delta w_{ij} \Leftrightarrow \frac{\partial f(net_j)}{\partial net_j} \qquad \text{und} \qquad net_j = \sum_{i=1}^{n} w_{ij} x_{ij}$$

Anpassen der Gewichte

- Patternlearning
  - Anpassung nach jedem Lernbeispiel
  - schnelles Lernen
  - kein „echter“ Gradientenabstieg
  - zufällige Reihenfolge ➔ gute Approximation

- Epochlearning
  - Mittelung der Gewichtsänderung über alle Beispiele
  - Anpassung nachdem alle Beispiele propagiert wurden
  - „echter“ Gradientenabstieg
  - nicht anfällig für Ausreißer / falsche Lerndaten

Overfitting

Fehler auf Verifikationsdaten steigt
ab einer Anzahl von Lernzyklen

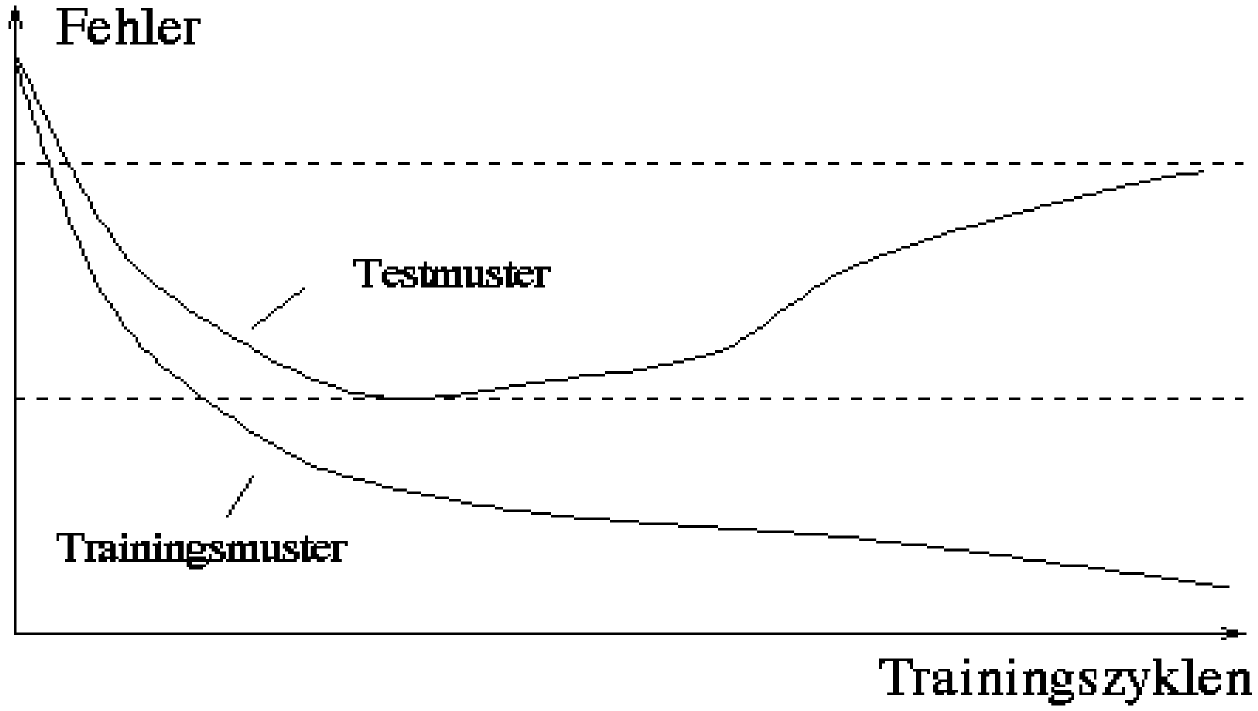

Mögliches Abbruchkriterium

Ältere Anwendungen von MLNN

Einige klassische Beispiele und typische Probleme:

- Gesichtserkennung
- PdV
- Alvinn ←→ Grand Challenge
- Lauron

Vorsicht: Wohldefinierte Anwendungen !

Institut AIFB
Institut IAR

Gesichtserkennung - MLNN

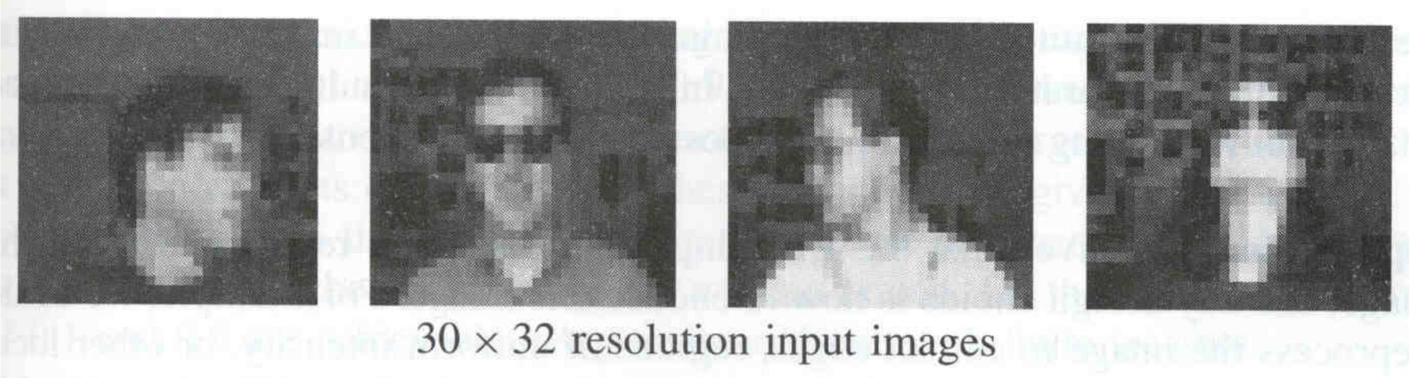

Vorgabe:

Grauwertbilder (255 Stufen, 128x128 pixel)

Ziel:

Erkennen ob ein Gesicht vorhanden ist
Welches Geschlecht
Blickrichtung (links, rechts, hoch, geradeaus)

Lernbeispiele

20 Personen
32 verschiedene Bilder/Person

Gesichtserkennung - MLNN

Input:

Rohdaten (Pixel), z.B.: 30x32 – Bild

➔ langsames Lernen

Merkmale wie Kanten, Ecken usw.

➔ Anwendungsabh., unterschiedliche Anzahl von Merkmalen ist problematisch

Output

- z.B: eine Ausgabe für Blickrichtung (0.2, 0.4, 0.6, 0.8)
- z.B: je eine Ausgabe für jede Blickrichtung ({0,1}, {0,1}, {0,1}, {0,1})
- Schwellwerte für die Interpretation der Ausgaben (z.B: [0,0.3] ➔ 0)
- analog für die anderen Ausgaben

Netz, Lernverfahren:

- z.B: Blickrichtung: Topologie: 960 x 3 x 4
- Lernrate z.B: $\eta = 0.3$
- Patternlearning
- Verifikation nach 50 Anpassungsschritten

Gesichtserkennung - MLNN

Ergebnis:

260 Beispiele ➔ 90% Erkennungsrate für die Blickrichtung

Analyse der output und hidden Gewichte:

- nach 1 Iteration

- nach 100 Iterationen

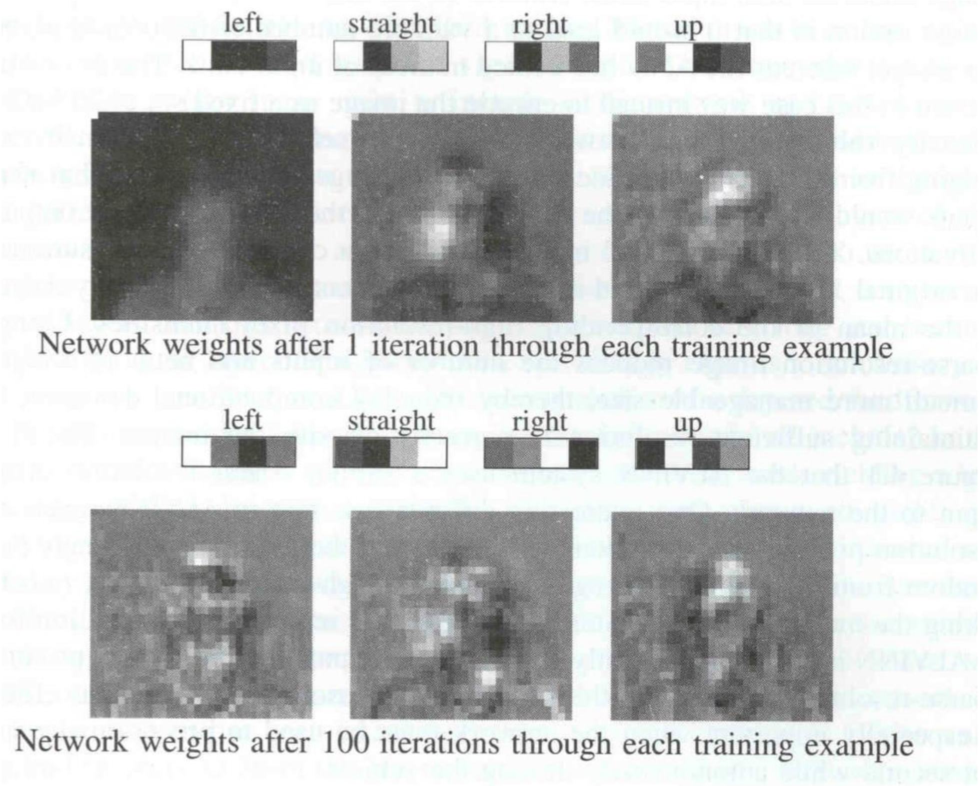

Hier keine Relevanz!!! Weil keine lokale Wissensrepräsentation

Autonomes Fahren mit Neuronalen Netzen ALVINN (Pomerleau ,CMU, 1996)

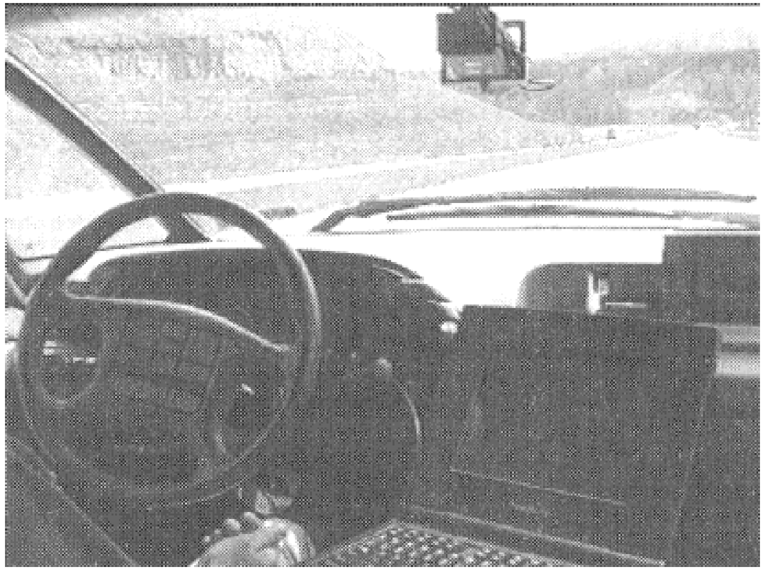

Ziel:

Steuerung eines Fahrzeugs mit Hilfe von Neuronalen Netzen

Autonomes Fahren mit Neuronalen Netzen ALVINN

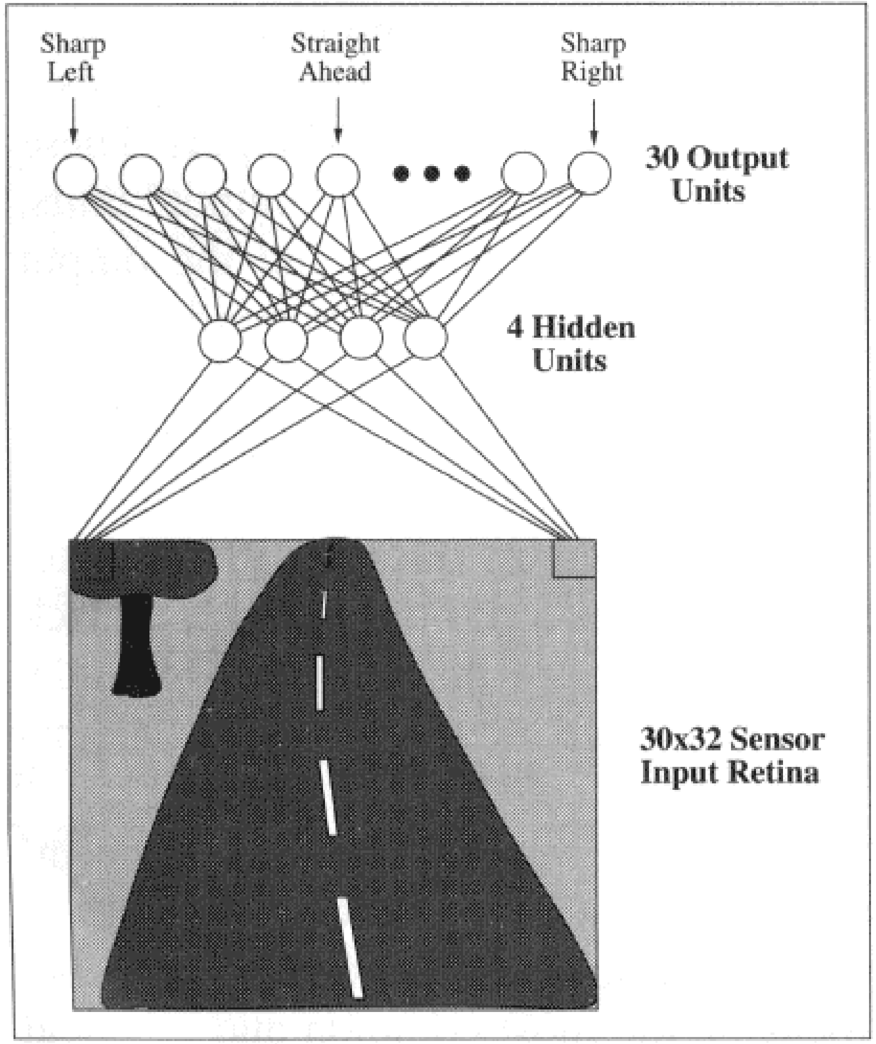

Beispiel: Realisierung der Lenkung

Input: Rohdaten (30x32 Pixel)

Output: 30 Lenkpositionen {0,1}

Topologie

- 960 Input Neuronen
- 4 Hidden Neuronen
- 30 Output Neuronen

Autonomes Fahren mit Neuronalen Netzen ALVINN

Problem: Beispieldatengenerierung

- Fahrer macht keine Fehler
  $\Rightarrow$ Ausnahmesituationen fehlen
- Viele verschiedene Situationen werden benötigt
  - Lichtverhältnisse
  - Straßenformen
- Sammeln ähnlicher Daten während einer Fahrt

→ Gefahr einseitigen Lernens

Lösungsansätze

- Generierung künstlicher Daten
  - Rauschen, Verschieben (immer noch gängig☺)
- Generierung ausgewogener Datensätze
- Multi - Network Ansatz

Autonomes Fahren mit Neuronalen Netzen ALVINN

Unterschiedliche Bedingungen

➔ Vielfältige Sensorik
➔ mehrere Netze

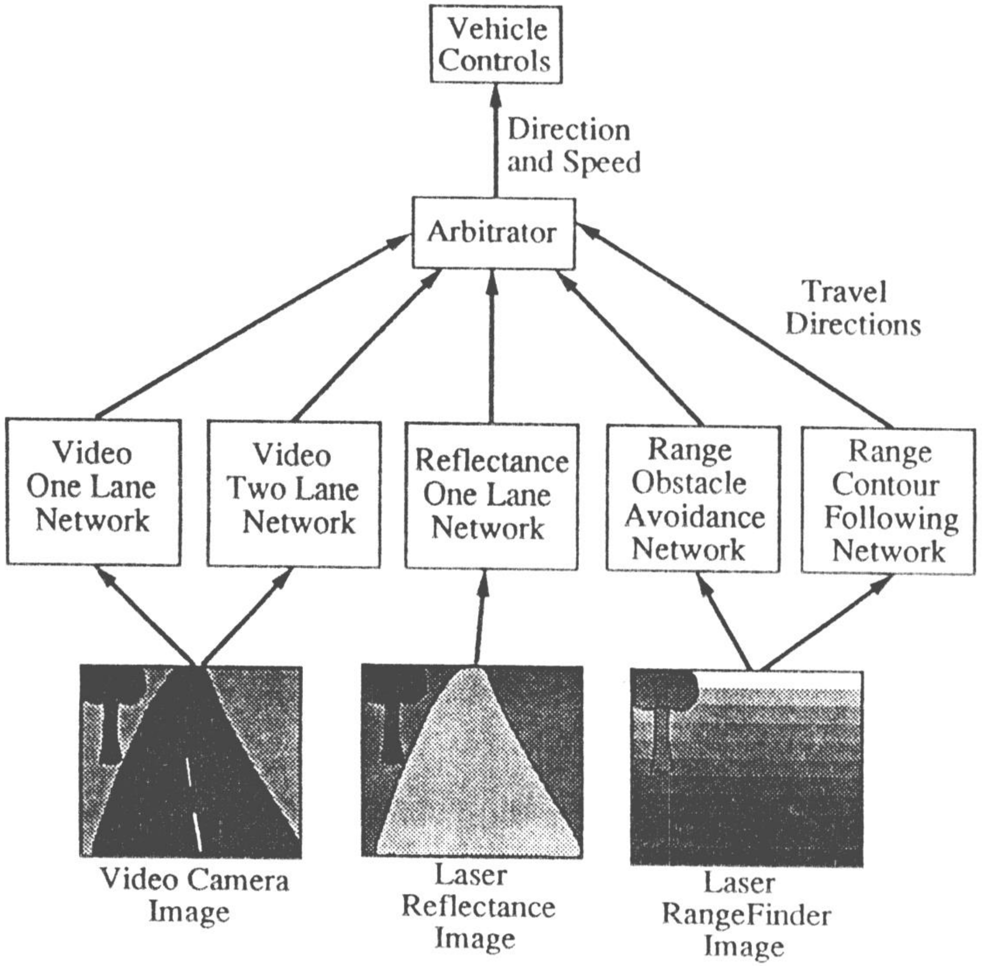

Im Vergleich dazu:
Autonomes Fahren – (seit) Grand Challenge 2005

http://video.google.com/videoplay?docid=8594517128412883394

Lauron (Laufmaschine neuronal gesteuert)

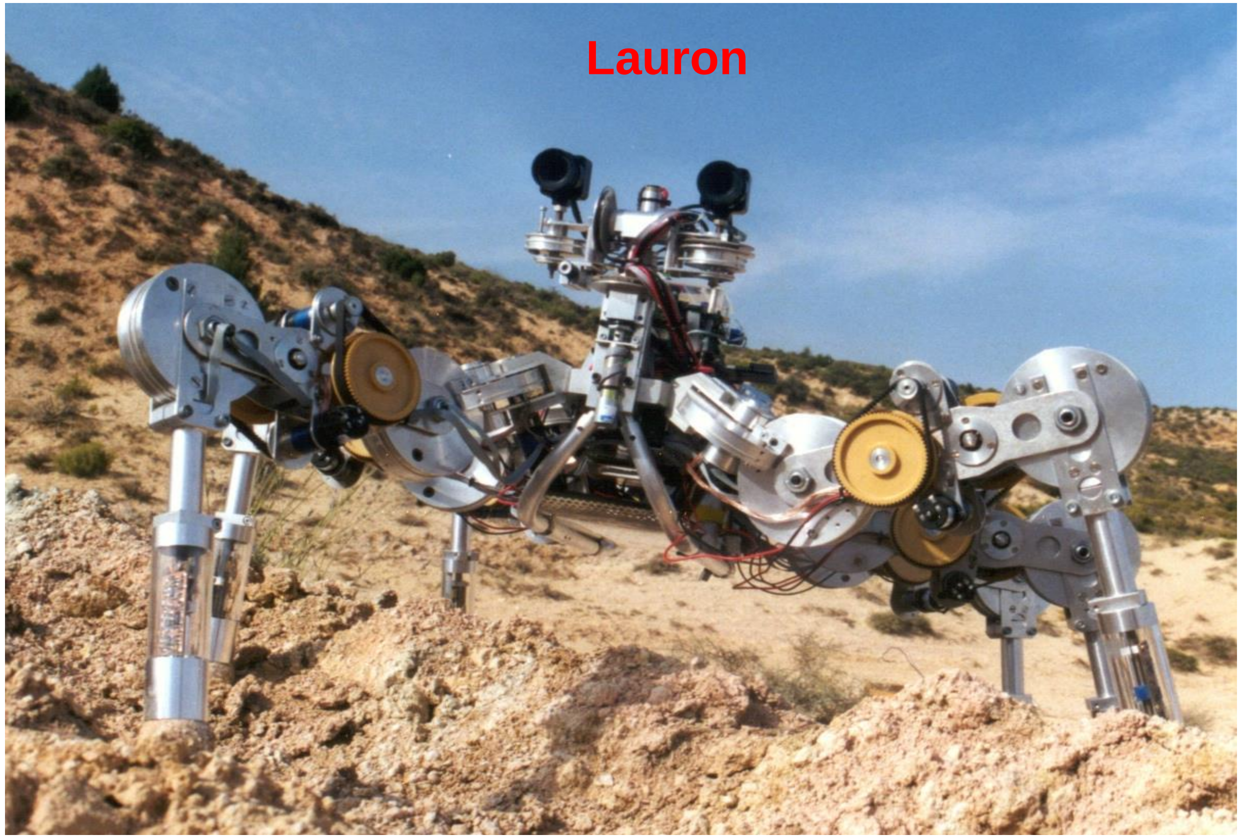

Frühe Anwendung NN: Bewegungssteuerung, Steuerung der einzelnen Beine (Gelenkwinkel)

Heute – Verhaltensbasierte Steuerung ohne NN

Bald ☺ – Verhaltensbasierte Steuerung mit Spiking NN (3. Generation)

EU – Flagship Projekt (seit 2013)

HBP Human Brain Project

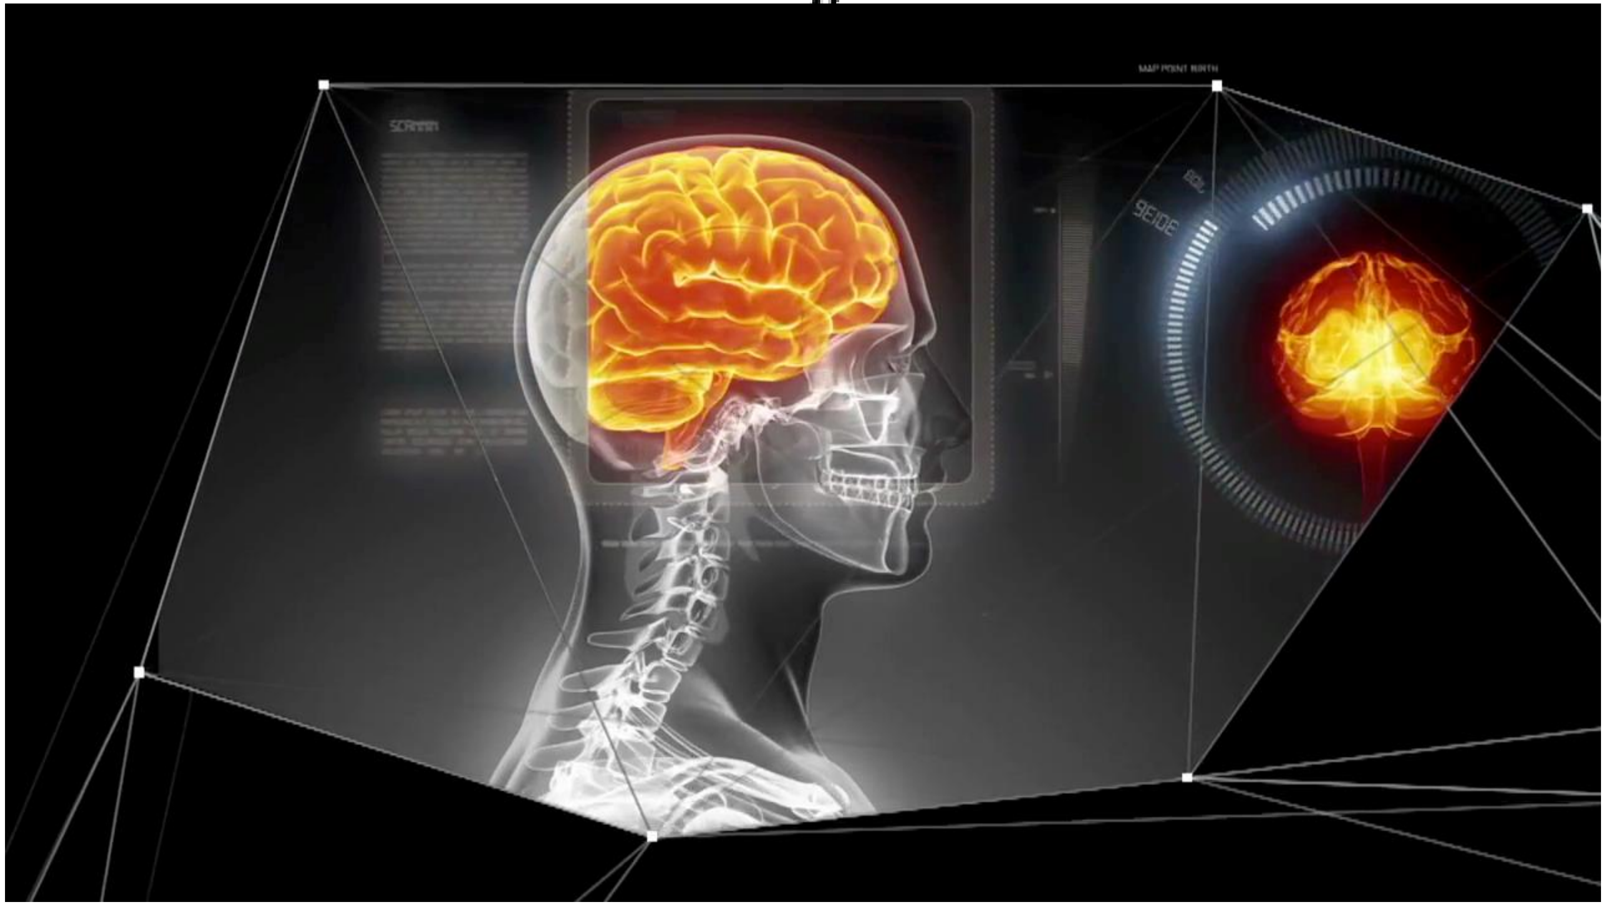

https://www.humanbrainproject.eu
http://www.youtube.com/watch?v=JqMpGrM5ECo

The HBP research areas and long-term goals

Goal: to *develop technology to unify our understanding of the human brain and to transfer this knowledge into products*

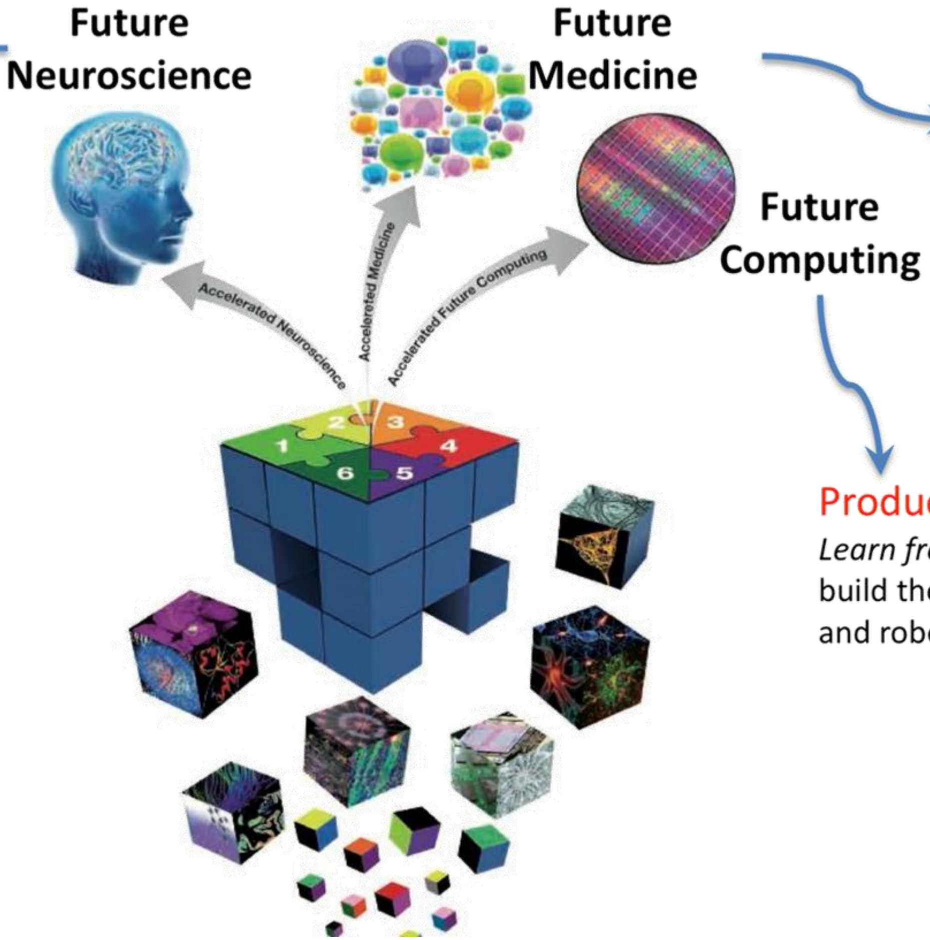

Unify
Integrate everything we know about the brain into computer models and simulations

Classify
Contribute to *understanding, diagnosing and treating* diseases of the brain

Produce
Learn from the brain to build the supercomputers and robots of tomorrow

Motivation: Why is the brain interesting for us, anyway?

10,000 neurons

850,000 neurons

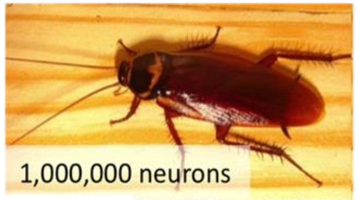

1,000,000 neurons

75,000,000 neurons

200,000,000 neurons

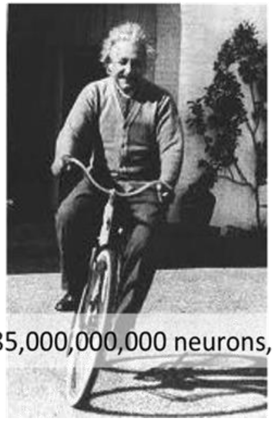

~85,000,000,000 neurons, 10^{15} synapses

- Algorithms are embedded in hardware
- Sensors and effectors operate in real-time
- The brain is massively parallel, but does not suffer from the problems of parallel computing: dead-locks, non-determinism, race-conditions, …
- … and decomposition into parallel tasks is self-organized/evolved
- Architecture is scalable from thousands to billions of “processors”
- Performance is robust – with graceful degradation
- Brains are extremely power and space efficient (“peta-flop computer on 20 Watt”)
- Calls for a “neurorobotics approach”

Human Brain Project

Ein Ansatz: Spiking Neural Networks SNN

Gepulste neuronale Netze

- Derzeit am häufigsten/häufig diskutierte KNN Modelle
- Hintergrund: Möglichst reale Abbildung natürlicher NN
- Berücksichtigen auch den zeitlichen Effekt der Aktivierung von Neuronen

- Idee:
  Neuronen feuern nicht wie bei MLP in jedem Propagationszyklus sondern
  abhängig von Kodierungsmodellen, Aktionspotential
  (als Folge der Frequenz eingehender Spikes oder der Zeitspanne zw. Spikes)

Spiking Neural Networks SNN

- Signal besteht aus kurzen elektr. Pulsen
- Pulse (Aktionspotentiale/Spikes) ~100mV der Dauer v. 1-2 ms
- Puls ändert sich bei Propagation entlang des Axons nicht

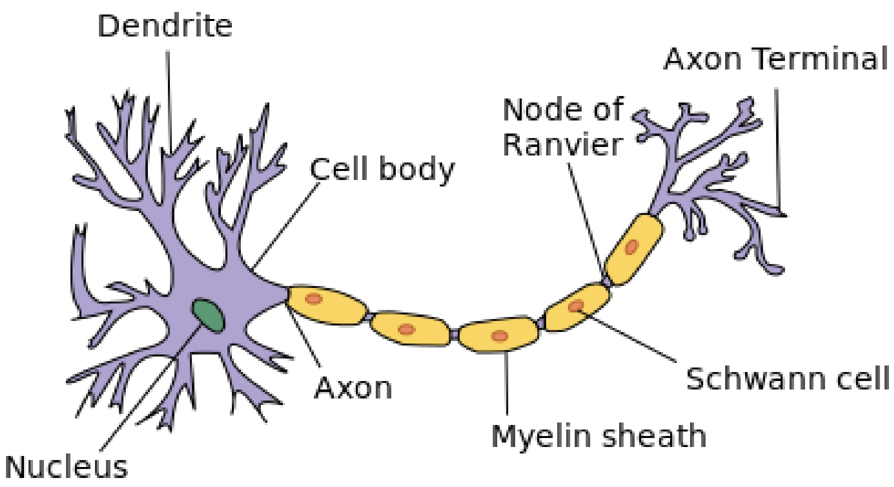

- Da alle Spikes eines Neurons gleich sind tragen sie keine Information

→

- Anzahl und Zeitpunkte der Spikes spielen eine Rolle
  z.B.: 20-50 Spikes in kurzer Zeit aktivieren Folgeneuron

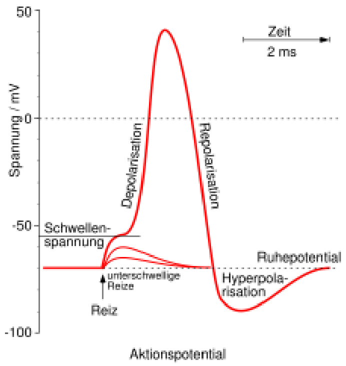

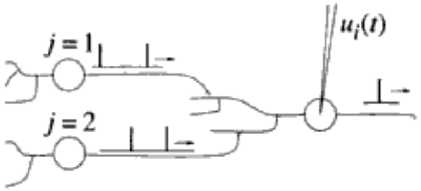

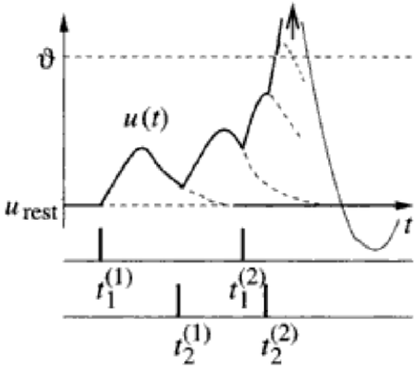

Spiking Neural Networks SNN

- In jedem kleinen Volumen des nat. Kortex werden Tausende von Spikes pro. ms emittiert

- Viele Forschungsfragen:
  - Aufbau Gehirn?
  - Teilsysteme - Aquivalenz zu anderen (bekannten) Algorithmen
  - (Unüberwachtes) Lernen?
  - Wie entsteht daraus Kognition?
  - HW - Realisierung?
  - ....

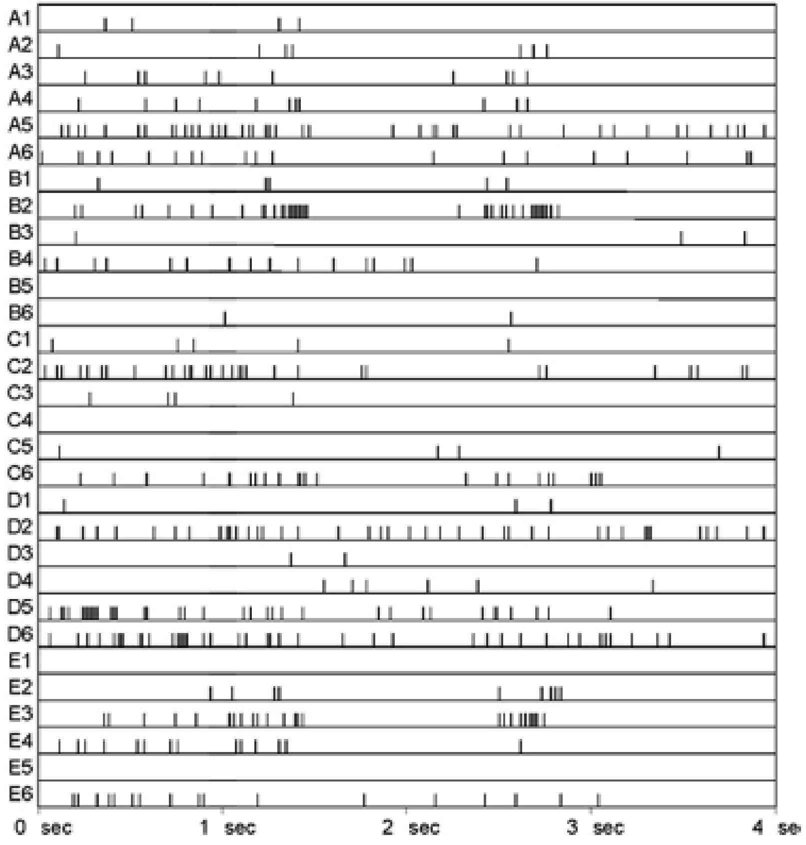

30 Neuronen im Affenkortex?

Forschungsfragen am FZI

- Was lässt sich dadurch in der Robotik erreichen?
  Wie? Wieso?
- Gibt es Modularität?
- Welche? Wie?
- Umsetzung in Verhalten?
- Wie lernen solche NN?
  (Auf Basis vorhandener
  NN- Modelle)
- Interesse?
  → FZI

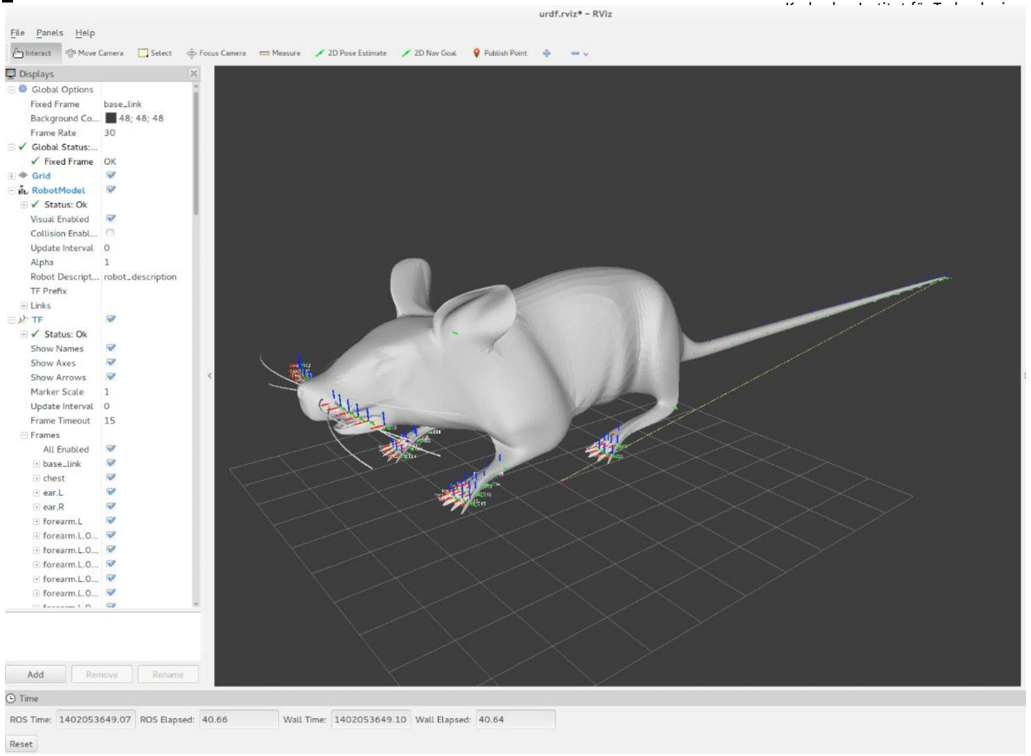

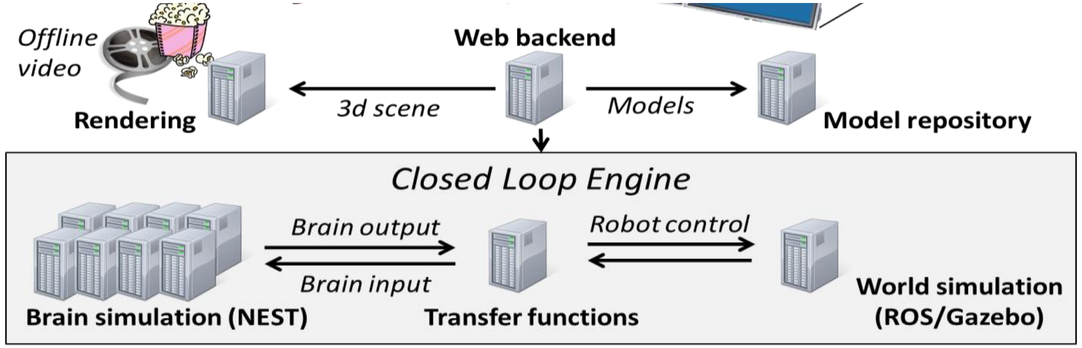

NN: Einordnung

Typ der Inferenz	induktiv	⟷	deduktiv
Ebenen des Lernens	symbolisch	⟷	subsymbolisch
Lernvorgang	überwacht	⟷	unüberwacht
Beispielgebung	inkrementell	⟷	nicht inkrementell
Umfang der Beispiele	umfangreich	⟷	gering
Hintergrundwissen	empirisch	⟷	axiomatisch

Literatur

- *Tom Mitchell*: ***Machine Learning***. McGraw-Hill, New York, 1997.
- *M. Berthold, D.J. Hand*: ***Intelligent Data Analysis.***
- *P. Rojas*: ***Theorie der Neuronalen Netze – Eine systematische Einführung***. Springer Verlag, 1993.
- *C. Bishop*: ***Neural Networks for Pattern Recognition.*** Oxford University Press, 1995. Vorlesung „Neuronale Netze 2006“ http://isl.ira.uka.de/
- (siehe auch „Ein kleiner Überblick über Neuronale Netze“, http://www.dkriesel.com)